

面向创新价值评估的摘要质量指标构建 v2

Abstract

学术摘要在科研传播与知识检索中发挥着关键作用，自动生成高质量学术摘要已成为大语言模型的重要应用方向。然而，科研摘要不仅需要事实准确，还需要覆盖研究动机、方法贡献及研究局限等高层认知信息，现有评估指标主要依赖文本相似度或局部事实核查，难以全面刻画摘要的科研创新价值。为此，我们提出 **InnoSum-Bench**，一个面向创新价值的学术摘要质量评估方法，从 Factual Consistency (FC) 与 Cognitive Coverage (CC) 两个互补维度进行评估。我们构建了包含 120 篇多学科论文及 240 篇人工标注摘要的数据集，并在六种摘要生成策略下评估七种主流大语言模型。发现当前模型通常能够保持较高的事实一致性，但在认知覆盖方面仍存在明显不足，尤其容易忽略研究动机、方法局限性及未来研究方向；同时，直接提示与链式思维提示在大多数设置下差异较小，CoT 未表现出稳定优势。我们希望 InnoSum-Bench 能够为科研场景下的摘要质量评估与模型能力分析提供新的研究视角，并促进面向科研创新价值的学术摘要生成方法的发展。

Introduction

将复杂科研论文压缩为结构清晰且信息完整的摘要，是科学传播与知识获取中的重要环节【49】。高质量学术摘要不仅帮助研究人员快速把握论文贡献，还支持文献筛选、跨学科协作以及潜在研究方向的探索。在信息爆炸与科研快速迭代的背景下，自动生成学术摘要逐渐成为提升科研效率的重要工具。随着大语言模型在长文本生成任务中的能力不断增强，利用模型自动生成学术论文摘要已成为辅助科研阅读的重要方向。因此，如何有效评估模型生成摘要的质量，成为推动该领域发展的关键问题。

为评估自动摘要质量，已有研究从不同评估侧重点提出了多种方法。第一类方法基于文本相似度进行评估，例如 ROUGE【18】通过 n-gram 重叠衡量摘要与参考摘要之间的词汇覆盖度，语义表示方法【19,20】则利用上下文嵌入在语义空间中计算文本相似度，以更好地处理复述与语义等价问题。第二类方法关注摘要内容的事实一致性。基于问答的评估方法【25,41】通过自动生成问题检验摘要信息是否能够由原文支持，而语义单元分解方法【23】将文本拆解为原子事实并计算其被支持比例，从而实现更细粒度的事实一致性评估。第三类方法利用大语言模型进行综合评估，相关工作【21】通过多维度评分等方式提升自动评估的灵活性与表达能力。这些方法从事实一致性以及综合语义理解等角度对摘要质量进行了评估。

尽管现有方法取得了显著进展，它们仍难以全面反映学术摘要在科研场景中的真实价值。现有指标主要关注表层语义匹配或信息覆盖程度，而忽略了摘要在支持更高层认知活动方面的作用，例如对研究动机、研究局限性、潜在影响以及未来研究方向等信息的表达能力。因此，即使模型在传统指标上取得较高得分，其生成的摘要仍可能缺乏对科研核心洞察的提炼能力，难以有效支持研究者进行深入理解与创新思考。

为解决上述问题，我们提出 **InnoSum-Bench**，一个面向科研创新价值的学术摘要评估方法。InnoSum-Bench 从两个互补维度对摘要质量进行评估：Factual Consistency (FC) 用于评估生成摘要是否准确传达关键科研事实，Cognitive Coverage (CC) 用于评估生成摘要是否覆盖支持科研思考的高层认知信息。通过结合这两个维度，我们能够刻画摘要的事实表达质量与认知支持能力，从而更全面地评估学术摘要在科研创新语境中的实际价值。我们构建了一个多学科论文摘要数据集，包含 120 篇科研论文及 240 篇由双人独立标注的结构化参考摘要，并在六种常见长文档摘要生成策略下评估了七种主流大语言模型。

我们获得了两个重要发现。首先，当前大语言模型生成的摘要通常能够保持较高的事实一致性，但在认知覆盖方面仍存在明显不足，尤其容易忽略研究动机、方法局限性以及未来研究方向等高层认知信息。其次，直接提示 (SimPrompt) 与链式思维提示 (Chain-of-Thought, CoT) 之间的性能差异较小，CoT 并未在科学论文摘要任务中表现出稳定优势。这些结果表明，现有模型在提炼科研核心洞察方面仍存在显著提升空间。我们希望 InnoSum-Bench 能够为科研场景下的摘要质量评估与模型能力分析提供新的视角，并促进学术摘要生成方法的发展。

本文其余部分安排如下：第 2 节回顾相关工作；第 3 节介绍所提出的 InnoSum-Bench；第 4 节展示实验设置与结果分析；第 5 节给出结论并讨论研究局限与未来工作。

2 Related work

2.1 Scholar Paper Summarization

自动文本摘要的目标是从冗长的原文中生成简洁而信息完整的摘要。早期研究主要采用抽取式方法，通过特征向量中心性或余弦相似度等指标为句子评分并择优选取【4, 5】。近年来，随着预训练语言模型的发展，生成式方法在学术文本摘要任务上取得了显著进展。

围绕学术论文摘要生成这一任务，现有研究大致从两个不同视角展开。第一类方法从学术社区的视角出发，通过挖掘学术社区对目标论文的评价信息来生成摘要。这类研究通常利用引用网络结构【34】或收集引用目标论文的句子来构建摘要【12, 15】，因为这些引用句往往蕴含了其他研究者对论文贡献的理解与评价。这类方法的优势在于能够提供来自学术共同体的外部视角，但其有效性高度依赖于论文已积累的引用数量，因此对于新近发表的论文难以适用。此外，这类方法反映的是学术群体对论文的解读，而非论文自身的完整内容。

第二类方法聚焦于论文内容本身。这类方法中，一种常见的思路是采用“抽取-生成”的两阶段框架，即先识别原文中的关键信息单元，再基于这些内容生成摘要。在抽取阶段，研究者运用多种策略筛选核心内容。例如，Rezapour等人【32】利用图结构识别重要句子；Lebanoff等人【35】对句子及句子对进行联合评分与选择；Majadly和Last【2】通过规则方法提取论文的关键方面。XSum【44】通过动态生成问题来引导对原文或相关文献内容的检索，而HERA【43】则先对论文各段落生成局部摘要，再使用大语言模型对这些局部摘要进行检索，找到相关信息后整合生成最终摘要。这类方法通过优先聚焦重要内容，有效降低了长文档处理的复杂度，但其往往依赖局部信息片段，难以完整把握论文整体的论证结构与逻辑演进。

另一种思路尝试直接对全文生成摘要。这类方法通常采用“分块处理”的策略来实现对全文信息的整合。例如，Leiva-Araos等人【3】采用MapReduce框架，将长文档划分为多个片段分别进行摘要生成，然后逐步合并这些中间摘要，最终形成完整摘要。这种策略虽然在技术上实现了全文覆盖，但在将文档拆分为独立片段进行独立摘要时，往往难以保持论文原有的结构组织和跨章节信息关联，导致生成摘要出现逻辑断裂或关键信息分散的问题。

针对上述分块处理中存在的信息碎片化与逻辑连贯性不足这一挑战，后续研究从不同角度探索了解决方案。一些方法采用自底向上逐层摘要聚合的策略，例如HTSIR【46】和MAL-RAG【48】利用文档的层级结构，先对底层文本片段进行摘要，再逐层聚合形成章节乃至文档级的摘要表示。另一些方法如CoTHSSum【47】则采用按章节划分的长文本处理策略以保留原文结构，进而采用分层生成的策略完成摘要。这类方法通过保留原文的组织框架，更好地维持了论证的连贯性与结构完整性。

2.2 Automatic Evaluation Metrics

为评估生成摘要的质量，研究者提出了多种自动指标。早期方法如 **ROUGE**【18】和 **METEOR** 基于 n-gram 匹配评估摘要与参考文本的表面相似度，但停留在词汇层面，难以捕捉语义丢失。随后，基于语义嵌入的方法如 **BERTScore**【19,20】利用预训练语言模型的上下文向量计算文本相似度，能够处理语义等价和复述问题，但仍主要关注整体语义重叠，对事实一致性和细粒度信息覆盖刻画有限。

为进一步提升精细度，部分方法从内容一致性和覆盖度出发设计专门评估手段。例如，**QAGS**【25】、**QAEval**【26】、**QAFactEval**【27】等基于问答的评估框架通过检验摘要回答问题的能力衡量事实一致性；基于语义单元分解的方法【23】将文本拆解为原子事实，计算其被支持的比例，实现比句子级更精细的事实精度度量。沿此思路，部分研究提出了面向层面的评估框架【24,28】，将参考摘要拆解为背景、方法、结果、结论，分别评估各层面的覆盖情况。

近年来，基于大语言模型的评估框架展现出高度灵活性。**G-Eval**【17】利用链式推理和概率加权求和，将离散评分转化为连续分数，提高了评估的细粒度与灵活性；**GPTScore**【21】则可根据自定义描述词进行多维度评分，同时兼顾一致性、覆盖度和连贯性。

尽管上述方法从文本相似度、事实一致性及多维语义评估等角度提升了自动评价的精细度，但仍主要关注信息匹配与事实覆盖，难以判断摘要是否有效传达论文的核心科研贡献。此外，现有指标普遍缺乏对不同认知层级信息的区分，难以评估摘要在支持理解、分析与判断等高层认知活动方面的能力。因此，如何从科研创新价值角度对学术摘要进行评估仍是一个有待解决的问题。

2.3 Summarization Datasets


现有学术摘要数据集在推动自动摘要技术发展方面发挥了重要作用。早期研究通过收集来自 arXiv 和 PubMed 的大规模文献语料构建了摘要生成数据集【39】，该数据集保留了原文的篇章结构（如引言、方法和结论），为长文档模型的训练提供了基础。

随后，研究者针对不同应用场景开发了高压缩比的摘要数据集。例如，**SciTLDR**【30】提供作者自写或基于同行评审意见的极短摘要（平均约20词），适用于文献快速初审或筛选场景。另一类数据集则利用引文网络捕捉学术社区的集体视角，如 **CL-SciSumm**【31】和 **SciSummNet**【38】，通过整合引用句与原文片段，为融合学术影响力的摘要生成提供资源。

近期研究则探索了 AI 生成结构化摘要的新范式。**CS-PaperSum**【40】利用 ChatGPT 为 91,919 篇计算机科学论文生成结构化摘要，涵盖关键贡献、方法创新、评估指标等字段；**ScholarSum**【24】构建了 500 条模型生成摘要的元评估基准，并按照背景、方法、结果、结论四个核心维度分解，为细粒度摘要质量评估提供支撑。

总体来看，上述数据集的设计目标主要集中在信息压缩与快速阅读上。然而，当评估需求从“快速筛选”转向“深度理解与创新分析”时便暴露出不足：它们往往弱化甚至省略了方法细节、验证过程、研究局限等对科研活动至关重要的深层信息。这一信息缺失限制了从大规模文献中自动挖掘潜在研究关联与创新线索的可能性。

3 InnoSum-Bench



3.1 Data Collection and Preprocessing

(1) Task Definition

在本研究中，我们从创新价值的角度探讨了自动评估学术论文摘要的问题。给定一篇长篇科研论文及其对应的人工参考摘要，目标是评估由大语言模型生成的摘要是否能够准确传达关键科研事实，并支持研究者进行深入思考与潜在创新线索的挖掘。为此，我们从事实一致性（FC）与认知覆盖度（CC）两个互补维度对摘要质量进行评估。

(2) Data Collection

为了验证所提出评估指标的有效性，我们构建了一个多学科论文摘要数据集，涵盖计算机科学与天文学、计算机科学与教育以及计算机科学与医疗健康三个交叉学科领域。每个领域选取 40 篇论文，共计 120 篇科研论文。

论文检索阶段通过 Semantic Scholar 与 NASA ADS 提供的 API 接口进行文献获取。我们通过表1所示的主题关键词进行检索，并依据引用次数进行递减排序筛选，过滤掉引用次数少于 20 次或者无法获取完整 PDF 的文献，满足筛选条件的论文通过 DOI 自动下载全文 PDF 文件。

(3)Data Preprocessing

获取论文 PDF 后，我们使用 MinerU【45】对 PDF 文档进行解析。解析过程中提取论文正文文本并转换为 Markdown 格式，保留论文原有的章节层级。随后删除参考文献与附录部分，仅保留引言、方法、实验及结论等核心章节内容，从而减少无关信息干扰。

在人工摘要标注阶段，我们邀请 6 名计算机专业研究生参与标注工作。每篇论文由两名标注者独立撰写摘要，以保证摘要表达的多样性与客观性。所有摘要均遵循统一的结构化模板，由五个核心模块组成：Research Background、Methodology、Datasets、Experiments 和 Discussion。其中，Research Background 模块用于概括研究问题、应用背景及研究动机；Methodology 模块总结论文的整体方法思想，并描述主要方法流程及关键技术，同时可包含核心公式及其变量说明；Datasets 模块列出论文使用的数据集来源及基本特征；Experiments 模块总结主要实验设置、评价指标及关键结果，并给出对应结论；Discussion 模块对论文贡献、局限性及潜在影响进行综合总结。

为保证人工摘要质量，我们采用一致性控制机制。首先使用 all-MiniLM-L6-v2 句向量模型计算同一论文两篇摘要之间的语义相似度，当相似度低于 0.6 时，视为摘要之间存在内容偏差，由标注者进行重新复核与修订，在保留独立表达的同时确保人工摘要能够覆盖论文核心信息。

数据集最终包含 120 篇科研论文及 240 篇人工摘要。论文平均长度为 16.59 页（约 8,314 词），人工摘要平均长度为 911 词，对应约 9:1 的压缩率。数据集的详细统计信息如表 2 所示。

Topic		
Alzheimer Disease Detection	Anomaly Detection	ECG Arrhythmia Detection
Exoplanet Candidate Classification	Galaxy Morphology Classification	Galaxy Morphology Classification
Knowledge Tracing	Learning Resource Recommendation	MRI Brain Tumor Segmentation
Personalized Learning	Photometric Redshift Estimation	Stellar Object Classification
llar Physical Parameter Determinat	Student Performance Prediction	Variable Star Classification

Table 1: Topics Used for Paper Retrieval

领域	论文数量	人工摘要数量	论文平均页数	论文平均长度 (词)	摘要平均长度 (词)	平均引用次数
天文	40	80	21.27	10712.88	1023.71	95.55
教育	40	80	14.82	8074.93	793.54	179.95
医疗	40	80	13.68	6154.85	916.79	354.75
总计/平均	120	240	16.59	8314.22	911.35	210.08

3.2 Evaluation Metric

Huber and Niklaus 【42】的研究指出，现有多数评测基准主要集中于中低阶认知技能，缺乏对分析、评价和创造等高阶认知能力的系统评估。这一现象在学术摘要评估中尤为明显：传统指标通常关注文本表面相似度或信息覆盖率，却较少评估摘要是否能够支持研究者进行更深入的学术理解与判断。

受到这一研究的启发，我们认为高质量学术摘要不仅需要准确传递研究事实，还应能够支持研究者在不同认知层级上的理解与思考。基于这一认识，我们设计了面向创新价值的摘要质量评估方法，由两个互补维度组成：事实一致性（Factual Consistency, FC）和 认知覆盖度（Cognitive Coverage, CC）。前者用于评估生成摘要是否准确传达关键科研事实，后者用于评估生成摘要是否覆盖支持科研思考的高层认知信息。

(1) Factual Consistency

结合学术论文的典型结构，我们将摘要中的关键信息划分为八类语义单元：

Core Problem: The core scientific problem or application challenge addressed by the research.

Method Innovation: New ideas or methodological innovations proposed by the research.

Core Techniques: Key technologies or model components used to implement the method.

Validation Evidence: Experimental setups, datasets, or comparison methods supporting the conclusions.

Performance Results: Key experimental results or performance metrics.

Field Value: Potential impact or application value of the research.

Research Limitations: Limitations explicitly stated in the paper.

Future Directions: Future research directions proposed by the paper.

在评估过程中，我们使用混合智能体（Mixture of Agents, MoA）框架，从生成摘要与参考摘要中分别提取对应语义单元。具体而言，DeepSeek-V3.1 作为主要提取模型，首先从模型生成摘要与参考摘要中识别对应的语义单元。随后，将提取的语义单元提交给多个审查模型（包括 Gemini 2.0 Flash、Qwen 和 GPT-4o-mini）进行独立评估。每个模型从五个维度对语义单元的质量进行检查：准确性（Accuracy）、完整性（Completeness）、规范性（Normativity）、相关性（Relevance）以及冗余性（Redundancy），并给出通过或拒绝的判定。

我们采用多数投票机制（majority voting）作为通过标准，当超过半数审查模型给出肯定判断时，该语义单元被认为通过审查；若未达到多数同意，则由 DeepSeek-V3.1 根据审查意见重新生成语义单元，并再次提交审查。该过程最多迭代 5 次，直至审查通过或达到最大迭代次数。

完成语义单元提取后，我们对每个语义单元进行评分。评分采用 五级评分标准（1-5），其中分值越高表示生成摘要与参考摘要在该语义单元上的事实一致性越高。

最终的事实一致性得分计算如下：

$$Score_{FC} = \frac{1}{N} \sum_{i=1}^N s_i \quad (1)$$

其中， $N=8$ ， $s_i \in \{1,2,3,4,5\}$ 为单元评分。

(2) Cognitive Coverage

在保证事实准确性的基础上，高质量学术摘要还应能够支持研究者在不同认知层级上的理解与思考。为刻画摘要的认知深度，我们借鉴 Bloom 认知分类学（Bloom's Taxonomy），从六个递进层级评估摘要对学术理解的支持能力：

Memory Level: Focus on explicit factual information, such as terminology, dataset names, method names, or key experimental results.

Comprehension Level: Focus on understanding and summarizing the core research content, such as research objectives, methodological workflow, or main findings.

Application Level: Focus on application scenarios or usage explicitly mentioned in the summary.

Analysis Level: Focus on comparisons, performance differences, or causal relationships between different methods or experimental results described in the summary.

Evaluation Level: Focus on contributions, advantages, or limitations explicitly stated in the summary.

Creation Level: Focus on future research directions or extensions explicitly proposed in the summary.

针对每一个认知层级，我们从人工参考摘要中各生成两个评估问题，从而构建覆盖不同认知深度的问题集合。问题同样通过 MoA 框架进行多模型协作生成与审核。DeepSeek-V3.1 首先基于参考摘要生成候选问题，随后由 Gemini-2.0-Flash、Qwen 和 GPT-4o-mini 从层级一致性、答案准确性和冗余性三个维度进行独立评估，并采用多数投票机制确定是否接受。若未通过，则由 DeepSeek-V3.1 进行修订并重新提交，该过程最多迭代 5 次，直至审查通过或达到最大迭代次数。

在获得问题集合后，使用 DeepSeek-V3.1 根据模型生成摘要回答这些问题。最终得分通过两种维度进行综合评估：大语言模型评分 $S_j \in \{1,2,3,4,5\}$ 和语义向量相似度 $S_{v_j} \in [0,1]$ ，两者通过加权融合得到最终得分：

$$Score_{CC} = \frac{1}{N} \sum_{j=1}^N (\alpha S_j + \beta \cdot S_{v_j}) \quad (2)$$

其中，N表示评估问题数量，权重参数设置为 $\alpha=0.7$ ， $\beta=0.3$

4 Experiment Results

4.1 Experimental Setup

Evaluated Models: 为了验证所提出的 FC 与 CC 指标的有效性，我们选取了七个主流大语言模型生成论文摘要进行实验，包括 DeepSeek V3.1 【】、DeepSeek R1 【】、Gemini 2.0 Flash 【】、GLM-4 Flash 【】、GPT-4o mini 【】、LLaMA-3.3-70B-Instruct 【】 以及 Qwen-Max-2025-01-25 【】。

Summary Generation Strategies: 由于学术论文篇幅较长，直接将全文输入大语言模型容易受到上下文长度限制，因此需要对长文档进行处理。相关研究中常用的长文本处理策略包括 Heading-Based Splitting 【47】、MapReduce 【3】 与 RAG 【44】。

其中，Heading-Based Splitting 方法按照论文的章节标题对全文进行分段，并依据预定义的五部分摘要模板，从相关章节中提取信息生成对应的子摘要，最终将各分子摘要整合为完整的论文摘要。MapReduce 方法将论文划分为固定长度的文本块（chunk size = 1000），首先为每个文本块生成中间摘要（Map 阶段），然后对这些中间摘要进行整合（Reduce 阶段），得到最终摘要。在 RAG 方法中，论文同样首先被划分为固定长度的文本块（chunk size = 600），并使用 all-MiniLM-L6-v2 模型进行向量化后存储到 FAISS 索引中。针对摘要模板的五个部分分别构造查询，从向量库中检索最相关的 top-k（top-k = 5）文本块，并基于检索到的内容生成对应部分的子摘要，最后将五个子摘要组合为完整摘要。

在提示策略方面，我们比较了简单提示（SimPrompt）与思维链提示（Chain-of-Thought, CoT）【】两种方式。SimPrompt 采用直接生成摘要的简洁提示，引导模型对输入文本进行概括；CoT 提示则通过引导模型分步推理，逐步识别论文核心问题、方法和实验结果等，再生成最终摘要。

通过将两种提示策略与三种长文档处理方法组合，我们获得了六种摘要生成策略：SimPrompt + Heading-Based Splitting、SimPrompt + MapReduce、SimPrompt + RAG，以及 CoT + Heading-Based Splitting、CoT + MapReduce 和 CoT + RAG。这种组合设计使我们能够系统分析提示策略与长文本处理方法的交互影响。

Baseline Metrics: 在评估阶段，我们对比了多种自动摘要评估指标，包括 ROUGE、Vector Similarity、BERTScore、Facet-aware Metric (FM) 以及 QuestEval，并与本文提出的 FC 与 CC 指标进行对比分析。FC 与 CC 指标统一采用 GPT-4o mini 进行评估。其中，FM基于文档 BMRC

（Background、Method、Result、Conclusion）结构对摘要进行分解评估，以衡量不同结构化信息的覆盖情况。QuestEval则通过自动生成问答对，并利用原文或参考摘要验证答案，从而评估摘要对核心信息的支持能力。

4.2 Main Result

我们首先比较不同摘要生成模型在各项评价指标上的表现，结果如表 3 所示。总体来看，DeepSeek V3.1 在多数指标上取得最优或次优结果，包括 FM、ROUGE-1、ROUGE-2 以及 FC 指标，同时在 BERTScore 与 Vector similarity 上也保持较高水平。这表明该模型能够稳定提取论文核心内容，并在关键事实表达方面具有较强能力。然而，其 CC 得分并非最高，说明较高的事实一致性并不必然对应更全面的认知信息覆盖。相比之下，DeepSeek R1 在 CC 指标上取得最高得分，表明其生成摘要在研究动机、研究局限以及未来方向等高层认知信息的覆盖方面更具优势。在其余模型中，LLaMA-3.3-70B-Instruct 在 QuestEval 指标上取得最高得分，并在 ROUGE 与 FC 指标上保持较稳定表现，显示出较强的事实表达能力。相比之下，GLM-4 Flash 在多数指标上得分较低，尤其在 FC 与 CC 指标上均明显落后，说明其在长文档摘要任务中对关键信息的提炼与组织能力仍存在一定局限。

为进一步分析摘要生成策略对结果的影响，我们统计了六种生成策略在所有评价指标上的表现，结果如表 4 所示。整体来看，不同策略之间的性能差异明显小于不同模型之间的差异，说明摘要质量主要受生成模型能力影响，而摘要生成策略的影响相对有限。

从长文本处理策略来看，Heading-Based Splitting 在多数指标上取得较优结果，尤其在 SimPrompt 设置下，该策略在 FM、ROUGE 系列指标以及 FC 与 CC 指标上均表现较好。这反映出利用论文原有章节结构能够帮助模型更好地整合跨章节信息，从而提升事实表达与认知信息覆盖能力。相比之下，RAG 在 QuestEval 指标上表现相对较好，说明基于检索的策略能够聚焦局部关键信息，在基于问答验证的评估方式中具有一定优势。MapReduce 在 Vector similarity 指标上表现较高，表明分块摘要再合并的方式能够在一定程度上保留原文语义表达，从而在语义相似度指标上取得较好结果。

从提示策略角度来看，SimPrompt 与 CoT 的得分整体差异较小，且未呈现稳定优势。在部分指标上，SimPrompt 甚至略优于 CoT。这一结果表明，引入逐步推理过程并不能稳定提升科学论文摘要质量。

model	FM	QuestEval	rougeL	cosine_similarity	BERTSCORE	FC(gpt 4o mini)
deepseek r1	0.8241	0.3919	0.2596	0.8513	0.8384	3.2
deepseek v3.1	0.8303	0.4015	0.2839	0.8647	0.8444	3.3
gemini 2.0 flash	0.819	0.4056	0.2642	0.855	0.8376	3.1
glm 4 flash	0.7655	0.4105	0.2371	0.8236	0.8384	3.0
gpt 4o mini	0.7798	0.4073	0.2398	0.8484	0.8393	3.1
llama-3.3-70b-i	0.791	0.413	0.26	0.8555	0.8416	3.2
qwen-max-2025	0.8151	0.4025	0.2658	0.8626	0.8425	3.1

表 3: Scores of seven summary generation models. Results are reported as mean $\pm$ standard deviation, calculated across six summary generation strategies. Bold font indicates the best result under each metric, and red font indicates the worst result.

strategy_type	prompt	FM	QuestEval	rougeL	cosine
Heading-Based Splitting	COT	0.7978	0.4120	0.2778	
Heading-Based Splitting	SimPrompt	0.8133	0.3946	0.2787	
MapReduce	COT	0.8009	0.3966	0.2570	
MapReduce	SimPrompt	0.8111	0.3985	0.2461	
RAG	COT	0.7928	0.4157	0.2617	
RAG	SimPrompt	0.8053	0.4104	0.2306	

Table 4 Scores under six summary generation strategies. Results are reported as mean $\pm$ standard deviation, calculated across seven summary generation models. Bold font indicates the best result under each metric, and red font indicates the worst result.

4.3 Reliability Analysis

(1) Human Correlation

为验证所提出的 Factual Consistency (FC) 与 Cognitive Coverage (CC) 指标与人工评分的一致性，我们在 SimPrompt + Heading-Based Splitting 设置下，对 DeepSeek R1 生成的摘要进行人工标注，并计算不同评估模型与人工评分之间的 Spearman 相关系数、组内相关系数 ICC(2,1) 以及分数偏差 Δ -Score。相关结果分别列于 Table 5 与 Table 6。

在事实一致性 (FC) 评估任务中，自动评分与人工判断呈现较强相关性，Spearman 相关系数 ρ 介于 0.5180–0.6679 之间 ($p < 0.001$)。其中，GPT-4o Mini 在三项指标上均取得最佳表现 ($\rho = 0.6679$ ， $ICC = 0.6768$ ， $\Delta = 0.2172$)，说明其在排序一致性与绝对评分上均与人工判断较为接近。在认知覆盖度 (CC) 评估任务中，整体趋势与 FC 类似，不同评估模型的 Spearman ρ 分布于 0.5473–0.7090 区间。GPT-4o Mini 仍取得最佳表现 ($\rho = 0.7090$ ， $ICC = 0.5947$ ， $\Delta = 0.2615$)，进一步表明其具有较好的评分一致性。

为进一步分析不同评价指标之间的关系，我们绘制了 Spearman 相关性热力图，如 Fig.2 与 Fig.3 所示。可以观察到传统指标与人工评分的相关性明显低于 FC 与 CC：ROUGE-L、BERTScore 与人工评分

的 Spearman ρ 多数处于中等水平 ($\approx 0.2-0.4$) , Cosine Similarity 和 QuestEval 相关性更低, 表明传统指标难以充分反映摘要在**传达科研事实**和**支持高层次科研思维**方面的价值。不同评估模型计算得到的 FC (或 CC) 指标之间具有较高相关性, 表明不同评估模型在评分趋势上具有较好一致性, 能够稳定反映摘要的事实一致性与认知覆盖能力。

	Spearman	ICC(2,1)	Δ -Score
FC (deepseek v3.1)	0.6282	0.4586	0.4370
FC (deepseek r1)	0.6572	0.4089	0.4849
FC (gpt 4o mini)	0.6679	0.6768	0.2172
FC (gemini 2.0 flash)	0.6336	0.3197	0.5646
FC (glm 4 flash)	0.5264	0.3914	0.3339
FC (llama 70b)	0.5180	0.2832	0.4354
FC (qwen)	0.6471	0.4955	0.2672

Table5 Consistency comparison between different evaluation models and human scores on Factual Consistency (FC), including Spearman correlation, ICC (2,1), and Δ -Score. Bold font indicates the best result under each metric, and red font indicates the worst result.




Fig2 Heatmap of Spearman correlations among different evaluation metrics on Factual Consistency (FC).

	Spearman	ICC(2,1)	Δ -Score
CC (deepseek v3.1)	0.6680	0.3852	0.4738
CC (deepseek r1)	0.6574	0.4171	0.4143
CC (gpt 4o mini)	0.7090	0.5947	0.2615
CC (gemini 2.0 flash)	0.6199	0.3500	0.4670
CC (glm 4 flash)	0.5473	0.4913	0.2943
CC (llama 70b)	0.5785	0.4764	0.3119
CC (qwen)	0.6291	0.5123	0.2773

Table6 Consistency comparison between different evaluation models and human scores on Cognitive Coverage (CC), including Spearman correlation, ICC (2,1), and Δ -Score. Bold font indicates the best result under each metric, and red font indicates the worst result.




Fig3 Heatmap of Spearman correlations among different evaluation metrics on Cognitive Coverage (CC).

(2) Statistical Power Analysis

为评估不同评价指标区分生成模型差异的能力，我们通过 1000 次 bootstrap 重采样并结合配对 t 检验 ($\alpha = 0.05$) 计算各指标的平均统计功效 (Average Statistical Power)。

实验结果如图 4 所示，CC (Cognitive Coverage) 整体表现出较高的统计功效，在不同评估模型下数值分布于 0.5423–0.7096 区间；FC (Factual Consistency) 的统计功效介于 0.4962–0.6726 之间，说明两项指标能够区分不同生成模型之间的摘要质量差异。相比之下，ROUGE 系列指标同样表现出较高统计功效，表明基于词元重叠的指标在检测系统级差异方面仍具有一定优势。Vector similarity (0.4068) 与 BERTScore (0.4589) 的统计功效处于中等水平，而 QuestEval (0.1453) 的统计功效最低，说明其在区分不同模型输出方面的能力有限。




Fig4 Average statistical power of different metrics.

(3) Self-preference Analysis

为分析 LLM 评估模型在评分过程中是否存在自我偏好（self-preference）现象，即评估模型是否倾向于对自身生成的摘要给予更高评分，我们构建了生成模型与评估模型之间的交叉评分矩阵，并绘制了对应的热力图。从图 5 可以观察到，在 FC 与 CC 两种评价指标下，对角线位置（即模型对自身生成摘要的评分）并未明显高于其他位置。该结果表明，评估模型未表现出明显的自我偏好，其评分结果主要由摘要内容本身决定，而非生成模型与评估模型之间的一致性。




Fig. 5 Cross-evaluation heatmap between generation models and evaluation models. (a) Factual Consistency (FC) scores; (b) Cognitive Coverage (CC) scores. Rows represent generation models, columns represent evaluation models. Diagonal positions correspond to models evaluating their own summaries.

(4) Cross-domain Evaluation

图 6展示了不同领域下 FC 与 CC 两个维度上的平均得分。在事实一致性（FC）维度上，医学（Medical）领域整体得分最高，天文学（Astronomy）次之，而教育（Education）领域得分相对较低。这一差异可能与不同领域论文的写作结构与信息表达方式有关。医学与天文学论文通常包含较为明确的实验流程、定量结果和结构化描述，使模型在生成摘要时更容易对齐原文中的关键事实信息；相比之下，教育领域论文往往包含更多情境化讨论或定性分析，从而增加了模型在保持事实一致性方面的难度。相比之下，在认知覆盖度（CC）维度上，不同领域之间的差距明显缩小。尽管医学领域在多数配置下仍取得略高得分，但各领域之间的波动范围较小。这说明认知层级支持能力在不同学科之间相对稳定，而事实一致性更容易受到领域写作风格与信息表达方式的影响。




Fig. 6 Average FC and CC scores across different research fields. Each subplot corresponds to a combination of a summary generation strategy and prompt configuration. The x-axis indicates research fields. Blue bars represent Factual Consistency (FC), and green bars represent Cognitive Coverage (CC).

(5) Length-based Evaluation

图 7 展示了不同论文篇幅条件下各生成策略在 FC 与 CC 两个维度上的平均得分。对于 RAG 方法，其在短篇论文（≤10 页）条件下取得最高得分，而在中篇与长篇论文上的表现有所下降。这表明当文档较短且关键信息较为集中时，检索式生成策略更容易捕获核心内容；随着文档长度增加，信息分布更加分散，检索策略的有效性有所减弱。

对于 Heading-Based Splitting Classification 与 MapReduce 方法，两者均在中篇论文（11–25 页）条件下表现最佳，在短篇与长篇论文上得分略低。这说明基于章节结构划分或分块聚合的策略在文档长度适中时更有利于整合跨章节信息。

总体而言，RAG 更适用于较短文档，而 Heading-Based Splitting Classification 与 MapReduce 在处理中等长度文档时表现更为稳定。




Fig. 7 Average scores of different summary generation strategies across paper lengths. Papers are categorized as short (≤ 10 pages), medium (11–25 pages), and long (> 25 pages). Blue bars represent Factual Consistency (FC), and green bars represent Cognitive Coverage (CC).

4.4 Parameter Analysis

为了分析长文档处理策略中关键参数对摘要质量的影响，我们随机选取 30 篇论文对 MapReduce 与 RAG 方法中的参数进行调节，并使用 FC 与 CC 指标进行评估。

如 Fig. 8 所示，在 MapReduce 方法中，随着 chunk size 从 600 增加到 1000，FC 与 CC 得分均持续提升，并在 chunk=1000 时达到最高；当进一步增加到 1200 时，两项指标均出现下降。这一趋势表明，较小的文本片段难以提供完整上下文，导致关键信息缺失，而过大的片段则引入更多次要内容，分散模型对核心信息的关注。

在 RAG 方法中（Fig. 9），top-k 与 chunk size 对结果的影响呈现出类似趋势。随着检索数量从 $k=3$ 增加到 $k=5$ ，FC 与 CC 均明显提升，说明适当增加检索片段有助于补充关键信息。然而，当 k 进一步增加到 7 时，得分变化不稳定，部分设置出现下降，表明额外引入的检索内容可能包含不相关信息，从而干扰摘要生成。从 chunk size 的角度来看，随着片段长度从 300 增加到 600，FC 与 CC 整体上升，

而在更大尺寸（如 700）时增益减弱甚至回落，说明过小片段信息不足，过大片段则降低检索片段之间的区分度。

综合来看，不同长文档处理策略在参数选择上均体现出类似的规律：摘要质量依赖于输入信息的有效组织，当信息不足时，模型难以恢复关键事实；而当信息过载时，模型则难以聚焦于核心内容。基于上述分析，我们在实验中采用 MapReduce 的 chunk size=1000，以及 RAG的 chunk size=600、top-k=5 作为默认设置。




Fig. 8 Performance of the MapReduce method under different chunk sizes. (a)CoT prompt; (b) SimPrompt. Blue bars represent Factual Consistency (FC), and green bars represent Cognitive Coverage (CC).




Fig. 9 Performance of the RAG method under different top-k and chunk size combinations. The x-axis represents top-k settings, and each subplot corresponds to a chunk size. Blue bars represent Factual Consistency (FC), and green bars represent Cognitive Coverage (CC).

4.5 Case Study

我们选取论文《*Neural Computation as a Tool for Galaxy Classification: Methods and Examples*》作为示例，对模型生成摘要与人工摘要进行对比，并分析不同指标下的表现。该案例展示了模型摘要在保持表层事实一致性的同时，仍可能在研究动机、证据支撑及高层认知信息方面出现缺失，而传统相似度指标难以识别这些问题。

如 Table 7 所示，在第一个示例中，人工摘要将研究目标明确表述为“实现星系形态的自动分类”，而模型摘要则将其转述为“评估输入参数的信息性”。尽管模型正确提及 PCA 与 ANN 等技术要素，但其改变了方法的核心动机。这类偏移不会造成明显的事实错误，因此在 ROUGE 或 BERTScore 等相似度指标上仍可能获得较高得分，但会影响对研究核心贡献的理解。在第二个示例中，模型摘要能够正确复述关键结论（例如使用 3 个主成分可达到与全部特征相当的性能），但明显压缩了实验过程，省略了训练样本规模、网络结构及优化方法等关键信息。这表明模型虽然保留了结论，但弱化了支撑结论的验证证据。此类问题在传统相似度指标下不易被识别，因为核心结论仍然保持一致。在第三个示例

中，人工摘要明确指出“监督学习引入人类偏见”这一关键局限，并提出未来研究方向（如引入多波段数据与无监督方法）。相比之下，模型摘要未能覆盖这些核心内容，而仅给出较为泛化的局限性描述（如噪声处理问题）。此类缺失主要集中在高层语义信息上。

为了进一步说明认知覆盖度的评估方式，Table 8 给出了六个 Bloom 认知层级中的示例问题及对应回答。可以看出，模型在低层认知任务中表现较好，而随着认知层级提升，其表现明显下降。在 Memory、Comprehension 与 Application 层级，模型能够正确回答问题，且与人工答案具有较高的语义相似度（均超过 0.9），表明其能够覆盖显式事实信息。然而，在 Analysis 层级，模型未能准确表达“variance alone is insufficient”这一关键结论；在 Evaluation 层级，模型未识别“supervised learning inherits human biases.”这一核心局限；在 Creation 层级，模型未能生成任何有效回答。这一趋势表明模型摘要在高层认知能力（分析、评价与创造）方面存在明显不足。

Fig. 10 则展示了该案例在不同指标下的评估结果。模型摘要在事实一致性（FC）上获得 3.75，同时在传统指标（如 ROUGE1=0.6433,ROUGE2=0.2698,ROUGEL=0.3452，

Vector similarity = 0.8521,BERTScore = 0.8592,FM=0.925,QuestEval=0.4035）上均表现较好。然而，其认知覆盖度（CC）仅为 2.97，显示出高层认知信息的缺失。

总体而言，该案例揭示了当前模型生成摘要的一个典型特征：模型能够保持事实一致性，但容易忽略研究动机、局限性及未来方向等高层认知信息。传统自动评价指标难以识别此类问题，相比之下，Factual Consistency 与 Cognitive Coverage 指标能够分别从语义单元与认知层级两个角度对摘要质量进行更细粒度刻画，从而揭示模型摘要在“表面正确”情况下潜在的信息缺失。

Human summary	DeepSeek R1 summary
Overarching Goal: To automate galaxy morphological classification by using Artificial Neural Networks (ANNs) for non-linear dimensionality reduction and supervised learning, effectively replicating human expert decisions. ...	Overarching Goal: Evaluate the informativeness of input parameters for Artificial Neural Networks (ANNs) using Principal Component Analysis (PCA) and encoder networks for dimensionality reduction, followed by supervised ANN classification of galaxy morphology. ...
...Experiment: This study determined how many Principal Components (PCs) are needed for effective classification compared to using all input features. A 7:3:1 network was trained on 600 galaxies from the D7 sample using Quasi-Newton and weight decay, and tested on 191 galaxies. RMS scatter was measured using all 7 diameters ($\sigma=2.2$), only the 1st PC ($\sigma=3.6$), and the first 3 PCs ($\sigma=2.2$).	...Experiment: PCA-compressed data (D7 sample: 7 metric diameters) was tested with a 7:3:1 network. Performance was evaluated using scatter (σ) when varying the number of Principal Components (PCs). Conclusion: Using 3 PCs recovered the same scatter ($\sigma=2.2$) as all 7 diameters, showing minor PCs are critical despite lower variance contributions. ...

Conclusion: Three PCs were necessary to match full-input performance, showing that variance alone is insufficient to determine optimal feature compression....	
... A key limitation is the reliance on supervised learning, which inherits human biases and does not explore fully unsupervised discovery. ... Future work should incorporate multi-wavelength data and dynamical properties to move toward a physically grounded classification system and develop unsupervised methods to identify novel features beyond human-defined categories.	...Limitations include unexplored classification approaches (e.g., modified linear networks) and unaddressed challenges like handling noisy data.

Table 7 Partial comparison between human-written and model-generated summaries.

	问题	人工摘要回答
Memory Level	<i>What classification method is proposed for galaxy morphological classification in the paper?</i>	Artificial Neural Networks (ANNs)
Comprehension Level	<i>What is the role of Principal Component Analysis (PCA) in the methodology?</i>	PCA is used to reduce the dimensionality of the input parameter space by identifying linear combinations of parameters with maximal variance.
Application Level	<i>What application does the proposed ANN method serve in astronomical research?</i>	The proposed ANN method serves the application of automating the classification of galaxy morphology, replicating human expert decisions.
Analysis Level	<i>What inference can be made about the number of Principal Components required for effective classification?</i>	Three Principal Components were necessary to match full-input performance, indicating that variance alone is insufficient.
Evaluation Level	<i>What limitation did the authors mention regarding their classification method?</i>	The authors mentioned a key limitation in the reliance on supervised learning, which inherits human biases.
Creation Level	<i>What innovative approaches could be developed to handle human biases in supervised learning?</i>	Research could focus on creating hybrid models that combine supervised and unsupervised techniques to mitigate biases.

Table 8 Example questions and answers for each Bloom cognitive level under the Cognitive Coverage (CC) evaluation.




Fig. 10 Evaluation results for the paper “*Neural Computation as a Tool for Galaxy Classification: Methods and Examples*”. (a) Scores of eight core semantic units for Factual Consistency (FC, scale 1–5); (b) Average scores of six cognitive levels for Cognitive Coverage (CC, scale 1–5); (c) Average vector similarity (0–1) of answers to six cognitive-level questions.

5 Conclusion and Discussion

在本研究中，我们提出了一种面向创新价值的摘要自动评估方法，将摘要质量划分为 **Factual Consistency（事实一致性, FC）** 与 **Cognitive Coverage（认知覆盖度, CC）** 两个互补维度。FC 用于评估摘要对论文关键科研事实的准确表达能力，CC 用于衡量摘要在不同认知层级上支持理解、分析与判断的能力，提供与传统文本相似度指标不同的评价视角。通过结合这两个维度，不仅能够刻画摘要的事实表达质量，还能衡量其在科研场景中支持高阶认知的能力。

为了验证方法有效性，我们构建了一个跨计算机与天文、教育、医疗三个交叉学科的数据集，包含 120 篇论文及 240 篇由双人独立标注的结构化参考摘要。在此基础上，我们系统比较了七种主流大语言模型在六种常见摘要生成策略下的表现。我们发现，当前大语言模型生成的摘要通常能够保持较高的事实一致性，但在认知覆盖方面仍存在明显不足，尤其容易忽略研究动机、方法局限性以及未来研究方向等高层认知信息。并且，直接提示（SimPrompt）与链式思维提示（Chain-of-Thought, CoT）之间的性能差异较小，CoT 并未在学术摘要生成任务中表现出稳定优势。这些结果表明，现有模型在提炼科研核心洞察方面仍存在显著提升空间。

尽管本文方法表现出良好的评估能力，但仍存在局限。本研究的数据集规模和学科覆盖仍然有限，仅包含三个交叉学科领域，可能影响指标的跨领域泛化能力。未来工作将考虑在更大规模、多领域的语料上进一步验证指标有效性，并尝试将 FC 与 CC 指标与摘要生成过程相结合，从而实现对学术摘要质量的持续优化与改进。

【1】 A scientific-article key-insight extraction system based on multi-actor of fine-tuned open-source large language models

【2】 Leveraging peer-review aspects for extractive and abstractive summarization of scientific articles

【3】 Large scale summarization using ensemble prompts and in context learning approaches

【4】 LexRank: Graph-based Lexical Centrality as Saliency in Text Summarization

【5】 TextRank: Bringing Order into Text

【6】 SummaRuNNer: A Recurrent Neural Network based Sequence Model for Extractive Summarization of Documents

【7】 Get To The Point: Summarization with Pointer-Generator Networks

- 【8】 BART: Denoising Sequence-to-Sequence Pre-training for Natural Language Generation, Translation, and Comprehension
- 【9】 A Systematic Survey of Text Summarization: From Statistical Methods to Large Language Models
- 【10】 Summit: Iterative Text Summarization via ChatGPT
- 【11】 Element-aware Summarization with Large Language Models: Expert-aligned Evaluation and Chain-of-Thought Method
- 【12】 Scisummnet: A large annotated corpus and content-impact models for scientific paper summarization with citation networks
- 【13】 Automatic summarization of scientific articles A survey
- 【14】 A summarization system for scientific documents
- 【15】 Citance-Contextualized Summarization of Scientific Papers
- 【16】 PEGASUS: Pre-training with Extracted Gap-sentences for Abstractive Summarization
- 【17】 G-Eval: NLG Evaluation Using GPT-4 with Better Human Alignment
- 【32】 Two-Stage Graph-Augmented Summarization of Scientific Documents
- 【33】 A survey of text summarization techniques
- 【34】 Citation-enhanced keyphrase extraction from research papers: A supervised approach
- 【35】 Scoring sentence singletons and pairs for abstractive summarization
- 【37】 CiteSum: Citation Text-guided Scientific Extreme Summarization and Domain Adaptation with Limited Supervision
- 【42】 LLMs meet Bloom's Taxonomy: A Cognitive View on Large Language Model Evaluations
- 【18】 Rouge: A package for automatic evaluation of summaries.
- 【19】 Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks
- 【20】 Measuring Sentences Similarity: A Survey
- 【21】 GPTScore: Evaluate as You Desire
- 【22】 Human-like Summarization Evaluation with ChatGPT
- 【23】 FACTSCORE: Fine-grained Atomic Evaluation of Factual Precision in Long Form Text Generation
- 【24】 New Paradigm for Evaluating Scholar Summaries: A Facet-aware Metric and A Meta-evaluation Benchmark
- 【25】 Asking and Answering Questions to Evaluate the Factual Consistency of Summaries
- 【27】 QAFactEval: Improved QA-Based Factual Consistency Evaluation for Summarization

- 【28】 Facet-Aware Evaluation for Extractive Summarization
- 【26】 Towards Question-Answering as an Automatic Metric for Evaluating the Content Quality of a Summary
- 【41】 QuestEval: Summarization asks for fact-based
- 【29】 Bringing Structure into Summaries: a Faceted Summarization Dataset for Long Scientific Documents
- 【30】 TLDR: Extreme Summarization of Scientific Documents
- 【31】 Overview and Results: CL-SciSumm Shared Task 2019
- 【38】 ScisummNet: A Large Annotated Corpus and Content-Impact Models for Scientific Paper Summarization with Citation Networks
- 【39】 A Discourse-Aware Attention Model for Abstractive Summarization of Long Documents
- 【40】 CS-PaperSum: A Large-Scale Dataset of AI-Generated Structured Summaries for Computer Science Papers
- 【43】 HERA: Improving Long Document Summarization using Large Language Models with Context Packaging and Reordering
- 【44】 Ask, Retrieve, Summarize: A Modular Pipeline for Scientific Literature Summarization
- 【45】 MinerU: An Open-Source Solution for Precise Document Content Extraction
- 【46】 Enhancing abstractive summarization of scientific papers using structure information
- 【47】 Multiple Abstraction Level Retrieve Augment Generation
- 【48】 CoTHSSum: Structured long-document summarization via chain-of-thought reasoning and hierarchical segmentation
- 【49】 Automatic summarization of scientific articles: A survey