

分 类 号： TP399
论文编号： 2023022438

密级：

贵 州 大 学
2026 届硕士研究生学位论文

基于大语言模型的天文数据分析任务
智能执行技术研究

学科专业： 电子信息
研究方向： 计算机技术
导 师： 田华
研 究 生： 谢家福

中国 ■ 贵州 ■ 贵阳

2026 年 06 月

硕士学位论文答辩委员会名单

基于大语言模型的天文数据分析任务 智能执行技术研究

答辩人：谢家福

答辩委员会委员：

贵州师范大学 教授：____张仁津____（主席）

贵州大学 副教授：____程欣宇____

贵州大学 副教授：____黄初华____

贵州大学 副教授：____蔡丽____

贵州大学 副教授：____杨赵琪璘____

答辩秘书：____王力鑫 中级____

答辩时间：2026 年 05 月 25 日

答辩地点：博学楼 610

摘要

天文数据分析在科学研究中至关重要，在以 WorldWide Telescope (WWT) 为代表的天文数据可视化平台中开展深度的分析任务时，研究者需要在可视化交互与底层脚本编写之间频繁切换，由此产生的认知负荷严重制约了数据分析效率。尽管基于大语言模型的工具调用与多智能体技术提供了自动化思路，但现有方法在天文领域面临工具调用能力有限与多智能体编排逻辑易错的挑战。为此，本文开展了基于大语言模型的天文数据分析任务智能执行技术研究，旨在推动天文数据分析向智能化和低门槛化方向发展，主要工作如下：

(1) 针对天文数据查询任务中，现有 RAG 的工具调用方法因在检索阶段难以解析隐式依赖而易出现中间工具漏检、导致工具调用链断裂的问题，本文提出一种基于动态 RAG 的天文数据查询工具调用方法。该方法通过设计“检索工具、生成工具调用链、生成假设工具描述并再次检索”的检索与生成的动态交替机制，有效补齐了具有隐式特征的关键工具，从而构建逻辑完整的工具调用链。为了评估该方法的有效性，本文构建了包含 93 个天文查询工具与 600 条真实场景天文数据查询任务的专用基准测试，实验验证了该方法的有效性。

(2) 针对复杂天文数据分析任务中，现有通用多智能体编排方法因缺乏领域逻辑感知而易陷入执行顺序混乱、关键处理环节缺失或数据流转断层等编排失效的问题，本文提出一种基于反向递归多智能体编排的天文数据分析任务执行方法。该方法首先通过中心调度器进行全局初步的智能体编排，然后以末端目标智能体为锚点，通过“工具选取、缺失数据识别、前置智能体分配”的递归闭环，自动推导并补全缺失的前置处理环节，生成逻辑严密的智能体协作链。为了评估该方法的有效性，本文构建了包含 141 个专业工具和 160 条多维度评测任务的基准测试，验证了该方法的有效性。

(3) 设计并实现了 WWT 智能交互系统。系统采用前后端分离的五层解耦架构，通过融合空间交互与感知、多智能体协同调度与决策过程可视化等功能，实现了天文数据分析任务的端到端输出，有效降低了专业天文数据的分析门槛。

关键词：大语言模型；检索增强生成；工具调用；多智能体

ABSTRACT

The analysis of astronomical data is indispensable to scientific research efforts. Nonetheless, when performing comprehensive analysis tasks on astronomical data visualization platforms represented by WorldWide Telescope (WWT), researchers have to frequently switch between visual interaction and underlying script coding. The cognitive load resulting from this severely constrains the efficiency of data analysis. Although tool calling and multi-agent technologies based on Large Language Models (LLMs) provide new ideas for automation, existing methods face challenges in the astronomical domain, such as limited tool invocation capabilities and error-prone agent collaboration logic. Therefore, this thesis investigates intelligent execution technologies for astronomical data analysis tasks based on LLMs, aiming to advance the field towards intelligence and a lower technical barrier. The main contributions are as follows:

(1) In astronomical data query tasks, existing RAG-based tool calling methods are prone to missing intermediate tools due to the difficulty in parsing implicit dependencies during the retrieval stage, which leads to broken tool calling chains. To address this, this thesis proposes a dynamic RAG-based tool calling method for astronomical data queries. By designing a dynamic alternation mechanism between retrieval and generation — specifically, “retrieving tools, generating tool calling chains, generating hypothetical tool descriptions, and re-retrieving” — this method effectively recovers critical tools with implicit characteristics, thereby constructing a logically complete tool calling chain. To evaluate its effectiveness, a dedicated benchmark containing 93 astronomical query tools and 600 real-world astronomical data query tasks was constructed, and experiments verified the effectiveness of the proposed method.

(2) In complex astronomical data analysis tasks, existing general multi-agent orchestration methods lack domain logic perception, making them prone to orchestration failures such as disordered execution sequences, missing critical

processing steps, or data flow disruptions. To tackle this, this thesis proposes an execution method for astronomical data analysis tasks based on backward regressive multi-agent orchestration. Firstly, a central scheduler performs a global initial agent orchestration. Then, using the terminal target agent as an anchor, it automatically deduces and completes the missing prerequisite processing steps through a regressive loop of “tool selection, missing data identification, and prerequisite agent assignment,” thereby generating a tightly logical agent collaboration chain. To evaluate this method, a benchmark containing 141 professional tools and 160 multi-dimensional evaluation tasks was constructed, verifying the effectiveness of the method.

(3) The design and implementation of the WWT intelligent interaction system are presented. The system adopts a five-layer decoupled architecture separating the front and back ends. By integrating functions such as spatial interaction and perception, multi-agent collaborative scheduling, and decision process visualization, it achieves end-to-end output of astronomical data analysis tasks, effectively lowering the threshold for professional astronomical data analysis.

Keywords: Large Language Model, Retrieval Augmented Generation, Tool Calling, Multi-agent

目录

摘 要	I
ABSTRACT	II
第 1 章 绪论	1
1.1 研究背景及意义	1
1.2 国内外研究现状	3
1.2.1 大语言模型的工具调用技术	3
1.2.2 大语言模型的多智能体技术	6
1.3 主要研究内容	8
1.4 论文组织结构	10
第 2 章 相关理论与技术	11
2.1 天文数据分析工具及可视化平台	11
2.1.1 天文数据分析工具	11
2.1.2 天文可视化平台	11
2.1.3 天文数据分析工具与 WWT 可视化平台使用方法	12
2.2 基于大语言模型的提示工程	15
2.3 基于大语言模型的工具调用技术	16
2.4 基于大语言模型的 RAG 技术	16
2.5 基于大语言模型的多智能体技术	17
2.6 本章小结	18
第 3 章 基于动态 RAG 的天文数据查询工具调用方法	19
3.1 基准测试构造	20
3.1.1 任务定义	20
3.1.2 工具收集	20
3.1.3 任务构造	21
3.1.4 任务划分	22
3.1.5 评估指标	24
3.2 方法设计	26
3.2.1 构建语义丰富的工具文档	26
3.2.2 基于大语言模型动态 RAG 的工具调用方法	27
3.2.3 任务执行	29
3.3 实验结果及分析	30
3.3.1 对比实验	30
3.3.2 消融实验	32
3.3.3 参数分析	34
3.3.4 案例分析	35
3.4 本章小结	38
第 4 章 基于反向递归多智能体编排的天文数据分析任务执行方法	39
4.1 基准测试构造	39

4.1.1 任务定义	40
4.1.2 工具收集	41
4.1.3 任务构造	42
4.1.4 任务划分	43
4.1.5 评估指标	46
4.2 方法设计	48
4.2.1 天文专业智能体设计	49
4.2.2 基于反向递归的智能体编排	51
4.2.3 任务执行	53
4.3 实验结果及分析	53
4.3.1 多智能体对比分析	53
4.3.2 参数分析	57
4.3.3 案例分析	58
4.4 本章小结	61
第 5 章 WWT 智能交互系统构建	62
5.1 设计目标	62
5.2 需求分析	62
5.2.1 系统功能需求分析	62
5.2.2 系统非功能分析	63
5.3 系统设计	64
5.3.1 系统总体设计	64
5.3.2 功能模块设计	65
5.4 系统功能实现与测试	66
5.4.1 环境配置信息	66
5.4.2 系统功能实现	66
5.4.3 系统功能测试	69
5.5 本章小结	71
第 6 章 总结与展望	72
6.1 总结	72
6.2 展望	73
致谢	74
参考文献	75
研究生期间参加的科研项目及取得的成果	79
图版	80
表版	81

第 1 章 绪论

1.1 研究背景及意义

天文数据分析是现代天文学研究的核心环节，旨在从海量、多源、异构的观测数据中挖掘揭示宇宙演化规律的关键信息。随着地面与空间观测设备的快速迭代，天文学已全面迈入大数据时代，数据分析在科学研究与普及中的价值日益凸显^{[1][2]}。在此过程中，天文数据可视化是开展直观化、交互式深度分析的重要先导与辅助手段。以 WorldWide Telescope (WWT) 为例，该平台将浩瀚的观测数据整合于统一的三维空间中，不仅支持天文成像数据等特定类型分析结果的直观呈现，也可以让用户通过缩放或者平移等操作来关注他们感兴趣的区域进行针对性探索，极大辅助了研究者洞察宇宙奥秘^[3-5]。

然而，在 WWT 可视化平台中开展深度的天文数据分析任务仍面临巨大挑战。如图 1-1 所示，在执行“使用目标检测算法检测 WWT 当前图中的星体”这一典型任务时，传统方式高度依赖人工干预：用户需手动编写代码，依次调用多个专业底层工具库（如 AstroQuery、PhotUtils 等^[5-9]）完成数据获取与处理分析，最后再将结果手动上传至可视化环境。这种流程碎片化、技术门槛高的任务执行方式，效率低下，增加了研究者深度天文探索的难度。



图 1-1 传统手动方式完成基于 WWT 的天文数据分析任务

近年来，以 ChatGPT^[10]、DeepSeek^[11]为代表的大语言模型取得了突破性进展，其中工具调用^[12-15]能力的涌现为打破上述技术壁垒带来了契机。大语言模型能够精准解析用户的自然语言意图，并自主调度外部专业工具（API）执行复杂任务，从而实现自然语言理解与专业工具操作的深度融合，打通从指令理解到工具执行的完整闭环。借助这一机制，非专业用户无需编写底层代码，即

可通过自然语言驱动复杂的天文分析流程，显著降低深度探索的技术门槛。

尽管如此，真实的天文数据分析通常涉及多步骤耦合的复杂工程。若由单一大语言模型独立完成从数据获取、处理到可视化的全流程，模型将面临极高的认知负荷，容易顾此失彼，出现执行偏差。为此，基于大语言模型的多智能体技术^[16-18]提供了一种更优的架构。该技术秉持“群体协作优于个体应对”的理念，通过统筹分工，将复杂的任务拆解为子任务，并交由具备不同专业背景的智能体通过调用工具协同完成。

这种多智能体分工架构的有效性，依赖微观执行与宏观调度两个层面的能力：一是各智能体在各自领域的专业工具调用能力；二是决策层智能体对全局任务的理解与编排能力^{[22][23]}。二者相辅相成，构成了驱动多智能体系统可靠运行的基础。然而将多智能体技术落地于天文数据分析领域将面临两大关键挑战：

在微观执行层面，不同智能体面临的挑战差异显著。在本研究的天文分析场景中，智能体主要涵盖数据查询、图像分析、事件分析及可视化智能体。其中，对于后三个智能体而言，其所需工具数量较少、功能明确，大模型通过上下文学习即可有效掌握。然而，作为系统数据基石的天文数据查询智能体面临的情况更为复杂：一方面，天文数据源广泛、导致其工具库规模庞大；另一方面，天文数据查询工具间存在严苛的逻辑前置依赖（例如，坐标获取是调用成像工具的必要前提）。若将全部工具直接输入模型，将显著增加计算负担并降低推理性能。因此，一种可行的解决方案是引入 RAG^[19]（Retrieval-Augmented Generation，检索增强生成）机制作为前置过滤步骤，即先从庞大的工具库中检索出相关工具，再交由大模型进行调用。然而，现有的基于 RAG 的工具调用方法（如 Craft^[20]、Re-invoke^[21]和 Toolshed^[22]）在此特定场景下存在局限性，在检索阶段难以解析隐式依赖而易出现中间工具漏检，这种检索偏差会导致大模型在后续环节出现无工具可调或调用错误的情况，进而造成数据获取环节失败，阻塞整个分析流程。因此，本文的第一个研究重点是针对数据查询任务改进基于 RAG 的工具调用机制，以实现复杂工具库下的高精度匹配与调用。

在宏观调度层面，即便数据查询智能体具备了精准取数的能力，如何将其与其他分析及可视化智能体高效协作，仍是另一大难点。天文数据分析具有严格的前后置依赖与特定的据流转逻辑（如必须先获取数据才能进行图像分析）。

如何从候选智能体集合中精准选择智能体并合理分配子任务，即“智能体编排”，是协同的核心。然而，现有的 AgentVerse、AutoGen 等通用多智能体^[23-26]技术缺乏对领域特有逻辑的感知，在编排时易出现逻辑错误，影响整体分析流程的可靠性。因此，本文的第二个研究重点是设计一种高效的编排机制，使其能够深度理解全局任务的领域逻辑，实现智能体的精准匹配与子任务的合理分配，进而保障多智能体间数据流转与协作的精准控制。

面对上述挑战，本文开展基于大语言模型的天文数据分析任务智能执行技术研究。本文将优化重点落在两个层面：一是优化工具检索增强的工具调用机制，以提升数据获取智能体在面对海量复杂天文工具时的精准调用能力；二是优化多个智能体之间的协同编排机制，使其能够精准感知天文数据的流转逻辑，确保整个天文专家智能体团队高效运转。二者相辅相成，共同推动天文数据分析向智能化、自动化和低门槛化方向发展。

1.2 国内外研究现状

本文旨在利用大语言模型相关技术，实现自然语言驱动的天文数据分析任务的端到端智能执行。因此本文将总结国内外关于大语言模型工具调用技术以及多智能体协同技术的研究成果并对其进行分析。

1.2.1 大语言模型的工具调用技术

近年来，大语言模型在自然语言处理领域取得显著进步，在文本理解与逻辑推理方面表现出色，能够完成意图解析与内容生成等工作。但是由于其基于固定语料进行训练，且输出形式仅限于文本，无法很好地解决实时信息查询、准确的数学计算以及与外部软件交互等问题。因此，如何将大语言模型与外部工具结合，通过工具调用的方法来克服现有局限，成为了当前的研究热点。

大语言模型的工具调用，是指将大模型本身具备的强大通用智能与对外界的访问能力相结合的一种方式。在此过程中，需要将工具接口信息（如功能说明、参数要求以及期望的结果形式等）、用户提问以及提示信息构建为一个上下文环境。随后，大语言模型基于该上下文自主决策使用哪些工具，并为这些工具配置相应的参数值，从而输出对应的工具调用指令。




图 1-2 工具调用相关研究^[13]

当前，对于工具调用的研究（如图 1-2 所示）越来越深入并且呈现多元化趋势，在一些常规场景的基础上，这项技术已经拓展到医学、生物学以及农业等领域^[27-30]并且具有广泛的应用潜力。工具调用过程分为工具选择到调用，现有的相关工作主要有两种方式：一是基于大语言模型的工具调用，二是基于 RAG 的工具调用。

（1）基于大语言模型的工具调用

该方法主要利用大语言模型的内部推理来进行工具选择与调用。根据是否经过微调，具体可分为两种方式：在未经微调的情况下，通常将用户指令、任务相关信息及可用工具的介绍一并作为输入语境提供给模型，由模型自主思考得出最优解决方案；而在经过微调后，模型通过训练已内化工具的使用逻辑，能够理解用户意图并给出正确答案，无需进一步指导即可做出决定。

① 不微调大语言模型

该方案基于大语言模型的上下文理解能力，在不需要再做额外的训练的情况下即可达到很好的效果。其主要思路是将用户问题、工具描述及参数等输入大模型，通过提示词策略^{[31][32]}引导模型自主选择并调用相应工具。

为克服单一提示词策略下推理能力的不足，研究者提出了多种增强方案：一是思维链^[33](Chain of Thought, CoT)方法，即通过添加“让我们一步一步来思考”等提示词，引导模型进行更合理的推理。在此基础上，ReAct^[34]方法将决策推理与执行相结合，并利用外部工具的即时反馈来更新自身思路，实现两者的良好配合。

针对误差传播问题，DFSDT 方法^[35]通过引入深度优先搜索改进决策树，从

而提高准确率；ChatCoT^[36]则在多轮对话中引入工具辅助，在促进对话式推理的同时增强了获取外部知识的能力；ToolNet^[37]采用有向图表示工具集，引导模型依据规则逐层挑选合适的工具，直至完成目标任务。

总的来说，尽管不微调大语言模型凭借零样本学习能力和高度灵活性在某些场景下表现优异，但受限于上下文窗口长度及处理长文本时的注意力分散，当面临大规模工具库输入时，仍极易出现推理能力下降与选择失效的问题。

② 微调大语言模型

通过对大语言模型实施监督微调，可显著增强其工具选择与调用能力。这类方法通常通过构建包含用户指令与对应工具调用序列的样本对来训练大语言模型。代表性工作包括：ToolFormer^[38]利用自监督机制合成工具调用样本进行训练；Gorilla^[39]则构建了涵盖数千个工具的数据集，并通过指令微调赋予模型跨平台工具调用能力。此外，GPT4Tools^[40]与 ToolAlpaca^[41]等研究也在此方向上提出了新思路。

尽管微调方法在常见工具场景下表现优异，但其高昂的训练成本以及对长尾、冷门天文工具泛化能力的不足，限制了其在专业领域的广泛应用。

（2）基于 RAG 的工具调用

当可用工具库规模庞大时，将所有工具描述直接输入给大语言模型往往不切实际。因此，一种更高效的方案是：先借助检索器，根据用户问题检索出 TopN 个最相关的工具；随后，再将这 TopN 个工具的详细描述交给大语言模型进行调用。可以说，构建先检索、后调用的高效机制，是充分发挥增强型大语言模型潜力的关键所在。

根据检索原理的不同，现有的工具检索器主要分两类：第一类是依赖词项的稀疏检索：利用 TF-IDF^[43]或 BM25^[44]等算法，通过统计关键词匹配度将用户查询与工具描述对齐；第二类则是基于语义的稠密检索：利用神经网络学习查询与工具描述之间的深层语义关系，并通过余弦相似度等方法计算匹配度^{[45][47]}。

在此基础上，根据是否对检索器进行微调训练，相关研究又可进一步划分为以下两种路径：

① 微调检索器

此类方法依赖标注数据训练专用的检索模型。例如，ToolLLM^[35]、

Confucius^[48]和 TPTU-v2^{[49][48]}均训练了 Sentence-BERT^[45]模型作为工具检索器，实现了高效的相关工具召回。然而，这类方法的泛化能力较弱：每当工具库新增一个工具时，往往需要重新微调检索器以适应变化，维护成本较高。

② 不微调检索器

所谓不微调检索器，是指在检索过程中直接利用预训练检索模型的固有语义理解能力，而不针对特定工具集对检索模型参数进行额外训练或更新。此类方法旨在避免对标注数据的依赖，主要利用大语言模型的提示工程与推理优化策略，对查询或文档进行语义增强以提升检索效果。例如，CRAFT^[20]采用多种视角匹配方式，在推理阶段基于用户问题推测出可能的工具名称及对应描述，并将其加入到原始查询中进行检索；Re-Invoke^[21]和 Toolshed^[22]则是在离线阶段通过生成假设问题的方式，来扩充工具说明书的内容。而在在线推理阶段，Re-Invoke 主要根据用户意图生成若干个不同的查询语句，Toolshed 则采用更为复杂的查询重构方法，包括初始查询重述、任务分解以及子任务变体生成等操作，以此为基础产生更多查询来达成最终目的。

尽管免微调检索器摆脱了数据标注的限制，但其局限于浅层字面匹配，缺乏对隐含意图与复杂层级依赖逻辑的解析能力。这种粗粒度的语义理解容易导致工具召回不全。

1.2.2 大语言模型的多智能体技术

前述研究主要聚焦于单一大语言模型智能体的工具调用机制，致力于通过增强 LLMs 的感知、推理与行动能力，使其在特定任务中实现自主决策与工具调用。然而，面对高度复杂、跨领域或多阶段的现实任务，单一智能体往往受限于自身的认知带宽与专业深度，不仅容易在长链条推理中出现误差累积，且难以兼顾全局视野与局部细节，难以独立完成多步骤、端到端的高质量解决方案构建^[16-18]。

当前的研究趋势表明，多智能体技术正成为推动大语言模型发展的重要力量。这一发展基于“群体智能”的理念，并受到“心智社会”^[50]与“心智理论”^[51]的启发。多智能体系统的工作方式类似于人类社会的专业化分工合作：它由具有不同职责与目标的个体智能体构成分布式网络，以协作完成复杂任务。在此过程中，各智能体不仅能共享信息与经验，还能通过交流与讨论克服自身的

认知局限，从而减少单一视角带来的偏见。这使得整个系统在处理跨模态感知、多层次推理乃至跨领域融合等问题时具有更优的效果，同时也提升了系统的鲁棒性、灵活性以及对外界环境的适应能力。

当前，基于大语言模型的多智能体系统主要演化出两类技术范式：固定流水线式多智能体编排与动态自适应多智能体编排^{[17][23]}。

（1）固定流水线式多智能体编排方法

该方法通过预定义智能体的执行顺序，构建结构严谨的任务处理流水线，将复杂目标分解为有序阶段并由专用智能体依次承接。以软件开发领域为例，ChatDev^[52]与 MetaGPT^[53]将流程细化为设计、编码、测试、文档生成等环节，确保各阶段严格按序执行。该方法在特定领域展现出良好的通用性与高效性，如医疗健康领域的药物研发框架 Prompt-to-Pill^[54]、金融交易决策框架 TradingAgents^[55]与 FinCon^[56]，以及化学领域的分子发现框架 MT-MOL^[57]等。

然而，固定流水线方法受限于人工预设的执行链路，缺乏动态适应性。该方法在单一任务下表现优异，但面对异构任务集合时，往往暴露出协作拓扑僵化的问题。以天文场景为例，其任务呈现显著多样性（涵盖图像分析、事件分析、数据获取等），不同任务解构后所需的智能体个数及交互顺序存在极大差异。固化的流水线编排难以实现任务需求与智能体组合间的多对多动态映射，导致预设流程无法有效兼容个性化求解路径。

（2）动态自适应多智能体编排方法

为突破固定流水线的局限，研究者提出了动态自适应编排方法，旨在根据任务特性自动选取专业智能体，并动态分配子任务以实现高效协同。

近年来，多种代表性方法推动了该领域的演进。AutoAgents^[24]采用初步编排和审查的双阶段策略，利用审查机制迭代完善协作流程；AgentVerse^[23]则通过专家招募机制，先选取智能体再进行迭代优化编排。与此同时，基于对话驱动的动态交互模式也取得了显著进展。AutoGen^[26]结合中央调度与对话机制，构建了指令下达、智能体选取、响应反馈的迭代循环；OWL^[25]同样依托此类对话模式，通过指令者与执行者的多轮交互直至任务完成。

尽管动态自适应编排提升了灵活性，但上述方法在应用于高度专业的天文科学团队时仍面临显著挑战。由于天文领域智能体所掌握的工具具有极强的专

业性与异构性，现有编排方法缺乏对天文科学团队协作模式的细粒度认知，难以精准匹配专业工具与任务需求，从而导致编排逻辑错误或执行效率低下。

1.3 主要研究内容

图 1-3 展示了本文的研究内容。天文数据分析过程高度依赖对专业工具的熟练运用以及天文可视化平台的使用，构成了极高的专业门槛。为了降低这一门槛，使得公众能够便捷地在天文可视化平台中开展天文数据分析，本文开展基于大语言模型的天文数据分析任务智能执行技术研究，旨在推动天文数据分析向智能化、自动化与低门槛化方向发展。本文主要研究内容如下：




图 1-3 研究内容概览图

(1) 基于动态 RAG 的天文数据查询工具调用方法

本研究点聚焦于天文数据查询任务，针对现有基于 RAG 的工具调用方法在复杂查询场景下易因在检索阶段难以解析隐式依赖而易出现中间工具漏检而导致工具链断裂问题，于是提出一种基于动态 RAG 的天文数据查询工具调用方法。该方法通过设计“问题重写、初步检索、工具链补全、基于假设性工具的再次检索”的检索与生成动态交替，有效挖掘并补齐具有隐式特征的关键工具，从而构建逻辑完整的工具调用链。此外，本研究构建了包含 93 个天文查询工具与 600 条真实场景查询任务的专用基准测试集，从数据类型与工具调用复杂度等多维度客观验证了该方法的有效性。

(2) 基于反向递归多智能体编排的天文数据分析任务执行方法

本研究点面向涉及多步骤、多工具协同的复杂天文数据分析任务，针对现有通用多智能体编排方法因缺乏对天文领域数据流转逻辑的感知而易陷入执行顺序混乱、关键处理环节缺失或数据流转断层等编排失效的问题，本文提出了一种基于反向递归多智能体编排的天文数据分析任务执行方法。该方法首先离线构建涵盖“数据查询、图像分析、事件分析、WWT 可视化”四类专业角色的天文专家智能体团队，在在线推理阶段，在中心调度智能体在初次智能体编排后，以末端目标智能体为锚点，通过“工具选取、缺失数据识别、前置智能体分配”的递归闭环，自动推导并补全因意图模糊或隐性前提缺失导致的前置处理环节，生成逻辑严密的智能体协作链。最后，本研究构建了包含 141 个专业工具和 160 条多维度评测任务的基准测试，客观验证了该方法在异构复杂任务中的鲁棒性与优越性。

(3) WWT 智能交互系统构建

为了将前述的动态检索与多智能体技术真正应用于天文数据分析，并解决现有 WWT 平台对非专业用户操作门槛较高的问题，本研究构建了 WWT 智能交互系统。该系统以 WWT 三维可视化引擎为前端，采用 Vue 3 与 Django 架构，在后端集成了天文数据获取、图像处理和视图控制等专业工具接口，并将两项核心算法进行了工程化整合。系统以自然语言为驱动，实现了从用户输入、任务智能拆解分发、专业工具自动调度到视图渲染反馈的全流程闭环。在此基础上，系统支持空间交互与感知、多智能体协同分析以及决策过程可视化等功能，最终为公众提供了一个零代码的天文数据深度探索环境。

1.4 论文组织结构

第一章 绪论。本章介绍了天文数据分析任务的智能执行技术面临的挑战为背景，大语言模型技术带来的机遇，引出文本的研究背景与意义。然后分析了现有的 RAG 工具调用以及多智能体编排协作面临的挑战。接着介绍了大语言模型的工具调用、大语言模型多智能体的研究现状。最后，介绍本文的主要研究内容和组织结构。

第二章 相关理论与技术。本章主要介绍了天文数据分析工具和可视化平台及使用方法、大语言模型提示词工程、工具调用技术、大语言模型 RAG、大语言模型多智能体技术的相关理论与技术。

第三章 基于动态 RAG 的天文数据查询工具调用方法。本章聚焦于天文数据查询任务，首先构造涵盖多类天文数据查询场景的基准测试。然后提出一种基于动态 RAG 的天文数据查询工具调用方法，提升大语言模型在复杂天文数据查询中的准确性与鲁棒性。

第四章 基于反向递归多智能体编排的天文数据分析任务执行方法。本章面向更复杂的天文数据分析任务，首先构建了涵盖多场景的天文数据分析基准测试。然后提出一种基于反向递归优化的智能体编排方法，通过分工协作与动态调度，提升天文分析任务在智能执行层面的效率与可靠性。

第五章 WWT 智能交互系统构建。本章将前文提出的理论与方法进行工程化落地，详细阐述了系统的总体架构设计、核心功能模块的实现以及系统测试。

第六章 总结与展望。对本文的研究工作进行了回顾与总结，分析了本研究存在的缺点，并提出了未来可行的解决方案。

第 2 章 相关理论与技术

本章主要介绍了基于大语言模型的天文数据分析任务智能执行技术的相关技术理论。本章将介绍天文数据分析及可视化工具（第 2.1 节）、提示词工程（第 2.2 节）、基于大语言模型的工具调用（第 2.3 节）、基于大语言模型的 RAG 技术（第 2.4 节）以及基于大语言模型的多智能体技术（第 2.5 节）。

2.1 天文数据分析工具及可视化平台

2.1.1 天文数据分析工具

为支撑大语言模型在复杂天文分析任务中的落地，本研究所构建的系统主要集成了以下工具：

数据获取工具：AstroQuery^[6]。作为统一查询接口集成 SIMBAD^[58]、VizieR^[59]及 NASA^[60]等数据库，该工具能够检索恒星星表、FITS^{[61][62]}图像、光谱、光变曲线等多维异构数据。该库封装上百个底层接口，各接口需配置坐标系、搜索半径等特定参数。同时，接口间存在严苛的逻辑前置依赖：获取 FITS 图像必须先经星表接口提取目标坐标，单次取数往往依赖多步串行调用。

图像处理分析与测光工具：PhotUtils^[8]。Astropy 核心组件，专精原始 FITS 图像定量化处理，负责星体检测、孔径测光、背景扣除与形态参数计算。调用该库需明确 FITS 文件路径及背景估计参数等，且对数据获取环节具强前置依赖，核心输入来自 AstroQuery 下载的文件等数据，取数失败将直接阻塞后续分析。

天文事件预测分析工具：SkyField^[7]。封装底层天体力学算法，通过解析高精度星历表求解天体视位置并补偿光行时等效应，用于掩星、日月食等天象预测。其参数需严格指定时间系统与空间坐标，计算起点同样依赖前置工具解析的目标名称或精确坐标。

2.1.2 天文可视化平台

天文数据可视化旨在将抽象的海量观测数据转化为直观的视觉信息，是辅助深度分析与降低探索门槛的关键环节。当前主流的天文可视化平台各有侧重：例如 Stellarium-Web^[63] 侧重于基于天体力学模型的高保真动态星空模拟；

ESASky^[64]则专注于多波段真实观测数据的无缝集成与叠加展示。

与上述平台不同，本研究选择 WorldWide Telescope (WWT) 作为系统的可视化终端，主要基于其独特的技术架构：WWT 能够将高保真天文事件模拟与海量真实影像（如 SDSS 巡天数据）融合于统一的三维天球映射之中。这是 WWT 区别于 Stellarium-Web 和 ESASky 的核心特征。同时，WWT 提供了以用户交互为中心的前端页面，用户可直接在视图中执行拖拽、缩放等直观操作，基于当前视图内容进行天文分析。例如，将十字光标定位至某颗恒星，系统即时显示其赤经、赤纬坐标；随后可编写代码调用外部工具（如 AstroQuery）查询该天区的星表或成像数据，使用 PhotUtils 等库完成测光、源提取等分析任务。分析结果亦可动态叠加回 WWT 视图，形成交互定位、数据获取、图像分析、结果回标的闭环。

此外，WWT 提供了 WWT Web Control APIs^[65]，支持参数化指令驱动前端。传入赤经赤纬可精准锁定天球目标，配置时间参数可回放天象演化。该机制将坐标与时间等参数直接映射为视图操作，使代码深度驱动可视化，打通了数据与视图的交互闭环。

2.1.3 天文数据分析工具与 WWT 可视化平台使用方法

结合对分析工具与 WWT 平台技术特点的理解，本节重点介绍二者在实际使用中的常规合作方式，并对具体操作步骤展开分析说明。此举旨在揭示“人机协同”过程中存在的低效与流程衔接不良问题，同时通过理清天文数据从获取、处理到可视化的完整链路，为后文收集基准测试数据提供参考依据。为实现上述目的，本节将传统的操作过程分解为五个部分进行论述。

(1) 天文数据获取与查询




图 2-1 基于 WWT 的天文数据获取与查询

如图 2-1 所示，用户可以在 WWT 中自由进行视角变换，当十字光标定位至某颗恒星时，系统会显示该天体准确的赤经与赤纬（即天球坐标系下的经纬度）。基于这两个关键参数，可通过 AstroQuery 获取目标天体及其周边的详细信息，例如星表条目、特定格式的天文图像（如 FITS 格式）以及多维光谱数据等。上述获取的数据可广泛应用于后续的天文学研究工作，例如借助 PhotUtils 工具包，研究人员能够对天文图像执行测光、去背景及目标检测等操作，进而为深入认知宇宙、开展进一步的科学研究提供有力支撑。

（2）可视化标注与结构构建



图 2-2 基于 WWT 的可视化标注与结构构建

WWT 支持对天区进行可视化标注，如图 2-2 所示，主要分为画圈标记恒星与连线构建星群两种方式。这两项功能具体表现为：一是以画圈方式标示单颗恒星的位置；二是以连线方式关联多颗星星或星座。例如在上图中，用户可在特定区域内使用 AstroQuery 查询已知天体信息，或者使用 PhotUtils 用检测算法检测该区域中所有可能存在的星体，然后可在 WWT 标注检测到的星体；而在下图中，则是利用 AstroQuery 查找到北斗七星的位置，在 WWT 上进行精确标注并连线，从而直观呈现它们之间的相对位置关系。此类标注既适用于科普教学，也可服务于科研中的目标界定、数据对比及结果可视化。

（3）精准定位与快速跳转



图 2-3 基于 WWT 的精准定位与快速跳转

用户若想快速跳转至某一天体或星群（如“仙女座星系”或“七姊妹星团”），如图 2-3 所示，可通过 AstroQuery 查询其准确的赤经与赤纬坐标，并将其输入至 WWT 中完成坐标定位。该方法为提高数据处理效率的重要手段，能够在海量星域信息中精准定位目标星体或重点观测区域，有助于研究人员迅速锁定罕见天体与主要观测目标，从而有效节省时间成本。

（4）天文事件模拟与复现




图 2-4 基于 WWT 的天文事件模拟与复现

如图 2-4 所示，WWT 不仅能重现当前天象，还可重现历史或未来特定时刻发生的特殊天文现象，如金星凌日、日全食等。借助 SkyField，用户能够准确

获取这些现象的发生时间及各天体的空间位置，进而在 WWT 中设定相应参数即可进行场景回放。图中上侧展示了地面视角下的金星凌日景象，下侧则呈现了太阳系宏观视角下的该现象，这有助于人们更深入地理解此类天文现象背后的科学原理。

(5) FITS 图像渲染与闭环处理




图 2-5 基于 WWT 的 FITS 图像渲染与闭环处理

如图 2-5 所示，用户可在 WWT 中上传并展示自定义的 FITS 格式天文图像数据。在获取当前视场对应的原始 FITS 文件后，可借助 PhotUtils 工具包进行处理分析，例如扣除背景噪声、目标检测等；处理完成后的优化图像可重新导入 WWT，实现更清晰、科学准确的可视化呈现。

2.2 基于大语言模型的提示工程

提示词工程是大语言模型应用的一项关键技术，并已取得显著成效。它致力于对输入内容进行优化，通过补充背景知识以及明确对目标结果的要求，使模型输出更加相关、合理且准确的回答。一般情况下，一个完整的提示词包括三条内容：核心指令、辅助性语境以及输出形式的要求。按照不同的任务难度，目前主要有如下几种方式：零样本提示^[66]，即不需要额外的信息就可以解决问题；少样本提示^[67]，用少量的例子让模型获得某种格式或者领域的规则；思维链提示^[68]，通过逐步展示思考的过程提高数学计算、常识判断等类型的任务的效果；以及思维树提示^[69]，用多个分支来表示复杂的决策过程，在需要深入分析或者有创造性想法的情况下有较好的表现。这些方法都有各自的优点，在实际使用时要根据具体情况选取或者结合起来使用。

在本文构建的多智能体系统中，提示词工程发挥着核心作用。它能够使决策层智能体准确理解天文数据的领域逻辑从而进行宏观调度，还能指导数据查

询、可视化等智能体调用天文工具。

2.3 基于大语言模型的工具调用技术

工具调用^[12-15]（Tool Calling）是大语言模型突破知识边界、连接现实世界的关键桥梁，它允许 AI 通过分析用户需求，自主决策调用外部 API，并以结构化 JSON 格式输出包含函数名与精确参数的调用指令；应用程序接收到该指令后执行实际操作（如查询实时天气、发送邮件或修改订单状态），再将执行结果反馈给模型，最终由 AI 整合工具返回的数据生成连贯、准确的自然语言回复，如图 2-6 所示。这一机制不仅赋予大模型获取实时信息的能力，更使其从被动对话系统转变为主动完成任务的智能代理，成为构建复杂 AI 应用的核心技术底座。




图 2-6 工具调用示意图

本文引入该技术主要是为了打破传统天文数据分析中高度依赖人工编写代码调用底层库的技术壁垒。通过工具调用机制，系统能够将大语言模型的自然语言理解能力与专业天文接口的执行能力深度融合，使非专业用户仅需通过自然语言指令即可驱动复杂的数据获取与处理流程。特别是在本文构建的多智能体架构中，该技术是实现天文数据查询等智能体在微观层面精准操控海量、复杂天文工具的核心依托，从而为整个数据分析流程的智能化与低门槛化奠定执行基础。

2.4 基于大语言模型的 RAG 技术

检索增强生成（RAG）技术^[19]是缓解大语言模型知识幻觉与时效滞后问题的核心手段。其工作流程包含检索、增强与生成三个阶段：系统首先根据用户查询从外部知识库中召回相关信息，随后将其与原始提问融合构建提示词，最

终由大模型基于增强上下文生成准确结果，如图 2-7 所示。




图 2-7 RAG 示意图

随着技术演进，RAG 已被广泛应用于工具调用领域并演化为工具检索机制，即预先将工具的功能描述转化为向量索引，在处理复杂任务时优先召回语义相关的 Top-K 候选工具，再交由大模型进行后续的选择与参数填充，从而有效应对海量工具集带来的推理挑战。

本文引入 RAG 技术，主要在于天文数据查询智能体所需对接的工具库规模庞大且接口参数复杂，若将全量工具直接输入大模型将导致严重的计算负担与性能衰减。通过 RAG 机制进行前置的工具检索过滤，能够显著压缩模型每次推理时的工具候选空间，在保证功能覆盖的前提下有效降低底层调用成本。

2.5 基于大语言模型的多智能体技术

基于大语言模型的多智能体技术^[16-18]旨在通过角色分化构建具备集体智能的协作网络，以克服单一模型在处理复杂任务时的局限性。该技术将大模型专门化为功能各异的角色，利用其自然语言理解与知识储备能力，实现个体智能向集体合力的转化。在系统架构上，其交互形态主要涵盖合作、竞争、协商与层次四类，以应对不同场景的协同需求。同时，多智能体编排技术作为核心支撑，主要负责全局行为的有序组织，具体可分为依赖预定义规则的静态编排，以及通过管理智能体实时调整协作路径、在复杂环境中更具鲁棒性的动态编排。

本文引入该技术，是因为真实的天文数据分析涉及多步骤耦合的复杂工程，单一模型易因认知负荷过高而出现执行偏差。通过构建多智能体架构，能够将全局任务拆解并交由具备不同专业背景的智能体协同处理；以天文场景为例，其任务呈现显著多样性（涵盖图像分析、事件分析、数据获取等），不同任务解构后所需的智能体个数及交互顺序存在极大差异。本文选用动态编排策略，

以精准感知领域特有逻辑，实现多智能体间协作路径的灵活调度与全局任务的可靠运转。

2.6 本章小结

本章梳理了本研究构建智能化天文数据分析系统所依赖的理论与核心技术。先介绍了天文工具（AstroQuery、PhotUtils、SkyField）及 WWT 可视化平台，随后阐述了大语言模型四项关键技术的作用：提示词工程引导模型理解天文分析逻辑；工具调用将自然语言转化为工具操控，打破人工编程壁垒；RAG 通过前置检索解决海量工具的匹配负担；多智能体技术采用动态编排，拆解复杂任务并协同处理。这些技术共同构成了系统实现自动化、低门槛天文分析的技术底座。

第 3 章 基于动态 RAG 的天文数据查询工具调用方法

当前，天文数据查询工具种类繁多且专业化程度高，现有基于 RAG 的工具调用方法在应对此类复杂场景时面临显著挑战。主流方法如 CRAFT^[20]、Re-*invoke*^[21]和 Toolshed^[22]等，主要致力于通过大语言模型提示工程来优化工具文档与用户查询的语义，以提升检索匹配精度。具体而言，这些方法遵循一种单向流程：在离线阶段增强工具文档，在推理阶段重写或扩展用户原始问题，随后执行检索并固定候选工具集，最终由大模型基于该固定集合生成调用序列。

然而，复杂开放的天文查询任务往往需要多个具有严格输入输出约束的工具协同工作。其核心痛点在于，工具链中必需的中间工具在功能描述上往往具有隐式特征。传统的查询重写技术难以捕捉这种深层意图，导致检索环节容易遗漏这些中间工具。这种漏检会直接造成候选工具集不完整，最终使大模型只能基于残缺的工具集合生成断裂的工具调用链。

针对上述因中间工具漏检导致的工具链断裂问题，本文提出了一种基于大语言模型的动态 RAG 天文数据查询工具调用方法。该方法打破了传统的局限，实现了双重动态性：一是流程机制的动态，从“单向检索生成”转变为“先检索、后生成、再由生成到检索”的动态交替，生成阶段不再是检索的终点，而是触发新一轮检索的反馈信号；二是检索到的工具集的动态，从固定不变转变为逐步扩展。具体而言，首先，基于初步检索到的候选工具集，大模型生成一条可能不完整的初步调用链；随后，针对链路中的缺失环节，利用大模型生成假设性工具的描述，并以此为依据进行再次检索工具，通过这种机制，精准召回那些原本被遗漏的真实中间工具，使候选工具集逐步扩展至完整状态；最后，基于更新后的完整工具集，构建逻辑严密、连贯的工具调用链并执行。

为全面评估所提方法的有效性，本文构建了一个涵盖 93 个天文数据查询工具与 600 条真实场景查询的评测基准数据集。本章结构安排如下：第 3.1 节详细阐述该评测基准的构建过程；第 3.2 节系统阐述方法，重点介绍所提出的基于动态 RAG 的天文数据查询工具调用方法设计策略；第 3.3 节通过实验验证该方法的实际性能；第 3.4 节对本章工作进行总结。

3.1 基准测试构造

为验证本文提出的方法的有效性，并为相关研究提供可复现的评测基准，本章设计了一套面向天文数据查询的工具调用基准测试，其核心工作在于构建一个专用的评测数据集。该数据集旨在模拟真实科研场景下的多源异构数据查询需求，每条数据样本均由“用户自然语言查询语句-正确的工具调用序列”构成。围绕该基准测试，本节将依次阐述任务定义、工具收集、任务构造、任务划分、最后定义相应的评估指标。

3.1.1 任务定义

天文数据智能查询任务旨在弥合用户自然语言意图与底层数据服务之间的语义鸿沟。为建立可复现的评测基准，本任务在数据结构层面严格形式化定义为 (q, T_c) 二元组，分别对应评测样本的输入与期望输出：

(1) 任务输入 (q)

q 代表用户的真实自然语言查询需求。

(2) 任务输出 (T_c)

T_c 代表满足查询意图的正确可执行指令序列。作为二元组的逻辑核心， T_c 并非简单的工具名称列表，而是要求模型同时实现“工具的准确选取”与“完整的参数配置”。其具体结构定义如下：

$$T_c = \{(t_1, p_1), (t_2, p_2), \dots, (t_n, p_n)\} \quad (3-1)$$

其中， t_k 表示第 k 步选取的具体工具， $p_k = \{\text{param_name: param_value}\}$ 表示为该工具配置的具名参数字典。

综上所述，每一条数据样本均遵循 (q, T_c) 的统一格式， q 对应用户意图， T_c 对应包含具体工具选取与参数配置的执行逻辑。

3.1.2 工具收集

工具库是生成工具调用序列的工具来源。本研究梳理并集成了 20 多个权威天文数据源，构建了包含 93 个标准化查询工具的工具库。具体的数据源名称、工具数量、数据类型情况如表 3-1 所示。

表 3-1 天文数据查询工具收集表

序号	数据源	中文名称	工具数量	数据类型
1	ALMA ^[69]	阿塔卡马大型毫米波	4	星表、成像
2	Atomic	原子谱线数据库	1	原子谱线
3	CADC ^[70]	加拿大天文数据中心	4	星表、成像
4	CASDA ^[71]	澳大利亚平方公里阵列	1	射电星表
5	CDMS	科隆分子光谱数据库	3	分子谱线
6	Gemini	双子星望远镜	3	光学/红外星表
7	ESO ^[72]	欧洲南方天文台	2	多波段星表
8	HEASARC	高能天体物理科学档案研究中心	2	高能观测星表
9	HiPS	分层巡天数据	2	成像
10	HITRAN	高分辨率透射分子吸收数据库	2	分子吸收谱线
11	IRSA	NASA/IPAC 红外科学档案	2	红外星表
12	IRSA Dust	星际尘埃消光数据	4	尘埃消光
13	JPL	JPL 分子光谱数据库	4	分子谱线
14	MAST	米库尔斯基空间望远镜档案	14	星表、成像、光谱
15	MPC	小行星数据中心	5	轨道参数、星历
16	NED	NASA/IPAC 河外星系数据库	6	河外天体星表
17	NIST	美国国家标准与技术研究院	1	原子谱线
18	SIMBAD	斯特拉斯堡天文数据中心	9	多波段星表
19	SVO FPS	西班牙虚拟天文台滤光片服务	3	滤光片透射率
20	UKIDSS	英国红外望远镜深空巡天	3	红外成像 FITS
21	其它	-	18	-

这些数据资源广泛来源于 NASA、ESO、CDS、MPC 等全球权威天文机构，彰显了天文学研究的多国协作特征。该工具集不仅支持星表与多波段 FITS 图像等常规数据获取，还涵盖原子与分子谱线、光谱、光变曲线，以及滤光片响应函数、尘埃消光图等高维与专用数据产品。这种全面的数据支持，为恒星形成、星系演化及高能天体物理等前沿研究奠定了坚实基础。

3.1.3 任务构造

本文利用种子任务设计、模型驱动扩展、人工审核优化三个步骤建立构造测试任务的方案，以确保任务设计合理且样本覆盖面广。首先，在充分了解 93 个目标工具的功能特点及使用场景基础上，人工选取并编写 50 条种子测试任务，每个任务均以“问题描述-指令序列”的格式给出；然后基于大语言模型对这些种子测试任务进行语义扩写，得到多种表述形式的多个查询样本；接着经过多次人工检查与完善，最终形成 600 个高质量的测试集，用于后续工作。

3.1.4 任务划分

本文从数据类型和任务复杂度两个维度，对构造的测试数据任务进行划分：

(1) 按照查询的类型划分




图 3-1 天文数据查询中按照查询的类型划分的任务数量统计

如图 3-1 所示，本研究按照查询的类型划分，星表数据查询有 296 条任务，图像数据查询有 178 条任务，曲线数据查询有 126 条任务。各个类型任务的作用如下：

① 天文星表数据查询

星表是天文学研究的基石，此类任务旨在从海量数据库中提取特定天体的结构化属性。以查询 M13 球状星团的 Simbad 星表为例，其返回结果涵盖天体标识、赤经赤纬、视差、径向速度等关键参数（详见表 3-2）。在天文科研中，星表数据不仅是进行天体精准定位与交叉认证的核心依据，更是统计恒星演化特征、分析星系动力学环境以及构建大尺度宇宙结构模型的数据基础，具有不可替代的底层支撑作用。

表 3-2 天文星表主要字段介绍

字段名	字段解释	示例
main_id	天体的主要名称	M13
otype	天体类型	"G1C"（球状星团）
ra	赤经，单位：度（J2000 历元）	250.4
dec	赤纬，单位：度（J2000 历元）	36.5
plx_value	视差（parallax，单位：mas）	0.127
rvz_radvel	径向速度（km/s）	-244.4
rvz_redshift	相对论红移值	-8.1
sp_type	光谱型	None
morph_type	形态类型（主要用于星系）	None
coo_bibcode	坐标数据来源的参考文献	"2006AJ....131.1163S"

② 天文图像数据查询

这类任务是为了获取某一个天体或天区的高质量图像（如图 3-2 中的仙女座星系图像）。图像作为天文学中最常用的一种数据类型，在形态学研究以及空间分布分析时都离不开它。基于这些高质量的天文图像，科学家们可以研究星系旋臂结构、恒星形成区域的位置、星系团的弥散性，以及由暗物质存在引起的显著引力透镜效应等问题。



图 3-2 仙女座的图像数据

③ 天文曲线数据查询

此类任务主要涉及对特定天体的时序观测数据（光变曲线）或波长观测数据（光谱曲线）的获取（可视化效果如图 3-3 所示）。而在天文学中，这类曲线是研究天文现象的重要工具，在寻找系外行星凌日事件、了解超新星爆发机理、观测活动星系核的变化等方面都起到重要作用；同时光谱还可以提供天体的成分、温度、速度甚至红移等信息，从而帮助人们认识天体本身及其演变过程。




图 3-3 光谱和光变曲线图

(2) 按照工具调用数量划分




图 3-4 天文数据查询中按照工具的调用个数划分的任务数量统计

如图 3-4 所示。展示了基于工具调用数量的数据查询任务分类。单工具任务（200 条）的调用链长度为 1，工具独立运行即可得出结果，复杂度最低。双工具任务（200 条）的调用链长度为 2，其核心特征在于工具间的相互耦合：前一个工具的查询结果构成了后一个工具的必要输入，以此协同完成目标，归类为较为简单。三工具任务（200 条）的调用链长度达到 3，需要构建完整的输出和输入依赖链，三个工具间存在严格的数据传递关系，任何一个工具的执行都强依赖于其前置工具的输出，整体流程繁琐，属于较为复杂的任务。该分类直观体现了工具调用链路长度与任务难度的正相关关系。

3.1.5 评估指标

为了全面、客观地衡量智能体工具调用在复杂任务中的表现，本研究针对任务执行的核心过程，构建了包含工具检索与工具调用两个维度的量化评估体系。由于工具链式调用具有高度的耦合性，前序环节的微小偏差会导致最终任务失败，因此本体系所有指标均采用“严格匹配”原则：预测结果必须完全覆盖真实值集合方可视为正确，任何关键元素的遗漏均直接判定该样本为失败。

(1) 工具检索正确率 (Tool Retrieval Accuracy, TRA)

工具检索是整个任务执行的先决条件。工具检索正确率的作用在于衡量 RAG 模块从大规模工具库中精准定位目标工具子集的能力，其核心意义是验证系统是否具备找全所需工具的能力，避免因工具遗漏导致的任务中断。

设测试集样本总数为 M ，对于第 i 个样本，定义其真实所需的工具集合为 $T_{gold}^{(i)}$ ，经 RAG 模块检索后得到的预测工具集合为 $T_{pred}^{(i)}$ 。引入指示函数 $\mathbb{I}$ ，当且仅当真实工具集合是预测工具集合的子集时取值为 1，否则为 0。工具检索正确率 TRA 计算公式如下：

$$TRA = \frac{1}{M} \sum_{i=1}^M \mathbb{I}(T_{gold}^{(i)} \subseteq T_{pred}^{(i)}) \quad (3-2)$$

其中， $\subseteq$ 表示集合的包含关系。该指标要求预测集合必须完整覆盖真实集合，同时允许检索结果中存在多余的无关工具，但关键要求是不能遗漏任何一个真实需要的工具，只要满足子集关系即计为正确；反之，若存在任一真实工具未被检索到，则该样本计为0。

(2) 工具调用正确率 (Tool Call Accuracy, TCA)

在确保工具检索无误的基础上，任务的成功最终依赖于大语言模型对工具的准确使用。工具调用正确率用于评估模型在检索工具后，准确完成工具选取与参数配置的能力。该指标的意义在于直接反映模型能否将用户的自然语言意图，精准转化为可执行操作序列，是判定最终任务需求是否达成的关键标准。

对于第 i 个样本，设其真实的完整工具调用序列为 $S_{gold}(i) = \{(t_k, p_k)\}$ ，模型实际生成预测的完整调用序列为 $S_{exec}(i) = \{(t'_k, p'_k)\}$ 。其中， t_k 表示真实序列中第 k 步调用的工具名称， p_k 表示该工具对应的参数字典； t'_k 和 p'_k 分别表示模型生成预测序列中的工具名称和参数字典。工具调用正确率 TCA 定义为：

$$TCA = \frac{1}{M} \sum_{i=1}^M I(S_{gold}(i) \subseteq S_{exec}(i)) \quad (3-3)$$

在此严格对比机制下，判定 $S_{gold}(i) \subseteq S_{exec}(i)$ 成立必须同时满足两个条件：

工具选取一致：调用的工具名称必须完全包含真实任务所需的所有工具；

参数配置等价：对于每一个被调用的工具，其生成的参数字典 p'_k 必须与真实参数字典 p_k 一致。

若遗漏了关键工具、调用了错误工具，或者虽然选对了工具但参数配置错误/缺失，导致无法正确执行获取目标数据，则该样本的 TIA 计为0。此指标直接反映了模型将自然语言意图转化为精准可执行操作序列的能力。

3.2 方法设计

针对天文数据查询任务的复杂性，本研究设计了一种基于动态 RAG 的天文数据查询工具调用方法。旨在通过精准匹配并调用天文数据查询工具来解决复杂的查询任务。如图 3-5 所示，整体流程划分为离线构建与在线推理两个核心阶段：离线阶段致力于构建语义丰富的工具文档，为检索奠定知识基础；在线推理阶段则通过问题重写、工具检索、工具选取、工具链补全以及基于假设性工具描述的再次检索关键步骤，逐步构建出逻辑完整且连贯的工具调用链，最终实现任务执行。以下将对各模块的具体设计进行详细阐述。




图 3-5 基于动态 RAG 的天文数据查询工具调用方法设计图

3.2.1 构建语义丰富的工具文档

为了在复杂的天文查询任务中实现精准的工具匹配，本研究首先构建了具备丰富语义信息的工具文档。在构建过程中，本研究结合了人工定义与大模型生成两种方式。具体而言，先由人工梳理并确定工具的基本信息，包括工具标识、名称及参数规范，随后利用大语言模型自动生成逻辑连贯的功能描述与使用场景示例。该方式在保留工具结构化调用信息的基础上，提升了文档的自然语言表达能力，能更清晰地阐明工具功能与适用场景，从而为后续的工具检索与任务规划提供高质量的数据基础。此外，通过多轮人工核查与模型调整，工具文档的准确性、一致性及泛化能力得到进一步强化，确保工具文档能有效适应多样化的天文应用需求，并具备良好的可扩展性。得到的工具完整信息如表 3-3 所示。

表 3-3 天文数据查询工具描述表

字段名	示例
id	1
工具名	simbad_query_object
数据源	法国斯特拉斯堡天文数据中心
输入参数	输入天体名称
输出参数	输出星表数据
工具描述	该工具通过法国斯特拉斯堡天文数据中心查询天体信息，输入天体名称（如"M1"）即可获取该天体的详细数据。它能提供天体的位置坐标、类型、运动信息、测光数据。
问题示例	从斯特拉斯堡天文数据中心数据库(SIMBAD, Strasbourg astronomical Data Center)中获取 M31 天体的基本信息，包括位置、类型、观测数据及研究文献。

3.2.2 基于大语言模型动态 RAG 的工具调用方法

如何准确识别并组合出适配当前任务需求的工具链，是实现智能查询的关键。本研究提出一种基于大语言模型动态 RAG 的工具调用方法，通过问题重写、工具检索、工具选取、工具链补全与再次检索的检索与生成的动态交替，逐步动态构建出逻辑完整且连贯的工具调用链。具体过程如下：

(1) 问题重写

在天文数据查询的实际应用中，用户输入的原始问题往往存在表达模糊、信息不完整或意图隐含等特点。若直接将原始问题用于工具检索与任务规划，容易导致任务语义稀疏，进而影响工具匹配的准确性和调用链构建的完整性。为此，本研究在方法流程中引入问题重写模块。该模块借助大语言模型，对用户原始查询进行语义解构与信息补全，将其转化为结构清晰、意图明确的问题表达，从而为后续的任务细化与工具选择提供高质量的输入。

(2) 工具检索

在工具检索阶段，依托离线阶段构建的增强型工具库进行语义向量检索。该阶段通过计算问题重写后的向量与工具描述向量之间的相似度，快速筛选出一批与当前任务潜在相关的候选工具集合。

设重写后的问题文本为 Q_{rw} ，工具库中第 j 个工具的语义描述文本为 S_j 。通过预训练的文本嵌入模型将二者映射至高维向量空间，分别得到问题向量 $q=Emb(Q_{rw})$ 与工具向量 $d_j=Emb(S_j)$ 。系统通过计算两者间的余弦相似度来衡量

语义相关性，其公式定义为：

$$\text{sim}(q, d_j) = \frac{q \cdot d_j}{\|q\| \cdot \|d_j\|} \quad (3-4)$$

其中 $\cdot$ 表示向量点积运算， $\|\cdot\|$ 表示向量的 L2 范数。设工具库全体工具的文档向量集合为 $T = \{d_1, d_2, \dots, d_K\}$ ，基于上述相似度得分，系统通过检索函数选取得分最高的若干工具构成初始候选集合，该过程可形式化表示为：

$$C_{init} = \text{Retrieve}(q, T, N) \quad (3-5)$$

其中， q 为问题向量， T 为工具库全体文档向量集合， N 为设定的返回数量。 $\text{Retrieve}(\cdot)$ 表示依据余弦相似度对集合 T 中的元素进行降序排列，并截取前 N 项对应工具的检索映射函数。 $C_{init} = \{tool_1, tool_2, \dots, tool_N\}$ 表示最终输出的初始候选工具集合。

(3) 大语言模型辅助的工具选取

在获得初步候选工具集合后，本研究将其与重写后的问题一同输入大语言模型，以完成工具的选取。在此环节中，大语言模型依托其语义理解能力，剔除无关工具，并按数据处理逻辑将保留下来的工具排列成一条初步的调用链。该过程可形式化为：

$$L_{init} = \text{LLM}_{\text{select}}(Q_{rw}, C_{init}) \quad (3-6)$$

其中， Q_{rw} 表示重写后的问题， C_{init} 表示初步检索到的候选工具集合， $\text{LLM}_{\text{select}}(\cdot)$ 表示大语言模型的工具选取功能， $L_{init} = \{tool_{s1}, tool_{s2}, \dots, tool_{sm}\}$ 表示生成的初步工具调用链。

(4) 大语言模型辅助的工具链补全

然而，由于初步检索阶段仅依赖语义相似度匹配，极易漏掉那些功能描述具有隐式特征的工具，导致初步调用链 L_{init} 出现输入输出不匹配的逻辑断层。为弥补这一缺陷，本文引入大语言模型进行工具链的推理与补全。

具体而言，系统将重写后的问题与初步生成的工具调用链一同输入大语言模型，利用其逻辑推理能力分析链路中的数据流转关系并定位缺失环节。在此基础上，大语言模型会推理生成一个当前任务必需但实际未被检索到的假设性工具。该过程可表示为：

$$Tool_{hypo} = \text{LLM}_{\text{complete}}(Q_{rw}, L_{init}) \quad (3-7)$$

其中， $\text{LLM}_{\text{complete}}(\cdot)$ 表示大语言模型的推理补全功能， $Tool_{hypo}$ 表示生成

的假设性工具，其包含假设性工具名称及其功能描述 D_{hypo} 。通过构造假设性工具，本步骤将深层的隐含数据流转需求显式化，从而为后续的再次检索提供了精准的语义引导。

(5) 基于假设性工具描述的再次检索

根据上一轮生成的假设性工具名称及结构化描述，系统将其作为新的查询向量，动态触发新一轮的检索操作，精准识别并补齐因表述差异而遗漏的真实工具，实现候选工具集的动态扩展。该再次检索过程可形式化为：

$$C_{supp} = Retrieve(Emb(D_{hypo}), T, M) \quad (3-8)$$

其中， $Emb(\cdot)$ 表示将文本描述映射为向量空间的向量化操作， D_{hypo} 为假设性工具的功能描述文本， T 为工具库全体文档向量集合， M 为本次补充检索设定的返回数量， C_{supp} 表示最终匹配到的真实补充工具集合。通过将 C_{supp} 补充嵌入至初步调用链 L_{init} 的断层位置中，从而构建出逻辑完整且连贯的最终工具调用链。该过程表示为：

$$L_{final} = Merge(L_{init}, C_{supp}) \quad (3-9)$$

其中， $Merge(\cdot)$ 表示工具链合并与重组映射函数，负责根据数据流转逻辑将 C_{supp} 准确插入 L_{init} 的对应位置， L_{final} 即为最终构建出的逻辑完整且连贯的工具调用链。

3.2.3 任务执行

任务执行阶段作为整个流程的最终落地环节，旨在将逻辑规划转化为实际操作。在确定最优工具链后，系统利用大语言模型强大的代码生成能力，依据选定工具的 API 接口规范、参数约束，自动生成可执行的调用代码，并交由执行环境运行以获取最终结果。该过程可形式化表示为：

$$R = Execute(LLM_{gen}(Q_{rw}, L_{final})) \quad (3-10)$$

其中， $LLM_{gen}(\cdot)$ 表示大语言模型的代码生成映射函数，负责根据输入的重写后的问题 Q_{rw} 与最终工具调用链 L_{final} 生成符合规范的可执行代码； $Execute(\cdot)$ 表示代码执行环境的运行映射函数，负责运行生成的代码并返回结果； R 即为系统最终输出的任务执行结果。

3.3 实验结果及分析

为全面验证本章所提的基于动态 RAG 的工具调用方法的有效性，本节设计了对比实验、消融实验、参数分析和案例分析实验。

3.3.1 对比实验

(1) 实验设置

本实验选取三种主流 RAG 工具调用方法为基线：Craft^[20]、Re-Invoke^[21]和 Toolshed^[21]。为评估检索策略对各方法鲁棒性的影响，引入传统词频匹配检索器（BM25）与稠密向量检索器（Multilingual_e5_small，简称 e5）进行交叉对比。底层大语言模型统一采用 DeepSeek-V3，评估指标沿用 3.1.5 节定义的工具检索正确率（TRA）与工具调用正确率（TCA）。实验基于 3.1 节构建的评测数据集，包含 93 个工具及 600 条查询任务。

(2) 不同查询任务类型的对比分析

表 3-4 展示了各方法在星表、图像、曲线三类数据查询任务下的性能对比。其中天文星表数据查询（简称星表数据），天文图像数据查询（简称图像数据），天文曲线数据查询（简称曲线数据）的划分详见 3.1.4 节。

表 3-4 不同查询任务类型下的方法性能对比（%，加粗为最优）

RAG 工具 调用方法	检索器	星表数据		图像数据		曲线数据		总体	
		TRA	TCA	TRA	TCA	TRA	TCA	TRA	TCA
Craft	BM25	65.5	57.8	31.5	27.5	63.5	55.6	55.0	48.3
	e5	78.4	66.6	25.8	23.0	81.8	65.9	63.5	53.5
Re-Invoke	BM25	65.2	61.2	56.7	46.6	54.8	48.4	60.5	54.2
	e5	82.4	77.0	27.5	22.5	86.5	72.2	67.0	59.8
Toolshed	BM25	81.1	69.6	38.2	31.5	77.0	54.8	67.5	55.2
	e5	91.2	77.7	36.5	31.5	85.7	60.3	73.8	60.3
本章方法	BM25	80.7	71.6	63.5	48.9	65.9	52.4	72.5	60.8
	e5	94.3	86.5	88.2	84.3	88.9	77.8	91.3	84.0

在星表数据查询任务中，本章方法（e5）在星表数据查询任务中表现优异，TRA 和 TCA 分别达到 94.3%和 86.5%，优于其他基线方法。

在图像数据查询任务中，本章方法（e5）表现优异，TRA 和 TCA 分别达到 88.2%和 84.3%，优于其他方法。这归因于所提方法通过动态 RAG 的工具调用方法，能够有效获取图像数据的查询需求。

在曲线数据查询任务中，本章方法（e5）的 TRA 达到 88.9%、TCA 为 77.8%，较高于 Re-Invok。

总体性能：综合来看，本章方法在 e5 检索器下的总体 TRA 和 TCA 分别达到 91.3%和 84.0%，相较于基线 Toolshed（e5）分别提升了 17.5 和 23.7 个百分点，验证了所提方法在天文数据查询场景下的工具调用的有效性。此外，从检索器维度的横向对比可以看出，对于所有方法，在大多数查询任务类型下，稠密向量检索器 e5 优于传统词频匹配检索器 BM25，表明语义向量检索在处理复杂天文自然语言查询时优势很大。

（3）不同工具调用数量的对比分析

任务所需的工具调用数量直接反映了多步推理的复杂程度。在多工具场景下，前一个工具的输出需要作为后一个工具的输入，调用步骤的增加也意味着信息传递次数的增多。为此，本实验按调用工具个数将测试集均分为单工具（简称 Tool1）、双工具（简称 Tool2）与三工具任务（简称 Tool3）。表 3-5 详细展示了各方法随任务复杂度增加的性能变化与衰减趋势。

表 3-5 不同工具调用数量下的方法性能对比（%，加粗为最优）

RAG 工具 调用方法	检索器	Tool1		Tool2		Tool3		总体	
		TRA	TCA	TRA	TCA	TRA	TCA	TRA	TCA
Craft	BM25	92.5	86.0	63.0	56.5	9.5	2.5	55.0	48.3
	e5	97.0	90.5	69.0	59.0	24.5	11.0	63.5	53.5
Re-Invoke	BM25	93.5	90.5	54.5	50.5	33.5	21.5	60.5	54.2
	e5	99.0	96.0	70.5	61.0	31.5	22.5	67.0	59.8
Toolshed	BM25	95.5	89.0	73.5	62.0	33.5	14.5	67.5	55.2
	e5	93.0	87.5	85.5	72.5	43.0	21.0	73.8	60.3
本章方法	BM25	95.0	93.5	78.0	63.0	44.5	26.0	72.5	60.8
	e5	99.5	93.5	88.0	85.0	86.5	73.5	91.3	84.0

在单工具任务中，作为基础能力，该任务只需调用一个工具，各基线方法表现均较好，本章方法（e5）的 TRA 和 TCA 达到 99.5%和 93.5%，验证了其基

基础检索的准确性。

在双工具任务中，该任务需要依次调用两个工具，即第一个工具的输出要作为第二个工具的输入。基线方法性能开始下滑，如方法 Toolshed (e5) 的 TCA 降至 72.5%。本章方法 (e5) 凭借准确的步骤拆解能力，TRA 和 TCA 稳定保持在 88.0% 和 85.0%。

在三工具任务中，该任务需要依次调用三个工具，涉及两次中间结果的传递，复杂度较高。基线方法 (e5) 均遭遇严重衰减。本章方法 (e5) 展现出较强的抗干扰能力，TRA 与 TCA 维持在 86.5% 和 73.5%。

性能衰减分析：从 Tool1 到 Tool3，方法 Toolshed (e5) 的 TCA 累积衰减高达 66.5 个百分点，而本章方法 (e5) 衰减 20.0 个百分点。这一对比表明，传统方法在长链路中极易发生语义偏移与误差累积，而本章方法能够有效维持多步调用的连贯性，在复杂任务中具有鲁棒性。

3.3.2 消融实验

为了验证本章提出的动态 RAG 的工具调用方法中各关键模块的有效性，本节设计了实验。如表 3-6 表 3-7 所示，实验分别从不同查询数据类型（星表、图像、曲线）和不同工具链复杂度（单工具 Tool1、双工具 Tool2、三工具 Tool3）两个维度进行评估。实验统一采用 DeepSeek-V3 作为底层大语言模型，并固定使用稠密向量检索器 (e5) 进行工具检索。评价指标采用工具检索准确率 (TRA) 与工具调用准确率 (TCA)。具体消融变体设定如下：

w/o QR & CC: 同时移除问题重写模块，以及工具链补全与再次检索逻辑，退化为传统的单轮语义检索与简单排序，作为基础基线。

w/o CC: 在基础基线上引入问题重写模块，但移除后续的工具链补全与再次检索逻辑，用于验证问题重写模块的独立贡献。

w/o QR: 在基础基线上引入工具链补全与再次检索逻辑，但移除前置的问题重写模块，用于验证在缺乏问题重写的条件下，工具链补全逻辑的实际表现与影响。

本章方法: 包含问题重写与工具链补全与再次检索的完整方法，作为验证两模块协同重要性的上限基准。

表 3-6 不同查询任务类型下的消融实验结果 (%)

消融方法	星表数据		图像数据		曲线数据		总体	
	TRA	TCA	TRA	TCA	TRA	TCA	TRA	TCA
w/o QR & CC	73.0	63.2	28.7	26.4	77.0	66.7	60.7	53.0
w/o CC	81.4	75.3	27.0	25.8	88.1	67.5	66.7	59.0
w/o QR	89.5	79.7	87.6	78.1	80.9	69.8	87.1	77.2
本章方法	94.3	86.5	88.2	84.3	88.9	77.8	91.3	84.0

表 3-7 不同工具调用数量下的消融实验结果 (%)

消融方法	Tool1		Tool2		Tool3		总体	
	TRA	TCA	TRA	TCA	TRA	TCA	TRA	TCA
w/o QR & CC	96.0	90.5	63.0	55.0	23.0	13.5	60.7	53.0
w/o CC	99.5	97.5	72.5	65.0	27.5	14.5	66.7	59.0
w/o QR	97.5	84.5	88.0	77.5	76.0	69.5	87.1	77.2
本章方法	99.5	93.5	88.0	85.0	86.5	73.5	91.3	84.0

根据实验结果，可以观察到以下三个结论：

(1) 缺少“工具链补全与再次检索逻辑”（w/o CC）会导致复杂任务中的工具链严重断裂

如表 3-7 所示，移除该模块后，Tool3 任务的 TRA 从 86.5%降至 27.5%，总体的 TRA 从 91.3%降至 66.7%。其原因在于，单次语义检索难以命中功能描述隐式的中间工具。缺少了生成假设性工具、再次检索的机制，系统会漏掉这些关键工具，导致大模型只能基于残缺的工具集生成断裂的调用链，导致任务失败。值得注意的是，w/o CC 在 Tool1 任务上的 TCA 略高于完整方法，这是因为单工具任务所需工具少，引入该模块会增加检索到的工具数量，对大模型调用工具造成轻微干扰，但是在多工具任务上，完整方法取得较优的表现。

(2) 缺少“问题重写模块”（w/o QR）会降低初始检索准确性，影响后续工具补全

缺少该模块会使总体 TRA 从 91.3%降至 87.1%。天文查询语句常包含专业缩写或省略前提条件。不经过问题重写进行语义解构，初步检索召回的工具集

合会产生一些偏差。这种初始语义的缺失，使得后续的补全模块面临一定的压力。

（3）同时缺少两者（w/o QR & CC）会使系统退化为脆弱的单次检索基线

如表所示，w/o QR & CC 的总体 TRA 和 TCA 仅为 60.7%和 53.0%。系统既无法厘清用户模糊意图，又无法主动修补逻辑断层，完全退化为字面匹配，一旦遇到稍微复杂的真实需求就会失效。

3.3.3 参数分析

本实验旨在验证本章方法对不同主流大语言模型的泛化适配性，量化分析模型规模、语言适配性等核心因素对本方法的影响。

实验检索器统一选用 Multilingual_e5_small（前文实验已验证该组合性能最优），实验以工具检索正确率（TRA）和工具调用正确率（TCA）为核心评估指标，主要衡量不同基座大语言模型在 RAG 的工具调用方法中的准确性。实验选取当前工业界与学术界主流的 3 大开源模型系列作为测试对象，覆盖不同参数规模与技术特性：

Qwen 系列：qwen-2.5-72b-instruct、qwen-2.5-32b-instruct

DeepSeek 系列：deepseek-v3、deepseek-r1-distill-qwen-32b

GPT 系列：GPT4o-mini、GPT3.5-turbo-0125




图 3-6 不同 LLM 对本章 RAG 工具调用方法的性能影响

图 3-6 所示，根据参数分析实验结果，不同大语言模型在基于 RAG 的工具

调用方法中的表现存在显著差异。其中 `deepseek-v3` 展现出最优性能，其工具检索正确率（TRA）和工具调用正确率（TCA）分别达到 91.3% 和 84.0%，优于其他大模型。这表明该模型在工具调用任务中具有更强的语义理解能力和逻辑推理能力。同时可以看出，在同系列模型中，参数量越大，模型在任务上的通常表现往往越好。在 Qwen 系列模型中，72b 参数规模的 `qwen-2.5-72b-instruct` 略优于 32b 参数的 `qwen-2.5-32b-instruct`。在 DeepSeek 系列中，671b 参数的 `deepseek-v3` 模型优于 32b 参数的 `deepseek-r1-distill-qwen-32b` 模型，因为小规模参数的模型能力有限，不能很好的完成天文数据查询任务。

3.3.4 案例分析

为直观验证本章所提动态 RAG 的工具调用方法在复杂天文数据查询任务中的有效性，本节选取典型天文观测场景任务开展案例对比分析。实验以“获取在 `alma` 中塔比星周边 0.3 度范围内的成像数据”为目标任务（该任务为三工具任务），底层大语言模型采用 DeepSeek-V3，检索器统一选用 `Multilingual_e5_small`，对比本章方法与 Craft、Re-Invoke、Toolshed 三种基线方法的执行过程，进一步阐释各方法的核心差异与本章方法的优势。

（1）案例任务与正确执行流程

本案例目标任务为“获取在 `alma` 中塔比星周边 0.3 度范围内的成像数据”，该任务需按“坐标获取、区域检索、数据下载”的逻辑执行，涉及三个核心的工具，具体流程如下：

① 坐标查询：调用 `simbad_query_object` 工具，输入“塔比星”获取其 J2000 坐标系精确坐标；② 区域检索：调用 `query_alma_by_region` 工具，以该坐标为基准、0.3 度为半径，检索 ALMA 观测记录并提取 FITS 下载链接；③ 数据下载：调用 `download_alma_files` 工具，通过链接下载目标 FITS 成像数据。

该任务核心难点为：用户查询未显式提及“坐标获取”这个隐含的意图。

（2）各方法执行过程与分析

① 本章方法执行过程与分析

本章方法依托动态 RAG 的工具调用，能够解析任务隐含依赖，完成工具链的完整构造，具体执行步骤如下表 3-8 所示：

表 3-8 本章方法执行过程

步骤	详细过程
Step1:任务重写	输出： 在亚毫米波阵列（alma）中获取塔比星周边 0.3 度范围内的 FITS 成像数据
Step2:初步工具检索	检索出 TOP10 候选工具，含 download_alma_files、query_alma_by_region
Step3:LLM 工具选取	筛选出核心工具：download_alma_files（下载）、query_alma_by_region（检索）
Step4:假设工具生成	生成假设性坐标查询工具及描述，用于补充工具链。 如： 假设性的工具名: resolve_object_coordinates 假设性的工具描述: 该工具用于解析天体名称的天球坐标，通过输入天体名称（如塔比星），返回其坐标系下的精确位置。
Step5:检索	再次检索，得到 simbad_query_object，完成工具链补全。
Step6:任务执行	生成完整工具链调用代码，成功获取目标 FITS 数据。

分析可知，本章方法成功挖掘出用户查询中隐含的“坐标获取”意图，通过再次检索补齐关键工具，构建了逻辑完整的工具调用链，体现了本章方法对复杂隐式依赖任务的适配能力。

② Craft 的执行步骤

该方法采用“多视角匹配”策略，其核心流程为：首先基于用户原始查询问题，由大语言模型生成若干假设性工具名称及描述，以构建更具泛化能力的检索语句，从而提升后续工具匹配的覆盖率，执行步骤如表 3-9 所示。

表 3-9 Craft 的执行过程

步骤	详细过程
Step1:生成假设性工具名	假设性工具：get_data_around_coord,get_fits_in_range 描述：获取指定坐标周边范围内的特定类型数据
Step2:工具检索	检索出 TOP10 候选工具，含 download_alma_files、query_alma_by_region
Step3:任务执行	生成不完整的工具调用代码，任务失败。

核心缺陷：该方法仅对用户原始查询进行假设性工具生成，未深入挖掘天文查询任务中固有的子任务依赖关系，无法识别“坐标获取”这一前置隐式子任务，导致关键工具缺失，工具链断裂，最终无法完成任务

③ Re-invoke 的执行步骤

该方法利用大语言模型在离线阶段为每个工具文档生成多样化的合成查询，

并将其以特定格式追加到原文档中。随后推理阶段，通过识别用户意图，生成多查询语句再检索，执行步骤如表 3-10 所示：

表 3-10 Re-invoke 的执行过程

步骤	详细过程
Step1:意图提取（生成多查询语句）	提取意图： 在亚毫米波阵列中获取塔比星周边 0.3 度范围内的 FITS 成像数据
Step2:工具检索	检索出 TOP10 候选工具，含 download_alma_files、query_alma_by_region
Step3:任务执行	生成不完整的工具调用代码，任务失败。

核心缺陷：该方法仅依赖用户原始查询进行意图提取，缺乏对天文数据查询场景的领域认知，无法解析任务中隐含的子任务依赖，仅能匹配与用户表述直接相关的工具，无法补齐关键前置工具，导致任务执行失败。

④ Toolshed 的执行步骤

本方法借助大语言模型，为每个工具文档自动生成多样化的合成查询语句，并以结构化格式追加至原始文档中。在推理阶段，系统首先对用户需求进行任务拆解；随后，基于拆解后的子任务生成多种变体表述；最后，依据这些变体执行工具检索，以匹配最相关的功能模块，如表 3-11 所示。

表 3-11 Toolshed 的执行过程

步骤	详细过程
Step1:任务拆解	输出： 在亚毫米波阵列中获取塔比星周边 0.3 度范围内的 FITS 成像数据
Step2:生成任务变体	变体 1：通过专业天文数据接口检索塔比星周边 0.3 度范围内的亚毫米波观测数据，要求 FITS 格式成像文件，包含头文件元数据以支持科学分析 变体 2：获取塔比星周围 0.3 度天区的科学级天文图像数据集，支持 FITS 或其他通用格式，用于研究或教学演示
Step3:工具检索	检索出 TOP10 候选工具，含 download_alma_files、query_alma_by_region
Step4:任务执行	生成不完整的工具调用代码，任务失败。

核心缺陷：该方法虽实现了任务变体生成，但未深入结合天文观测的实际逻辑，无法挖掘任务中隐含的子任务依赖关系，仅能匹配表面相关的工具，无法补齐关键前置工具，工具链存在明显缺失，导致任务无法完成。

（3）案例结论

通过上述案例对比分析可见，本章所提的方法能够有效挖掘复杂天文查询任务中的隐式子任务依赖，补齐关键工具，构建逻辑完整的工具调用链，成功完成目标任务。而三种基线方法均因缺乏隐式子任务解析与工具链补全能力，无法识别“天体坐标获取”这一前置隐含的子任务，导致关键工具缺失、任务执行中断。

该案例进一步验证了本章方法在复杂天文数据查询场景中的有效性与优越性，尤其适用于存在隐式子任务依赖、需要多工具协同调用的查询任务，能够有效解决现有方法工具链不完整、匹配精度低的问题，为天文数据智能查询提供了可靠的技术支撑。

3.4 本章小结

本章针对天文数据查询中因中间工具漏检导致的工具链断裂问题，提出了一种动态 RAG 的工具调用方法。通过“问题重写、初步检索、生成假设性工具、再次检索”的生成与查询动态交替流程，有效挖掘并补齐了具有隐式特征的关键工具，构建出逻辑完整的工具调用链。

同时，为支撑客观评测，本章构建了包含 93 个天文查询工具与 600 条真实场景查询的专用基准数据集。实验结果表明，在不同数据查询类型（星表、成像、曲线）和不同调用复杂度（单工具至三工具）的任务中，所提方法的工具检索与调用正确率优于现有主流基线方法，有效解决了复杂天文场景下工具链匹配精度低、易断裂的问题。

第 4 章 基于反向递归多智能体编排的天文数据分析任务执行方法

在面对涉及多步骤、多工具协同的复杂天文数据分析场景，多智能体架构能有效实现端到端流程自动化。其核心在于将复杂任务分解为子任务，由不同专长的智能体调用自身的工具协同完成。在这过程中，如何从候选智能体集合中精准选择智能体并合理分配子任务，即“智能体编排”，是高效协作的关键。现有通用多智能体方法（如 AgentVerse, AutoGen 等方法^[23-26]）缺乏对天文领域特有数据流转与逻辑依赖的感知，导致在编排时，易陷入执行顺序混乱、关键处理环节缺失或数据流转断层等编排失效的问题，影响整体分析流程的可靠性与效率。

针对上述挑战，本文提出了一种基于反向递归多智能体编排的天文数据分析任务执行方法。该方法在离线阶段预构建了涵盖数据查询、图像分析、事件计算与可视化四大领域的专业智能体库。在在线推理阶段，首先通过中心调度器进行全局初步的智能体编排，然后以末端目标智能体为锚点，构建“工具选取、缺失数据识别、前置智能体分配”的递归闭环，系统能够自动推导并补全因用户意图模糊或隐性前提缺失而导致的前置处理节点，进而生成严密、完整的智能体协作拓扑。最终，各智能体依据该拓扑精准调用底层工具，从而提升端到端分析流程的鲁棒性与任务完成度。

为全面验证所提方法的有效性，本文构建了包含 141 个标准化天文工具的底层工具库，并基于真实交互场景梳理了 160 条涵盖多层级复杂度的评测数据集，任务类型全面覆盖天文图像分析、天文事件模拟及天文数据查询。本章结构安排如下：第 4.1 节详细介绍基准测试的构造；第 4.2 节系统阐述所提多智能体方法，重点解析专业智能体的构建及反向递归编排策略的设计原理；第 4.3 节对本章设计的智能体协作方法进行实验分析；第 4.4 节对本章内容进行总结。

4.1 基准测试构造

为验证本文提出的方法的有效性，并为相关研究提供可复现的评测基准，本章设计了一套基准测试，其核心工作在于构建一个专用的评测数据集。该数据集旨在模拟在 WWT 可视化环境中的天文数据分析需求，每条数据样本均由

“问题-任务分解序列-工具调用序列”构成。围绕该基准测试，本节将依次阐述任务的定义、工具库的构建、测试任务的构造、任务的划分、最后定义相应的评估指标。

4.1.1 任务定义

我们将任务形式化为一个包含用户意图、任务分解序列、工具调用序列的多元组 $D = \{Q, S_{init}, D_{seq}, T_{seq}\}$ 。具体定义如下：

(1) 用户问题与上下文 (Q, S_{init})

在真实借助 WorldWide Telescope 可视化平台展开天文数据分析任务的应用中，用户极少会直接输入“调用坐标：赤经为 0.7，赤纬为 41.2，视野大小为 2.3 的图像，然后使用星体检测算法检测这个图像的星体，并在 WWT 用圆圈标记检测到的星体”这样精确的指令，更自然的交互是（如图 4-1 所示）：用户在 WWT 可视化界面中随意滑动、缩放到某一感兴趣区域后，输入“帮我使用检测算法检测这个区域中的星体”，其意图中的“这个区域”并非硬编码在问题文本中，而是由用户当前的动态视图状态（即视图的中心坐标和视野范围）所隐含定义；同时，指令仅表达了高层目标，没有详细表明数据获取和处理过程，使得这类指令具有明显的模糊性。




图 4-1 WWT 智能交互系统中的自然语言星体检测交互示例

用户除了使用文本描述，还能通过平移或缩放 WWT 视图，将当前的视场状态作为上下文输入。因此，任务的完整输入由用户的自然语言问题 Q 和系统的 WWT 初始状态 S_{init} 共同构成。 S_{init} 包含 WWT 平台的当前视图状态（赤经、赤纬、视野大小），为问题提供了隐含的空间上下文。例如，用户提问“标记出这个区域为星系的星体”，其中“这个区域”由 S_{init} 动态定义。

(2) 任务分解序列 (D_{seq})

这是任务输出的核心环节，体现了多智能体编排的逻辑。在实际应用中，同一专家智能体往往需要负责执行多个子任务（例如，“数据获取智能体”同时负责“图像获取”与“星表查询”）。为准确表达这种一对多的任务分配关系， D_{seq} 采用以智能体为键、子任务集合为值的聚合形式进行定义：

$$D_{seq} = \{(a_i, D_i)\}_{i=1}^M \quad (4-1)$$

其中， M 为当前任务激活的专家智能体数量； a_i 表示第 i 个被激活的专家智能体类型（如数据查询智能体、图像分析智能体等）； $D_i = \{Task_{i,1}, Task_{i,2}, \dots, Task_{i,n_i}\}$ 为分配给该智能体的子任务描述集合这种形式化表达保证了任务要素的完备性，同时明确了执行主体与具体任务内容。

(3) 工具调用序列 (T_{seq})

针对用户给的任务，模型需要给出具体的可执行工具调用方案。 T_{seq} 代表满足查询意图的正确可执行指令序列。作为二元组的逻辑核心， T_{seq} 并非简单的工具名称列表，而是要求模型同时实现“工具的准确选取”与“完整的参数配置”。其具体结构定义如下：

$$T_{seq} = \{(t_1, p_1), (t_2, p_2), \dots, (t_n, p_n)\} \quad (4-2)$$

其中， t_k 表示第 k 步选取的具体工具； $p_k = \{\text{param_name: param_value}\}$ 表示为该工具配置的具名参数字典，包含该调用所需的全部参数键值对。

4.1.2 工具收集

为支撑多样化天文数据分析任务，构建了包含 141 个工具的专业工具库，涵盖四类核心功能，分布如图 4-2 所示。其中，天文数据查询工具数量最多（93 个），主要来源于 AstroQuery 专业库；事件分析工具 19 个，基于 SkyField 库整理；图像分析工具 23 个，来自 PhotUtils；WWT 可视化控制工具 6 个。每个工具均包含 Id、工具名、功能描述、输入输出参数等字段，全面说明其功能与使用方式，为天文数据处理提供系统化工具支持。




图 4-2 WWT 及数据分析工具类别分布统计

4.1.3 任务构造

为了保证基准测试任务的准确性与多样性，我们的任务构造遵循“种子构建、模型扩展、人工校验”的三阶段闭环流程，具体步骤如下：

（1）种子构建阶段

首先，我们在深入了解 WWT 交互平台操作方式的基础上，针对平台集成的 141 个工具，参考其官方文档与使用示例，人工编写并调试了 80 条种子数据，数据样本为“用户问题-工具调用序列”格式。这些种子数据的输入样本“用户问题”高度模拟了真实用户的交互习惯，即表达模糊、带有隐含空间信息（如“帮我检测这个区域的星体”）。

为了让这 80 条数据符合前文任务定义的“问题-任务分解序列-工具调用序列”标准结构，我们进一步对 141 个工具进行了系统归类，划分为：天文数据获取工具集、天文图像分析工具集、天文事件分析工具集以及天文 WWT 控制工具集。针对每条种子数据已有的工具调用序列，逐一匹配其工具所属的工具集类别，以工具功能为核心逆向推导子任务描述。最终形成“用户问题（需求起点）、任务分解序列（需求拆解）、工具调用序列（执行路径）”的完整结构，得到 80 条高质量结构化种子数据。

（2）模型扩展阶段

仅依靠人工编写的 80 条数据难以覆盖足够多样的用户表达方式。因此，我们利用大语言模型对这 80 条种子数据进行语义变体扩展。通过保持核心意图与执行路径不变，大模型将原本单一的任务问题改写为多种不同的自然语言表达，从而得到多样化的样本。

（3）人工校验阶段

大模型扩展的数据不可避免地会存在语义偏移或逻辑瑕疵。为此，我们进

行了严格的人工审查与修正，逐一核对扩展后的问题是否依然匹配原有的任务分解与工具调用序列，剔除不合格样本并修正细节错误。

经过上述严密的构建流程，我们最终得到了包含 160 条高质量数据的评测基准。该基准既保留了真实场景的模糊性与复杂性，又具备标准化的评估标注，为多智能体系统的能力测试提供了可靠支撑。

4.1.4 任务划分

本节从任务类型、协作规模及执行复杂度三个维度，对构建的任务数据集进行详细阐述。

(1) 按照任务类型进行划分

本基准测试依据天文数据分析的内在科学逻辑与数据处理范式，将任务划分为以下三个核心类别，其分布比例如图 4-3 所示。




图 4-3 天文数据分析任务中按照任务类型进行划分

① 基于 WWT 的天文图像分析

通过对天文图像进行背景扣除、星体检测和光度测量等处理，研究人员可以更准确地获取目标天体的形态与亮度信息，从而提升观测数据的科学价值。在 WWT 环境中，此类任务要求智能体能够准确解析隐含的视场空间上下文，自动串联底层的图像处理算法，实现从二维像素矩阵到天体物理参数提取、再到可视化空间标注的自动化转换闭环。具体应用示例如图 4-4 所示。




图 4-4 基于 WWT 的天文图像分析应用示例图

② 基于 WWT 的天文事件分析

该类任务以真实或模拟的天文现象为核心，围绕地内行星运行、地外行星运行、日月相位与食、二十四节气、天文掩食以及天体升落与中天等关键内容展开，引导用户在动态观测中掌握天体运动规律。在 WWT 三维动态可视化框架下，此类任务要求智能体具备严密的时间、空间坐标转换能力，能够将抽象的天体力学公式转化为直观的时空演化序列，提供直观可感的视觉体验。具体应用示例如图 4-5 所示。




图 4-5 基于 WWT 的天文事件分析应用示例图

③ 基于 WWT 的天文数据查询

在 WWT 环境中，该类任务不再是简单的数据库检索，而是将结构化的查询结果（如坐标、星等）映射为虚拟天空中的空间分布与拓扑结构。这要求智能体能够准确解析用户模糊的检索意图，自动调用跨域天文数据库（如 SIMBAD、VizieR），实现从抽象数据检索到空间特征可视化的闭环。具体示例如图 4-6 所示。




图 4-6 基于 WWT 的天文数据查询应用示例图

（2）按照完成任务所需的智能体调用数量进行划分

在多智能体编排中，从候选智能体集合中调用智能体的数量，决定了任务的复杂程度。一个任务所需的智能体数量越多，它们之间传递信息的环节就越多，出现理解偏差或信息丢失的风险也会随之增加。因此，我们根据任务实际需要调用的智能体数量，将任务划分为以下三个类别，以此来测试系统在处理不同长度协同链路时的稳定性。

① 单智能体任务：不需要跨角色协同，由 1 个智能体独立完成。例如，直接根据坐标查询某星系的基础数据。这类任务没有信息传递的过程，主要测试单个智能体的基础执行能力。

② 双智能体任务：需要 2 个智能体按顺序配合，中间涉及一次信息交接。例如，“数据查询智能体”先获取天体坐标，然后把结果传给“WWT 可视化智能体”进行星体渲染。这类任务开始考验系统在单次交接时能否准确传递上下文。

③ 三智能体任务：需要 3 个智能体配合，中间涉及两次信息交接。例如，“数据查询智能体”获取 FITS 图像→“图像分析智能体”进行目标检测→“WWT 可视化智能体”对检测结果进行渲染展示。这类任务的环节最长，很容易因为前一个环节的小错误导致后续结果全部出错（即误差累积），是测试系统编排能力的重点。

为了重点考察系统处理复杂协同任务的能力，我们在构建数据集时适当增加了高难度任务的比重。如图 4-7 所示，在 160 条评测数据中，单智能体任务有 20 条，双智能体任务有 42 条，而需要三次协同的三智能体任务最多，达到 98 条。




图 4-7 天文数据分析任务中按照任务所需的智能体调用个数划分的统计结果

（3）按照完成任务所需的工具调用个数进行划分

依据工具调用数量递增的规律，将任务划分为简单、中等、复杂三个难度等级，图 4-8 饼状图直观呈现不同工具调用数量的任务分布，表 4-1 明确各等级对应的工具调用个数与任务数量（单任务需要调用 1-2 个工具，共 29 条；中等任务需要调用 3-4 个工具，共 61 条；复杂任务需要调用 5-8 个工具，共 70 条）。该划分以工具调用次数递增为客观依据界定任务难度，能精准区分不同复杂度的天文数据分析任务，全面检验多智能体系统在简单、中等、复杂工具场景下的编排与执行能力。




图 4-8 天文数据分析中按照任务所需的调用工具个数进行划分统计

表 4-1 天文数据分析中按照任务所需的调用工具个数按难易进行划分

任务等级	工具调用个数	任务个数
简单任务	1-2	29
中等任务	3-4	61
复杂任务	5-8	70

4.1.5 评估指标

为了全面、客观地评估多智能体系统在天文数据分析任务中的表现，我们设计了评价指标体系，分别从协作编排逻辑与工具调用细节两个核心维度进行考量，这两个指标均采用完全覆盖的判定机制，确保模型生成的序列没有遗漏任何真实所需的步骤。

（1）智能体编排正确率（Agent Orchestration Accuracy, AOA）

该指标旨在评估多智能体编排中智能体选取与任务分配逻辑的完整性。

针对同一专家智能体可能负责执行多个子任务的情况（例如，“数据获取智能体”同时负责“图像获取”与“星表查询”），我们采用以智能体 a 为键、其负责的子任务集合 D 为值的二元组 (a, D) 来表达这种聚合关系。

对于测试集中的第 k 个样本，其真实的编排集合与模型预测的编排集合分别表示为二元组集合：

$$T_k^{gold} = \{(a, D^{gold}) | a \in A, D^{gold} \subseteq D_{all}\} \quad (4-3)$$

$$T_k^{pred} = \{(a, D^{pred}) | a \in A, D^{pred} \subseteq D_{all}\} \quad (4-4)$$

在该数学表达中，下标 k 代表当前评估的特定样本索引； a 代表系统中的某一个具体专家智能体； A 表示系统中全体可用智能体构成的集合； D_{all} 表示当前任务域下所有可能的子任务描述空间； D^{gold} 与 D^{pred} 则分别代表在真实标签与模型预测结果中，分配给智能体 a 的具体子任务描述集合。

为了准确衡量任务分配的完整性，本文规定模型预测的任务集合必须完全涵盖真实标签所要求的所有任务。基于此，单样本的编排判定结果 C_k 定义为如下分段函数：

$$C_k = \begin{cases} 1, & \text{若 } \forall (a, D^{gold}) \in T_k^{gold}, \text{ 均满足 } D^{gold} \subseteq D_k^{pred}(a) \\ 0, & \text{其他情况} \end{cases} \quad (4-5)$$

在此判定式中，符号 $\forall$ 为全称量词，表示“对于任意一个”； $D_k^{pred}(a)$ 表示在模型针对第 k 个样本的预测方案中，实际分配给特定智能体 a 的任务集合，若模型未激活该智能体，则该集合自然退化为空集 $\emptyset$ ；符号 $\subseteq$ 表示集合论中的子集关系。

该公式的数学含义为：只有当真实编排集合中的每一个二元组，其真实任务集 D^{gold} 均被完全包含于模型预测的对应任务集 $D_k^{pred}(a)$ 中时，判定结果 C_k 才取值为 1，否则取值为 0。

进而，智能体编排正确率（AOA）定义为全量测试样本编排判定结果的算术平均值：

$$AOA = \frac{1}{N} \sum_{k=1}^N C_k \quad (4-6)$$

式中， N 为测试样本的总数；求和算子 $\sum_{k=1}^N$ 表示将所有样本的判定得分进行逐项累加；除以 N 即求得最终的正确率比例。

在该定义下，核心约束条件 $D^{gold} \subseteq D_k^{pred}(a)$ 明确了正确编排的边界：真实要求的任务集合必须是模型预测任务集合的子集。在此标准下，若模型为智能体分配了超出真实需求的额外子任务，由于依然满足集合包含关系，该情形被

判定为正确；反之，若任意一个必要子任务未被包含在预测集合中而发生遗漏，则直接判定该样本的评估为错误。该指标通过严密的集合逻辑，精准量化了多智能体协作过程中的任务覆盖能力，有效保障了复杂任务执行的完整性。

（2）工具调用正确率（Tool Call Accuracy, TCA）

该指标是衡量任务最终是否成功执行的关键量化标准，反映了智能体将自然语言意图转化为具体可执行操作序列的能力。为了严格评估任务完成度，我们采用包含关系判定逻辑：模型生成的工具调用序列必须完全覆盖真实任务所需的所有工具调用序列。

设第 k 个样本的真实完整调用序列（包含工具及参数）为 $O_k^{\text{gold}} = \{(t_m, p_m)\}$ ，模型实际生成的完整调用序列为 $O_k = \{(t'_n, p'_n)\}$ 。工具调用正确率 TCA 定义为：

$$TCA = \frac{1}{N} \sum_{k=1}^N I(O_k^{\text{gold}} \subseteq O_k) \quad (4-7)$$

在此严格对比机制下，判定 $O_k^{\text{gold}} \subseteq O_k$ 成立必须同时满足以下两个条件：

工具选取一致：生成代码中调用的工具名称集合必须完全包含真实任务所需的所有工具，即 $\{t_m\} \subseteq \{t'_n\}$ ；

参数配置等价：对于每一个被调用的必需工具，其生成的参数字典 p'_n 必须与真实参数字典 p_m 在结构上一致。

该指标有效评估了智能体在工具选择与参数配置两个层面的综合执行能力，确保了任务执行的完整性与准确性。

4.2 方法设计

针对天文数据分析任务的复杂性，本研究设计了一种基于反向递归多智能体编排的天文数据分析任务执行方法。如图 4-9 所示，其整体流程分为离线阶段和推理阶段两个部分：在离线阶段，人工构建一个由四个天文领域专业化智能体组成的团队；在在线推理阶段：首先智能体初次编排，然后以末端智能体为锚点，通过“工具选取、缺失数据识别、前置智能体分配”的递归闭环，得到完整的智能体协作链，最终根据编排得到的任务表进行执行任务。具体如下：




图 4-9 基于反向递归多智能体编排的天文数据分析任务执行方法图

4.2.1 天文专业智能体设计

真实的天文数据分析是一个多步骤耦合的复杂工程，天文数据分析涉及从数据获取、处理分析到可视化的全流程。如绪论中的背景介绍所示，本研究采用多智能体技术，通过团队分工合作来解决天文数据分析。在多智能体架构下，本研究需预先建立一个结构合理、分工明确的专家智能体团队，且每个专业智能体在其专长领域内具备熟练使用相关工具、独立解决特定问题的能力。

我们依据在 WWT 环境下的天文数据任务的典型工作流（从原始数据获取、科学分析到最终交互式可视化）设计了四个功能解耦但协同高效的专家智能体。设智能体集合为 A ，则：

$$A = \{A_{data}, A_{img}, A_{event}, A_{vis}\} \quad (4-8)$$

(1) 天文数据获取智能体 (A_{data})

该智能体负责数据处理，从主流天文数据服务中查询并获取数据，包括天体的位置、星体类型、星等、光谱数据等。由于该领域涉及的查询工具数量庞大且更新频繁，若将所有工具描述全部传入上下文，会导致提示词过长且推理效率降低。因此，该智能体采用 RAG（检索增强生成）进行工具检索策略（详见第三章）。其构建逻辑首先通过向量相似度检索，从工具库中筛选出与用户问题语义匹配度最高的 Top-K 个工具，随后将筛选后的工具集输入大语言模型生成工具调用序列。该过程可形式化为：

$$S_{data} = A_{data}(u, Retrieve(u, T_{data})) \quad (4-9)$$

其中, u 为用户指令, T_{data} 为天文数据查询工具全集 (由 AstroQuery API 封装而成), $Retrieve(\cdot)$ 表示向量检索函数, 最终由 LLM 基于检索结果生成针对数据获取的工具调用序列 S_{data} 。

(2) 天文图像分析智能体 (A_{img})

该智能体负责图像分析, 专注于对原始天文图像进行科学级处理, 包括背景扣除、源检测、计算星体形态特征等操作。鉴于天文图像处理的专业工具相对标准化且数量有限, 该智能体采用全量工具注入策略, 直接将所有可用的图像处理工具描述一次性提供给大语言模型。模型通过语义理解直接定位所需工具并生成工具调用序列, 公式表示如下:

$$S_{img} = A_{img}(u, T_{img}) \quad (4-10)$$

其中, T_{img} 代表图像分析工具的全集 (由 PhotUtils API 封装而成), 无需检索步骤, 模型直接根据任务需求在全量工具中规划出有序的调用序列 S_{img} 。

(3) 天文事件分析智能体 (A_{event})

该智能体负责星历表数据计算分析, 计算特定时间与地点下的天体位置、视运动轨迹、相对几何关系, 以及掩星、凌日、合日等动态天文事件。与图像分析智能体类似, 天文事件计算分析所依赖的星历计算库功能明确且数量可控, 因此同样采用全量工具注入策略。其构建公式为:

$$S_{event} = A_{event}(u, T_{event}) \quad (4-11)$$

其中, T_{event} 为天文事件计算工具全集 (由 SkyField API 封装而成), 无需检索步骤, 模型直接根据任务需求在全量工具中规划出对应的事件计算分析调用序列 S_{event} 。

(4) WWT 可视化智能体 (A_{vis})

该智能体负责可视化, 将处理分析后的数据映射至 WWT 平台。由于 WWT 平台的可视化接口封装较为完善, 工具数量固定, 故同样采用全量注入策略。大语言模型根据数据处理分析结果, 直接调用完整的可视化工具集进行场景构建:

$$S_{vis} = A_{vis}(u, T_{vis}) \quad (4-12)$$

其中, T_{vis} 为 WWT 可视化工具全集 (由 WWT Web Control API 封装而

成)，无需检索步骤，模型直接根据任务需求在全量工具中规划出构建可视化场景的调用序列 S_{vis} 。

4.2.2 基于反向递归的智能体编排

(1) 智能体初次编排

引入一个具备全局视野的中心调度智能体。它首先接收并解析用户的自然语言任务 u ，然后从智能体集合中选取调用合适的专家智能体，并为每个专家智能体分配子任务，并按照逻辑依赖关系将它们编排成一个有序的协作序列，即初始智能体协作链 W_0 ：

$$W_0 = \langle (t_1, a_1), (t_2, a_2), \dots, (t_n, a_n) \rangle \quad (4-13)$$

其中， t_i 为第 i 个子任务， $a_i \in A$ 为负责该子任务的智能体。这一过程确保了专家资源能够被精准、高效地调动，并为后续的优化与执行奠定基础。

(2) 反向递归智能体编排

由于用户表述可能存在模糊性，加之中心调度智能体缺乏对各个智能体底层天文工具细节的掌握，导致初步编排的智能体协作链并不完整，常表现为所生成的链存在前置步骤不完整、任务缺失等问题。然而，经验表明，末端（即靠近最终输出）的智能体通常能被正确选取，因其直接对应用户显式意图。因此，本研究提出一种从后向前递归优化的策略，以末端智能体为锚点，逐层回溯并补全缺失的前置环节。

设当前的智能体为 a_{curr} ，其对应的子任务为 t_{curr} 。该优化过程包含三个紧密耦合、依次迭代的子步骤：

① 工具选取

将该子任务输入至对应的智能体后，该智能体会基于其工具集 T ，输出为任务所需调用的工具序列 T_{curr} ：

$$T_{curr} = \{tool_1, tool_2, \dots, tool_k\} \subseteq T \quad (4-14)$$

需要注意的是，此阶段仅涉及工具的选择与排序，不包含具体参数的配置。

② 缺失数据识别

在确定工具序列后，系统将当前子任务 t_{curr} 与该序列中各工具的输入接口规范 $input(T_{curr})$ 联合作为输入，传递给缺失数据识别大模型。该大模型通过对

任务语义与工具接口规范的深度解析，对比当前已知上下文与工具实际需求，反向推导出尚未被提供的输入数据项，将其标记为缺失数据 D_{miss} ：

$$D_{miss} = LLM_{identify}(t_{curr}, input(T_{curr})) \quad (4-15)$$

其中， $LLM_{identify}$ 表示缺失数据识别大模型的推理映射过程。利用大模型的语义理解能力，避免了传统硬编码解析带来的局限性，确保了数据依赖关系被精准捕获。

③ 缺失数据分配

针对识别出的缺失数据，系统会发起一次广播式查询：所有其他专业智能体将评估自身是否具备生成或获取该数据的能力。若某智能体能够处理该缺失数据，便会“举手响应”。设 $Match(d)$ 为能提供数据 d 的智能体，则：

$$a_{pre} = Match(D_{miss}) \quad (4-16)$$

由此，缺失数据被分配给具备相应处理能力的智能体 a_{pre} ，从而确定其作为当前智能体的前置智能体。

④ 递归优化与智能体协作链生成

一旦确立了当前智能体的前置智能体，系统便以该前置智能体为新的起点，递归重复上述三个子步骤，直到回溯至数据源头，形成一条完整的智能体协作链。设 $Optimize(a_{curr})$ 为以当前智能体为锚点向前递归构建智能体协作链的函数，该递归过程可严谨地形式化为分段函数：

$$Optimize(a_{curr}) = \begin{cases} \langle (t_{curr}, a_{curr}, T_{curr}) \rangle, & \text{若 } D_{miss} = \emptyset \\ Optimize(a_{pre}) \oplus \langle (t_{curr}, a_{curr}, T_{curr}) \rangle, & \text{若 } D_{miss} \neq \emptyset \end{cases} \quad (4-17)$$

其中， $\oplus$ 表示工作流序列的顺序拼接操作。递归的终止条件为当前智能体的缺失数据集为空（即 $D_{miss} = \emptyset$ ），这表明该智能体执行当前子任务所需的输入数据已完全具备（如来源于用户初始指令或已获取的常量），无需再向前追溯。

假设初步编排链 W_0 中的末端智能体为 a_{end} ，通过对该末端智能体执行上述反向递归优化函数，即可自后向前依次拼接出最终完整的智能体协作链 W_{final} ：

$$W_{final} = Optimize(a_{end}) = \langle (t_1, a_1, T_1), (t_2, a_2, T_2), \dots, (t_m, a_m, T_m) \rangle \quad (4-18)$$

其中， m 为优化后智能体协作链的总步骤数， (t_i, a_i, T_i) 表示第 i 步的子任务、

负责智能体及其选定的工具序列。与初始智能体协作链 W_0 相比， W_{final} 通过反向递归机制精确补全了所有隐含的前置数据处理环节，并显式绑定了每步所需调用的具体工具，从而构建出一条逻辑严密、功能完备的端到端执行链路。

4.2.3 任务执行

任务执行阶段作为整个流程的最终落地环节，旨在将逻辑规划转化为实际操作。在确定智能体协作链和工具链后，系统利用大语言模型强大的代码生成能力，依据选定工具的 API 接口规范、参数约束自动生成可执行的调用代码，并交由执行环境运行以获取最终结果。该过程可形式化表示为：

$$R = Execute(LLM_{gen}(u, W_{final})) \quad (4-19)$$

其中， u 为用户的初始任务指令， W_{final} 为反向递归优化后生成的完整智能体协作链（其中包含子任务和工具调用序列）， $LLM_{gen}(\cdot)$ 表示大语言模型的代码生成映射函数，生成端到端的全局可执行代码； $Execute(\cdot)$ 表示代码执行环境的运行映射函数，负责运行生成的代码并返回结果； R 即为系统最终输出的天文数据分析与可视化结果。

4.3 实验结果及分析

4.3.1 多智能体对比分析

（1）实验设置

对比基线：本文对比 AgentVerse^[23]、AutoAgents^[24]、OWL^[25]、AutoGen^[26] 四种通用的多智能体方法。

实验数据：本研究采用了自建的数据集，详见 4.1 节，其中工具共 141 个，任务数量共 160 条。其中按照任务类型划分为：基于 WWT 的天文图像分析，基于 WWT 的天文事件分析，基于 WWT 的天文数据查询。按照任务将会选取的专家团队数量进行划分为：单任务、双任务和三任务专家类型。按照任务所需的工具数量分为：简单、中等和复杂三个等级。

评估指标：本研究使用了智能体编排正确率（AOA），工具调用正确率（TCA）两个关键指标。详见 4.1 节的评估指标。

大语言模型选择：本实验使用 DeepSeek-V3 和 Qwen3.5-plus 大语言模型。

(2) 实验结果及分析

从实验总体结果来看本文方法在整体性能上较优。在 DeepSeek-V3 下，总体 AOA 分别达到 92.5%，TCA 达到 88.8%，较次优基线 AgentVerse 分别提升 11.8 和 8.8 个百分点。在 Qwen3.5-plus 下，总体 AOA 分别达到 92.5%，TCA 达到 91.3%，较次优基线 AgentVerse 分别提升 10.6 和 11.3 个百分点。这证明了反向递归多智能体编排机制在处理天文数据分析多步骤耦合与长链路流转问题时的有效性与优越性。以下分别从任务类型、智能体调用数量和工具调用数量三个维度展开对比实验。

① 基于任务类型的对比分析

本实验旨在评估所提出的方法在不同天文任务类型场景下的适应性与执行效能，验证其在处理异构需求时的鲁棒性。实验选取了涵盖“基于 WWT 的天文图像分析”（简称图像分析）、“基于 WWT 的天文事件分析”（简称事件分析）及“基于 WWT 的天文数据查询”（简称数据查询）三大类典型任务，详细分类情况见 4.1.4 小节，实验结果如表 4-2 所示：

表 4-2 不同天文任务类型下的多智能体性能对比（%）

智能体	大模型	图像分析		事件分析		数据查询		总体	
		AOA	TCA	AOA	TCA	AOA	TCA	AOA	TCA
AgentVerse	DeepSeek-V3	100	100	51.7	50.0	96.7	96.7	80.7	80.0
	Qwen3.5-plus	95.0	92.5	58.3	55.0	96.7	96.7	81.9	80.0
AutoAgents	DeepSeek-V3	95.0	92.5	48.3	43.3	93.3	93.3	76.9	74.4
	Qwen3.5-plus	95.0	92.5	45.0	41.7	95.0	93.3	76.3	73.8
OWL	DeepSeek-V3	65.0	60.0	66.3	61.7	93.3	90.0	75.0	71.9
	Qwen3.5-plus	80.0	80.0	58.3	51.7	91.7	90.0	76.3	73.1
AutoGen	DeepSeek-V3	92.5	90.0	48.3	45.0	93.3	88.3	76.3	72.5
	Qwen3.5-plus	92.5	90.0	55.0	48.3	86.7	86.7	76.3	73.1
本章方法	DeepSeek-V3	87.5	82.5	88.3	83.3	100	98.3	92.5	88.8
	Qwen3.5-plus	90.0	90.0	91.7	88.3	95.0	95.0	92.5	91.3

在图像分析任务中，本章方法准确率整体保持稳定，当任务链路固定且意图明确时，通用多智能体的常规规划能力已可应对，本章方法在补全缺失前置环节的优势未充分体现。

在事件分析任务中，本章方法表现出优势。基线方法 AOA 准确率均低于

67%，本章方法均优于现有基线方法。天文事件模拟任务具有高耦合性与高复杂度，本文的反向递归优化策略能够有效补全隐含环节，解决通用编排的错配问题。

在数据查询任务中，本章方法与基线均取得了较高的准确率。保持了同等的执行精度与稳定性。

② 基于智能体调用数量的对比分析

本实验旨在评估所提方法在不同智能体链路长度下的稳定性。根据任务实际从候选智能体集合中调用智能体的数量将其划分为单、双、三智能体任务（任务划分详见 4.1.4）量化智能体协同链路长度对系统编排能力的影响，直观检验系统在处理多次角色交接与信息传递时的稳定性。实验结果如表 4-3 所示：

表 4-3 不同智能体调用数量下的多智能体性能对比（%）

智能体	大模型	单智能体		双智能体		三智能体		总体	
		AOA	TCA	AOA	TCA	AOA	TCA	AOA	TCA
AgentVerse	DeepSeek-V3	100	100	100	100	68.4	67.4	80.6	80.0
	Qwen3.5-plus	100	100	100	100	70.4	67.4	81.9	80.0
AutoAgents	DeepSeek-V3	100	100	100	100	62.2	58.2	76.9	74.4
	Qwen3.5-plus	100	100	100	97.6	61.2	58.2	76.3	73.8
OWL	DeepSeek-V3	100	90.0	97.6	97.6	60.2	57.1	75.0	71.9
	Qwen3.5-plus	100	95.0	95.2	95.2	63.3	59.2	76.3	73.1
AutoGen	DeepSeek-V3	90.0	80.0	100	100	63.3	59.2	76.3	72.5
	Qwen3.5-plus	95.0	95.0	88.1	88.1	67.4	62.2	76.3	73.1
本章方法	DeepSeek-V3	100	100	95.2	92.9	89.8	84.7	92.5	88.8
	Qwen3.5-plus	100	100	100	100	87.8	85.7	92.5	91.3

在单智能体任务中，各方法均表现出极高鲁棒性。本文方法与多数基线在两种大模型上均实现 100% 的 AOA 与 TCA，仅 OWL 和 AutoGen 出现轻微下滑。这表明在无需跨角色协同的单节点场景下，各方法均能准确匹配专家智能体并正确调用工具，任务分配错配概率较低。

面对双智能体协同任务，各方法性能开始分化。通用方法依赖中心调度器的前向规划，易因表述模糊导致数据交接时出现信息理解偏差，本文方法表现稳定，在 Qwen3.5-plus 下达到百分之百双优指标，说明反向递归机制能有效修正初步编排的偏差。

在三智能体复杂协同任务中，本文方法展现出优势。基线方法性能下降，AOA 均低于 71%，暴露出前向规划在长链路中易遗漏前置步骤并导致误差累积的缺陷。本文方法以末端智能体为起点反向递归补全，有效捕获隐含的数据依赖关系。

综上可以看出，随着智能体调用数量增加，任务难度也在上升，本方法展现出一定的抗衰减优势。

③ 基于工具调用数量的对比分析

本实验旨在评估所提方法在不同工具链路长度下的执行稳定性。按任务所需工具数量划分为：简单任务（1–2 个工具）、中等任务（3–4 个工具）、复杂任务（5–8 个工具）。实验结果如表 4-4 所示。

表 4-4 不同工具调用数量下的多智能体性能对比（%）

智能体	大模型	简单(tool1-2)		中等(tool3-4)		复杂(tool5-8)		总体	
		AOA	TCA	AOA	TCA	AOA	TCA	AOA	TCA
AgentVerse	DeepSeek-V3	100	100	96.7	96.7	58.6	57.0	80.7	80.0
	Qwen3.5-plus	100	100	100	98.4	58.6	55.7	81.9	80.0
AutoAgents	DeepSeek-V3	100	100	88.5	86.9	57.1	52.9	76.9	74.4
	Qwen3.5-plus	100	96.6	90.2	90.2	54.3	50.0	76.3	73.8
OWL	DeepSeek-V3	100	93.1	82.0	82.0	58.6	54.3	75.0	71.9
	Qwen3.5-plus	96.6	93.1	88.5	86.9	57.1	52.9	76.3	73.1
AutoGen	DeepSeek-V3	93.1	89.7	90.2	86.9	63.3	52.9	76.3	72.5
	Qwen3.5-plus	93.1	93.1	85.3	85.3	61.4	54.3	76.3	73.1
本章方法	DeepSeek-V3	100	100	93.4	91.8	88.6	81.4	92.5	88.8
	Qwen3.5-plus	100	100	95.1	93.4	87.1	85.7	92.5	91.3

在仅需调用 1 至 2 个工具的简单任务中，多数方法均能保持较高的正确率。本章方法在两种大模型下均实现百分之百的 AOA 与 TCA，OWL 与 AutoGen 在特定模型下出现小幅下降，表明低工具需求下各方法的编排与调用均不易出错。

在中等复杂度任务中，大多数基线方法的各项指标开始出现下滑，AOA 普遍出现一定程度的波动与下滑。本章方法通过反向递归机制准确选取所需工具，在两种大模型下均稳定，有效避免了工具序列调用过程中的遗漏问题。

随着工具调用个数增至 5 至 8 个，基线方法的性能发生严重衰减，AOA 均未超过 64%，反映出常规前向规划在长工具链中极易产生规划错误。本章方法

展现出较强的稳定性。

综上所述可以看出，随着工具调用数量增加，本章方法在高复杂度长工具链任务中展现出较强的稳定性与优势。

4.3.2 参数分析

本参数分析实验旨在验证本章方法对不同主流大语言模型的泛化适配性，以智能体编排正确率（AOA）和工具调用正确率（TCA）为核心评估指标，主要衡量不同基座模型在天文数据分析任务中的准确性。实验选取当前工业界与学术界主流的四大开源模型系列作为测试对象，包括 Qwen 系列（qwen-2.5-72b-instruct、qwen3.5-plus）、DeepSeek 系列（deepseek-v3、deepseek-r1-distill-qwen-32b）、GPT 系列（GPT4o-mini）和 GLM 系列（GLM-5、GLM-4-air），覆盖不同参数规模与技术特性，通过量化分析模型规模、语言适配性等核心因素对方法性能的影响，明确本方法的模型选择边界，为实际场景的部署应用提供实验依据。




图 4-10 不同大语言模型在多智能体系统中的性能对比

如图 4-10 所示，实验结果显示，DeepSeek-v3、Qwen3.5-plus、GLM-5 均表现出色，性能较为接近。同时可以看出，在同系列模型中，参数量越大，模型在任务上的通常表现往往越好。在 Qwen 系列模型中，397b 参数规模的 qwen3.5-plus 较优于 32b 参数的 qwen-2.5-72b-instruct。在 DeepSeek 系列中，671b 参数的 deepseek-v3 模型优于 32b 参数的 deepseek-r1-distill-qwen-32b 模型。在 GLM 系列中，745b 的 glm5 模型的优于 106b 的 glm4.5-air 模型。

4.3.3 案例分析

为直观验证本章所提方法的有效性，本节选取典型天文数据分析场景任务开展案例对比分析。底层大语言模型统一采用 DeepSeek-V3，通过对比本章方法与 AgentVerse、AutoAgents、AutoGen、OWL 四种基线方法的执行过程，深度剖析各方法在复杂任务编排上的核心差异，并凸显本章方法在处理工具参数强依赖时的优势。

(1) 案例任务与正确执行流程

任务：计算分析 21 世纪以来第一次的金星凌日事件，并在 WWT 的地球视角下展示。正确的步骤，如表 4-5 所示：

表 4-5 金星凌日分析任务的正确执行流程与工具依赖

调用智能体	任务	调用工具
数据获取智能体	提供本地的星历表文件地址	"getEphemeris"
天文事件分析智能体	任务 1: 获取 21 世纪以来第一次金星凌日现象发生时金星的赤经赤纬坐标 任务 2: 获取 21 世纪以来第一次金星凌日现象发生的 UTC 时间	"oppositions_conjunctions_all", "skyfield.almanac.find_discrete", "is_strict_inferior_conjunction_event", "skyfield.api.load.at.observe"
WWT 可视化智能体	在地球观测视图下，可视化从 21 世纪以来第一次的金星凌日现象	"set_time", "center_on_coordinates"

执行上述工具链后，WWT 终端可正确渲染出地球视角下的金星凌日轨迹，如图 4-11 所示：




图 4-11 WWT 中金星凌日可视化结果展示

(2) 各方法执行过程与分析

以下分别为本章方法，AgentVerse，AutoAgents，AutoGen，OWL 的执行

过程：

① 本章方法的执行步骤

本章方法基于反向递归编排机制，执行过程如表 4-6 所示。

表 4-6 本章方法的执行步骤

步骤	详细过程
Step1:中心调度器进行初步编排	编排结果： 1.天文事件分析智能体：计算 21 世纪以来第一次的金星凌日现象发生的时间 2.WWT 可视化智能体：在地球视角下可视化该金星凌日现象
Step2:反向递归编排	1. 确定末端智能体为“WWT 可视化智能体”，识别其依赖缺失的：“金星凌日位置（赤经赤纬）”和“时间”数据； 2. 将“计算位置与时间”任务分配给“天文事件分析智能体” 3. 识别“天文事件分析智能体”依赖的“星历表据”，最终分配“数据获取智能体”执行基础数据获取。
Step3:任务执行	各个智能体根据被分配到的任务进行工具的调用并执行，任务执行成功。

执行结果：任务分配完整覆盖“数据→计算分析（时间+空间）→可视化”全链路，逻辑闭环，WWT 成功渲染结果。

② AgentVerse 的执行步骤

该方法采用专家招募和集体研讨的方式，执行过程如表 4-7 所示。

表 4-7 AgentVerse 方法的执行步骤

步骤	详细过程
Step1:专家招募	从预设的“天文专家团队”中匹配出三个相关智能体：数据获取智能体、天文事件分析智能体、WWT 可视化智能体。
Step2:集体讨论更新	各专家基于自身理解更新任务列表（每人仅一次修改权）。 讨论后任务列表： 1. 数据获取智能体：获取星历表文件地址 2. 天文事件分析智能体：计算金星凌日现象发生的时间 3. WWT 可视化智能体：展示金星凌日
Step3:任务执行	各个智能体根据被分配到的任务进行工具调用并执行

执行结果：任务失败。集体讨论受限于大模型的常识偏向（即关注凌日时间而忽视空间坐标），未能识别到计算赤经赤纬坐标这一隐性任务，导致 WWT 可视化阶段因缺少坐标而定位不到金星凌日事件，从而出现导致编排结果及任务失败。

③ AutoAgents 的执行步骤

该方法先进行一次初步编排，再由审查智能体给出编排后智能体工作链的优化建议，最终根据建议调整智能体协作链，执行步骤如表 4-8 所示。

表 4-8 AutoAgents 方法的执行步骤

步骤	详细过程
Step1:初步编排	编排结果： 1. 天文事件分析智能体：计算 21 世纪以来第一次金星凌日现象的时间
Step2:审查后更新	2. WWT 可视化智能体：在地球视角下可视化该金星凌日现象 审查智能体对上述流程进行评估并给出优化建议，更新后任务列表： 1. 天文事件分析智能体：计算金星凌日现象发生的时间和位置 2. WWT 可视化智能体：展示金星凌日
Step3:任务执行	各个智能体根据被分配到的任务进行工具调用并执行

执行结果：任务失败。虽然审查智能体在语义表层察觉到了遗漏，补充了位置概念，但其审查视角存在知识盲区，缺乏对底层工具的理解，未能识别出天文计算对底层星历表数据获取的绝对前置依赖，导致编排结果及任务失败。

④ AutoGen 的执行步骤

该方法先进行智能体的初步编排，再采用对话式交流：用户智能体下达指令，协作智能体从专家团队中选择合适的智能体执行，依据执行结果持续下达指令，直至任务完成。

表 4-9 AutoGen 方法的执行步骤

步骤	详细过程
Step1:初步编排	和表 4-8 初步编排计划类似。
Step2:从前往后下达指令并选取智能体	第一轮：下发“获取星历表”指令 → 分配给数据获取智能体执行； 第二轮：下发“计算金星凌日时间”指令 → 分配给天文事件分析智能体执行； 第三轮：下发“展示金星凌日”指令 → 分配给 WWT 可视化智能体执行，任务失败。

执行结果：任务失败。前向链式传递的局限性：该方法严格依赖前序步骤的输出触发后序步骤，缺乏全局视角的依赖感知。在下达展示指令时，未能前瞻性地意识到坐标数据的缺失，从而出现导致编排结果及任务失败。

⑤ OWL 的执行步骤

该方法采用对话式交流：用户智能体下达指令，协作智能体从专家团队中选择合适的智能体执行，依据执行结果持续下达指令，直至任务完成。

表 4-10 OWL 方法的执行步骤

步骤	详细过程
Step1:从前往后下达指令并选取智能体	第一轮：指令“获取星历表文件地址”→数据获取智能体执行； 第二轮：指令“金星凌日现象发生的时间”→天文事件分析智能体执行； 第三轮：指令“展示金星凌日”→WWT可视化智能体执行，任务失败。

执行结果：任务失败。与 AutoGen 类似，OWL 过度依赖前向链式的推进，导致在任务拆解阶段直接丢失了空间坐标计算这一关键节点，从而出现导致编排结果及任务失败。

4.4 本章小结

针对复杂天文数据分析多智能体编排易出错问题，提出一种基于反向递归优化的智能执行方法。该方法离线构建四大专业智能体团队；推理阶段以末端目标为锚点反向递归编排，精准回溯并自动补全缺失的前置节点。基于含 141 个工具和 160 条数据的基准，实验表明其编排与工具调用准确率显著优于基线，提升了端到端天文数据分析的鲁棒性与可靠性。

第 5 章 WWT 智能交互系统构建

本章详细阐述基于 WWT 的智能交互系统的设计与实现过程，依次从设计目标、需求分析、系统设计及功能实现与测试四个方面展开论述。

5.1 设计目标

传统天文数据分析通常在代码编辑器中进行，过程复杂且不够直观。本系统将人工智能模块集成到万维天文望远镜的 Web 前端，简化天文可视化平台与外部数据分析工具的使用流程，实现数据分析任务的智能执行。图 5-1 展示了该系统的设计原型：用户可在三维星图中拖拽浏览，通过自然语言提问，即可根据当前视图状态，解决天文数据分析任务。




图 5-1 WWT 智能交互系统原型图

5.2 需求分析

5.2.1 系统功能需求分析

按照系统的设计目的，整个系统的功能应划分为以下三个主要部分：空间交互与状态感知、多智能体协同分析、多模态结果呈现与过程可视化。

(1) 空间交互与状态感知功能

用户可以通过鼠标拖拽和滚轮缩放来浏览星空，界面上会实时显示当前视野中心的赤经赤纬坐标和视野范围。同时，用户可以通过点击按钮来显示赤道网络及加载星座连线等辅助观测图层。在接收用户的自然语言指令时，该模块会自动提取当前的坐标和视野状态，一并传递给后端系统，交给多智能体进行决策，通过这种输入能够让多智能体感知当前 WWT 的视图状态。

(2) 基于多智能体的协同分析功能

多智能体协同分析模块负责处理用户下达的复杂天文任务。系统在接收到指令后，首先识别用户的真实意图并进行逻辑推理，随后将整体任务拆解为数据查询、数据分析、可视化等具体的子任务。这些子任务会被分配给不同的子智能体，由各智能体调用相应的工具分别执行与完成。

(3) 多模态结果呈现与过程可视化功能

多模态结果呈现与过程可视化模块负责展示任务的执行过程和最终结果。为了提高系统的可解释性，前端会实时显示多智能体的协作状态和任务进度，例如提示“正在解析意图”或“正在生成代码”。最终的结果输出包含三个层面：会在星图上渲染结果图层或控制镜头自动跳转与高亮；文本层面会输出文本的分析结论；文件层面会提供原始数据和脚本的下载链接，以使用户进行离线验证和二次开发。

其中用户用例图如图 5-2 所示：




图 5-2 WWT 智能交互系统用户用例图

5.2.2 系统非功能分析

为保障智能交互系统的稳定运行与长效服务，本系统需满足以下非功能性需求：

(1) 可用性。系统需具有简便易懂的操作方式以及良好的信息组织结构，

减轻用户负担，使无相关专业知识的人能够快速了解该系统功能特点。

(2) **可扩展性**。使其能够以低成本无缝接入新的天文工具，从而从容适应未来业务需求的变化。

(3) **安全性**。需要建立一套完整数据加密机制以及权限管理机制来保护数据安全并且符合相关法律法规的规定。保证用户的隐私以及数据的安全需要建立一个有效的安全防护机制，在这个机制中需要有对于远程连接以及数据传输过程中的安全保障手段，以防止非法人员对系统的入侵和数据的窃取。

5.3 系统设计

5.3.1 系统总体设计

本系统采用前后端分离的轻量化架构设计，前端基于 Vue 3 框架开发，后端以 Django 为核心框架。系统整体通过自然语言交互降低技术门槛，并依托多智能体协同技术提升复杂任务处理能力，最终实现 WWT 环境下端到端的智能天文数据分析。系统总体设计如图 5-3 所示。




图 5-3 系统总体设计图

该系统采用五层架构设计，自上而下分别为用户交互层、通信层、业务逻辑层、工具层和外部资源层，各层级协同工作，具体设计如下：

第一层：用户交互层。该层作为系统的直接交互入口，包含智能对话框与

WWT 可视化界面。智能对话框负责自然语言指令的接收、历史会话管理及文本结果反馈；WWT 可视化界面集成 WWT 引擎，提供空间漫游、视场状态实时显示及分析结果的图层渲染功能，共同构成系统的输入输出终端。

第二层：通信层。该层负责前后端的数据与指令传输。系统采用 HTTP 协议处理常规的请求与响应交互；同时基于 WebSocket 协议建立全双工通信链路，专门用于后端服务向前端 WWT 界面推送控制指令，实现视角调整与图层加载等状态的实时同步。

第三层：业务逻辑层。该层是系统的核心处理单元，以 Django 框架为基础部署多智能体协作系统。该系统由智能体编排模块以及负责数据获取、图像分析、事件分析和可视化控制的专业智能体组成。该层负责解析自然语言指令，执行任务拆解与分配，并调度下层工具完成具体计算与分析逻辑。

第四层：工具层。该层封装了天文数据分析的底层专业能力，为业务逻辑层提供标准化调用接口。具体包含基于 AstroQuery 的数据获取工具、基于 SkyField 与 PhotUtils 的天文事件及图像分析工具，以及封装 WWT Web Control API 的可视化控制工具，屏蔽了底层代码的实现细节。

第五层：外部资源层。该层对接 SimBad、VizieR、Alma、NASA 等外部天文数据库，作为系统的数据来源支撑，通过标准接口实现跨平台天文数据的检索与获取。

通过上述五层架构设计，系统有效降低了各模块间的耦合度。用户发起的自然语言指令经通信层传输至业务逻辑层后，由多智能体协同调度工具层并调用外部资源层数据，最终在用户交互层完成分析结果的可视化呈现，形成完整的智能天文数据分析流程。

5.3.2 功能模块设计

（1）空间交互与状态感知模块

该部分使用 WWT 引擎搭建三维虚拟现实场景，支持平移与缩放操作，同时可叠加赤道坐标系网格及星座连线等辅助元素以提高定位准确性。此外，当用户发起对话请求时，会自动获取当前视角的中心点与视野范围，并将其作为隐式空间参数传递至后端多智能体实现对当前 WWT 空间视图状态的感知。

（2）多智能体协同分析模块

作为系统的中心组件，采用多智能体技术对自然语言进行理解与推理，将用户的高阶需求分解为一系列动作，并交由数据获取、图像处理以及事件分析等智能体负责完成。

(3) 多模态结果呈现与过程可视化模块

该模块负责系统输出的多模态反馈与决策过程的展示。在过程可视化方面，前端实时呈现任务分解与工具调用等状态流转信息，将内部决策过程转化为可视化的执行流程；在结果呈现方面，系统提供视图渲染、文字总结与文件下载三种输出形式。

5.4 系统功能实现与测试

5.4.1 环境配置信息

本系统的开发与运行基于轻量级的前后端分离架构，为了保证多智能体调度、天文数据分析以及三维可视化渲染的稳定运行，系统在操作系统、前端框架、通信协议及后端服务等方面进行了明确的环境选型与配置。具体的系统开发与运行环境配置信息如表 5-1 所示。

表 5-1 系统环境配置表

模块	技术栈/框架
操作系统	Windows10
前端	HTML、CSS、JavaScript、Vue 3、WWT Web SDK
通信协议	HTTP、WebSocket
后端框架	Python、Django

5.4.2 系统功能实现

(1) 空间交互与状态感知功能实现

① WWT 基础交互功能集成

通过集成 WWT Web 的 Vue 组件，系统实现了星空视图的基础浏览功能。该组件基于 WWT Web 引擎开发，提供鼠标滑动（平移星空视图）和缩放（调整视野大小）两种基础交互操作，满足用户对星空视图的基本浏览需求。

② WWT 辅助观测功能实现

WWT Web 的 Vue 组件本身已具备实时显示赤经赤纬坐标、切换网格及辅助功能等能力，但默认未在前端页面展示。通过 JavaScript 代码，本系统在前

端页面实现了以下功能：

设计实时显示区域，展示当前十字中心所指位置的赤经、赤纬坐标及当前视图的视野大小；开发按钮控件，将赤道网格、地平网格、黄道网格、银道网格等多种网格显示选项，以及星座边界、星座连线、星座图像等辅助功能暴露给用户，实现功能的可视化调用与切换。

这种设计充分利用了 WWT Web 组件的底层功能，通过前端代码将其转化为用户可交互的界面元素，确保了系统的实用性与易用性。

③ WWT 空间上下文感知功能

该功能在用户在输入框输入自然原语言描述并点击提交后，系统会将当前 WWT 视图的赤经赤纬和视野大小一同通过前端发送请求给后端。

如图 5-4 所示，展示空间交互与状态感知功能实现：




图 5-4 空间交互与状态感知功能展示图

（2）基于多智能体的协同分析功能实现

本模块的具体构建细节已在前文第三章与第四章进行了详尽阐述。在系统实现阶段，本模块的核心工作在于将上述理论设计工程化落地：后端 Django 服务以异步任务的形式加载该多智能体核心引擎。当接收到带有空间上下文的用户指令后，多智能体在后台自主完成意图解析、子任务拆解与分工，各专业智能体通过标准化接口无缝调用 Python 天文工具链（如 AstroPy、Photutils），自动生成并执行代码，最终将计算结果封装为标准格式返回给前端，实现了从自

然语言到复杂天文数据分析的端到端自动化闭环。

（3）多模态结果呈现与过程可视化功能实现

① 决策过程可视化功能

系统实现了后端任务状态的流式推送。在多智能体协同处理过程中，后端会在关键节点（如“正在解析意图...”、“数据获取智能体正在调用工具...”、“图像分析智能体正在执行代码...”）向前端主动发送状态流。前端接收到流式数据后，在对话框中实时渲染任务拆解与工具调度的流转信息，使用户能够直观、全程地监控 AI 的内部推理与协作链路。过程透明化展示效果如图 5-5 所示。




图 5-5 多智能体决策过程透明化展示图

② 多模态结果输出与渲染功能

系统提供可视化渲染、文本输出与文件导出相结合的多模态结果输出机制。以执行图像背景噪声剔除与展示任务为例，多智能体在任务编排阶段确认需求后，图像分析智能体在后台运行背景扣除算法对 FITS 数据进行处理；处理结束后，可视化智能体经由 WebSocket 通信链路向前端发送包含图像地址与渲染参数的控制指令；前端 WWT 组件接收指令后，自动控制视图跳转，并在当前天区叠加渲染处理后的 FITS 图像图层。与此同时，系统在交互界面同步输出结构化的总结的文本信息，并生成处理后数据文件的下载链接，以支持分析结果的离线验证与二次开发。效果如图 5-6 所示。



图 5-6 多模态结果输出与 FITS 渲染展示图

5.4.3 系统功能测试

为验证 WWT 智能交互系统是否满足前文 5.1 节 提出的设计目标与需求，本节基于表 5-1 的运行环境，采用黑盒测试方法对系统进行全面验证。测试内容严格按照系统的三大核心功能模块及非功能性需求展开，具体测试用例与结果如下：

(1) 系统功能测试

系统功能测试重点检验各模块的业务逻辑是否顺畅，输入输出是否达到预期标准，具体测试用例见表 5-2 。

表 5-2 系统功能测试用例表

用例编号	测试内容	测试用例描述	预期结果	测试结果
1	WWT 浏览 星空与坐标 显示	使用鼠标拖拽平移星空视图，滚动鼠标滚轮缩放视图	视图平滑渲染无卡顿，界面实时且准确地显示当前视图中心的赤经(RA)、赤纬及视野大小(FOV)	符合预期
2	辅助观测图 层切换	在界面上依次点击“赤道网格”、“星座连线”、“星座图像”等控制按钮	WWT 视图对应图层被正确叠加渲染，再次点击可正常隐藏，状态切换流畅	符合预期
3	空间上下文 感知	将视图拖拽至特定天区（如猎户座），在对话框输入“这里有什么星云？”	前端发送的请求中自动携带了猎户座附近的 RA/Dec 及 FOV 参数，后台能确定该空间区域	符合预期
4	复杂任务解 析与自动执 行	输入复杂指令：“查询仙女座星系附近的光学观测数据，并计算其核心区域的背景噪声”	多智能体成功拆解任务，自动生成并执行 Python 代码，调用 AstroQuery 等工具获取数据并完成计算，全程无需人工干预代码	符合预期
5	决策过程可 视化展示	执行用例 4 的复杂任务，观察对话框的动态变化	对话框以流式输出多智能体的协作过程（如“正在解析意图...”、“数据获取智能体正在调用工具...”等），过程清晰	符合预期
6	多模态结果 渲染与跳转	触发包含可视化结果的指令（如渲染仙女座 FITS 图像）	WWT 视图自动飞行跳转至目标天区，并将图像准确叠加为 WWT 图层；对话框同步输出文本；点击下载文件按钮可下载该文件	符合预期

（2）系统非功能测试

在保障核心业务逻辑的基础上，针对系统可用性、可扩展性及安全性进行专项测试，具体测试用例见表 5-3。

表 5-3 系统非功能测试用例表

用例编号	测试过程	预期结果	测试结果
1	邀请未受训用户进行 WWT 漫游与提问操作	界面直观，用户无需手册即可完成基本交互	符合预期
2	在后端接入新的天文数据工具接口	系统无需修改核心架构即可识别并调用新工具	符合预期
3	测试系统的身份验证和授权机制，非授权的用户是否能够访问特定功能和数据	非授权的用户无法访问相关功能和数据	符合预期

5.5 本章小结

本章以视场交互与自然语言查询相融合为设计目标，详细阐述了 WWT 智能交互系统的构建过程。系统采用 Vue 3 与 Django 框架，设计了五层解耦架构。在核心实现层面，完成了空间交互与感知、多智能体驱动天文工具链闭环执行，以及决策过程可视化与多模态结果渲染等关键功能的开发。测试结果表明，系统各模块运行稳定，有效实现了多智能体技术与三维星空环境的深度融合，为沉浸式智能天文数据分析提供了一种可行的工程实践方案。

第 6 章 总结与展望

6.1 总结

本文针对天文数据分析在 WWT 环境中存在的工具操作复杂、专业门槛高以及分析流程割裂等问题，开展了基于大语言模型的智能执行技术研究，旨在推动天文数据分析向智能化与自动化方向发展。主要研究内容与贡献总结如下：

首先，针对天文数据查询任务中，现有 RAG 的工具调用方法因在检索阶段难以解析隐式依赖而易出现中间工具漏检、导致工具调用链断裂的问题，提出了一种基于动态 RAG 的工具调用方法。该方法设计了工具检索、工具链补全与基于假设性工具的再次检索相交替的动态流程，能够有效识别并补全具有隐式特征的关键工具。为验证该方法的有效性，本文构建了包含 93 个天文查询工具与 600 条真实场景查询的基准数据集。实验结果表明，在星表、成像及光变曲线等多类数据查询任务中，该方法的工具检索与调用准确率均显著优于 Craft、Re-invoke、Toolshed 等主流基线方法，有效提升了复杂场景下工具链匹配的精度与连贯性。

其次，针对复杂天文数据分析任务中，通用多智能体编排方法因缺乏领域逻辑感知而易陷入执行顺序混乱、关键处理环节缺失或数据流转断层等编排失效的问题，提出了一种基于反向递归多智能体编排的任务执行方法。该方法离线构建了涵盖数据查询、图像分析、事件分析及 WWT 可视化的专业智能体团队。在线推理阶段，由中心调度器进行全局初步编排，随后以末端目标智能体为锚点，通过工具选取、缺失数据识别与前置智能体分配的递归闭环，自动推导并补全缺失的前置处理环节，从而生成逻辑严密的智能体协作链。基于包含 141 个专业工具与 160 条多维度评测任务的基准测试，实验结果表明，该方法在智能体编排与工具调用准确率上均显著优于 AgentVerse、AutoAgents、AutoGen 等通用多智能体基线方法，在复杂任务场景下表现出较强的鲁棒性与可靠性。

最后，集成上述技术构建了 WWT 智能交互系统。该系统基于 Vue 3 与 Django 的轻量化解耦架构，实现了空间交互与状态感知、多智能体协同分析、多模态结果呈现与过程可视化三项核心功能，为用户提供了一种沉浸式的天文

数据探索环境。系统测试表明，该系统能够稳定支撑从自然语言输入到三维可视化呈现的端到端自动化分析闭环，验证了本研究提出技术的工程化可行性与实用价值。

6.2 展望

为进一步提升系统的自主性与通用性，未来研究需在以下两个维度进行深化：

（1）引入大模型反馈机制以构建执行、验证与重排的闭环系统

当前系统虽已实现工具链的自动化调用，但结果验证仍依赖人工审查。未来研究需引入大模型反馈机制，利用多模态大模型对前端渲染结果进行语义审查，并借助代码解释器对中间数据产物（如 FITS 矩阵、星历表）进行逻辑校验。但依赖大模型的评估因缺乏可解释性而难以满足科学严谨性，未来需探索更具可解释性与可靠性的生成结果评估范式，如探索微调一个用于评估的大语言模型（收集构造大量高质量的多模态文本对用于微调）、构建一个评估多智能体等等。当检测到执行偏差时，系统自动生成诊断报告并反馈至规划调度器，触发反向递归重排，以降低人工干预成本，提升端到端自动化分析的鲁棒性。

（2）拓展专业智能体边界，向多波段与多信使场景延伸

天文数据分析通常涉及多波段与多信使数据。当前系统主要覆盖图像形态测量、天体运动模拟及基础目录查询等场景，未来需在智能体库中扩展更多跨维度的专业角色，例如负责光变曲线处理的时序分析智能体、负责光谱拟合与丰度测算的光谱分析智能体，以及处理射电与 X 射线等非光学数据的专用智能体。对于每加入一种数据分析功能，均需要探索并构建与之匹配的新的专用工具库，以定义该类智能体可调用的操作边界与接口规范。随着工具库异构性的增加，多智能体编排策略需具备解析图像、光谱、时序及坐标等多模态物理依赖关系的能力，以推动系统从空间可视化辅助工具向具备全栈处理能力的通用天文智能分析底座演进。

致谢

随着这篇论文的最终定稿，我的硕士求学生涯也即将落下帷幕。回首来路，心中满溢感激。首先，最深切的谢意要致谢我的导师，从最初的选题迷茫到最终的字斟句酌，是您的悉心指引与严谨治学一次次为我拨开迷雾，这份言传身教将令我受用终身。其次，感谢求学期间所有倾囊相授的师长，是你们的教诲为我构筑了坚实的学术基石；感谢朝夕相处的同窗好友，那些并肩奋战、热烈探讨的岁月不仅缓解了我的焦虑，更化作了我无比珍贵的青春印记。最后，我要将最深沉的谢意献给我的家人，是你们毫无保留的爱、理解与支持，始终为我筑起最温暖的避风港，让我得以心无旁骛地追逐梦想。带着这份沉甸甸的感恩，我将收拾行囊，继续坚定前行。

参考文献

- [1] 崔辰州, 于策, 肖健, 等. 大数据时代的天文学研究[J]. 科学通报, 2015 (5): 445-449.
- [2] Borne K D. Astrominformatics: a 21st century approach to astronomy[J]. arXiv preprint arXiv:0909.3892, 2009.
- [3] Rosenfield P, Fay J, Gilchrist R K, et al. AAS WorldWide telescope: a seamless, cross-platform data visualization engine for astronomy research, education, and democratizing data[J]. The Astrophysical Journal Supplement Series, 2018, 236(1): 22.
- [4] Goodman A, Fay J, Muench A, et al. Worldwide telescope in research and education[J]. arXiv preprint arXiv:1201.1285, 2012.
- [5] 王琴. 《基于 WWT 平台的天文教学模式研究》 [D]. 武汉: 华中师范大学, 2016.
- [6] Ginsburg A, Sipőcz B M, Brasseur C E, et al. Astroquery: an astronomical web-querying package in Python[J]. The Astronomical Journal, 2019, 157(3): 98.
- [7] Rhodes B. Skyfield: High precision research-grade positions for planets and Earth satellites generator[J]. Astrophysics Source Code Library, 2019: ascl: 1907.024.
- [8] Bradley L, Sipocz B, Robitaille T, et al. Photutils: photometry tools[J]. Astrophysics Source Code Library, 2016: ascl: 1609.011.
- [9] Robitaille T P, Tollerud E J, Greenfield P, et al. Astropy: A community Python package for astronomy[J]. Astronomy & Astrophysics, 2013, 558: A33.
- [10] Hello GPT-4o[EB/OL]. (2024-05-13) [2025-04-09]. <https://openai.com/index/hello-gpt-4o/>.
- [11] DeepSeek-AI. Deepseek-v3 technical report[J]. arXiv preprint arXiv:2412.19437, 2024.
- [12] Lin Y. 大模型工具学习进展与挑战 (Challenges and Advances in Tool Learning with Foundation Models)[C]//Proceedings of the 23rd Chinese National Conference on Computational Linguistics (Volume 2: Frontier Forum). 2024: 34-47.
- [13] Qu C, Dai S, Wei X, et al. Tool learning with large language models: A survey[J]. Frontiers of Computer Science, 2025, 19(8): 198343.
- [14] Chen J, Wu H, Pang J, et al. Tool learning with language models: a comprehensive survey of methods, pipelines, and benchmarks[J]. Vicinagearth, 2025, 2(1): 16.
- [15] 郑逸宁, 余镇, 杨捷, 等. 大语言模型的工具使用综述[J]. 自动化学报, 2025, 51: 1-16.
- [16] Park J S, O'Brien J, Cai C J, et al. Generative agents: Interactive simulacra of human behavior[C]//Proceedings of the 36th annual acm symposium on user interface software and technology. 2023: 1-22.
- [17] Zhang X, Dong X, Wang Y, et al. A survey of multi-ai agent collaboration: Theories, technologies and applications[C]//Proceedings of the 2nd Guangdong-Hong Kong-Macao Greater Bay Area International Conference on Digital Economy and Artificial Intelligence. 2025: 1875-1881.
- [18] Tran K T, Dao D, Nguyen M D, et al. Multi-agent collaboration mechanisms: A survey of llms[J]. arXiv preprint arXiv:2501.06322, 2025.
- [19] 任海玉, 刘建平, 王健, 等. 基于大语言模型的智能问答系统研究综述[J]. Journal of Computer Engineering & Applications, 2025, 61(7).
- [20] Yuan L, Chen Y, Wang X, et al. Craft: Customizing llms by creating and retrieving from specialized toolsets[J]. arXiv preprint arXiv:2309.17428, 2023.
- [21] Chen Y, Yoon J, Sachan D S, et al. Re-invoke: Tool invocation rewriting for zero-shot tool

- retrieval[C]//Findings of the Association for Computational Linguistics: EMNLP 2024. 2024: 4705-4726.
- [22] Lumer E, Subbiah V K, Burke J A, et al. Toolshed: Scale tool-equipped agents with advanced rag-tool fusion and tool knowledge bases[J]. arXiv preprint arXiv:2410.14594,2024.
- [23] Chen W, Su Y, Zuo J, et al. Agentverse: Facilitating multi-agent collaboration and exploring emergent behaviors[C]//The Twelfth International Conference on Learning Representations. 2023.
- [24] Chen G, Dong S, Shu Y, et al. Autoagents: A framework for automatic agent generation[J]. arXiv preprint arXiv:2309.17288, 2023.
- [25] Hu M, Zhou Y, Fan W, et al. Owl: Optimized workforce learning for general multi-agent assistance in real-world task automation, 2025[J]. URL <https://arxiv.org/abs/2505.23885>, 2025.
- [26] Wu Q, Bansal G, Zhang J, et al. Autogen: Enabling next-gen LLM applications via multi-agent conversations[C]//First conference on language modeling. 2024.
- [27] Xu X, Sankar R. Large language model agents for biomedicine: a comprehensive review of methods, evaluations, challenges, and future directions[J]. Information, 2025, 16(10): 894.
- [28] Li B, Yan T, Pan Y, et al. Mmedagent: Learning to use medical tools with multi-modal agent[C]//Findings of the Association for Computational Linguistics: EMNLP 2024. 2024: 8745-8760.
- [29] Gao S, Fang A, Huang Y, et al. Empowering biomedical discovery with AI agents[J]. Cell, 2024, 187(22): 6125-6151.
- [30] Yang S, Liu Z, Mayer W, et al. Shizishangpt: An agricultural large language model integrating tools and resources[C]//International Conference on Web Information Systems Engineering. Singapore: Springer Nature Singapore, 2024: 284-298.
- [31] Shen Y, Song K, Tan X, et al. Hugginggpt: Solving ai tasks with chatgpt and its friends in hugging face[J]. Advances in Neural Information Processing Systems, 2023, 36: 38154-38180.
- [32] Song Y, Xiong W, Zhu D, et al. Restgpt: Connecting large language models with real-world restful apis[J]. arXiv preprint arXiv:2306.06624,
- [33] Wei J, Wang X, Schuurmans D, et al. Chain-of-thought prompting elicits reasoning in large language models[J]. Advances in neural information processing systems, 2022, 35: 24824-24837.
- [34] Yao S, Zhao J, Yu D, et al. React: Synergizing reasoning and acting in language models[C]//The eleventh international conference on learning representations. 2022.
- [35] Qin Y, Liang S, Ye Y, et al. Toolllm: Facilitating large language models to master 16000+ real-world apis[J]. arXiv preprint arXiv:2307.16789, 2023.
- [36] Chen Z, Zhou K, Zhang B, et al. Chatcot: Tool-augmented chain-of-thought reasoning on chat-based large language models[C]//Findings of the Association for Computational Linguistics: EMNLP 2023. 2023: 14777-14790 .
- [37] Liu X, Peng Z, Yi X, et al. Toolnet: Connecting large language models with massive tools via tool graph[J]. arXiv preprint arXiv:2403.00839, 2024.
- [38] Schick T, Dwivedi-Yu J, Dessì R, et al. Toolformer: Language models can teach themselves to use tools[J]. Advances in neural information processing systems, 2023, 36: 68539-68551.
- [39] Patil S G, Zhang T, Wang X, et al. Gorilla: Large language model connected with massive

- apis[J]. Advances in Neural Information Processing Systems, 2024, 37: 126544-126565.
- [40] Yang R, Song L, Li Y, et al. Gpt4tools: Teaching large language model to use tools via self-instruction[J]. Advances in Neural Information Processing Systems, 2023, 36: 71995-72007.
- [41] Tang Q, Deng Z, Lin H, et al. Toolalpaca: Generalized tool learning for language models with 3000 simulated cases[J]. arXiv preprint arXiv:2306.05301,2023.
- [42] Lu P, Peng B, Cheng H, et al. Chameleon: Plug-and-play compositional reasoning with large language models[J]. Advances in Neural Information Processing Systems, 2023, 36: 43447-43478.
- [43] Sparck Jones K. A statistical interpretation of term specificity and its application in retrieval[J]. Journal of documentation, 1972, 28(1): 11-21.
- [44] Robertson S, Zaragoza H. The probabilistic relevance framework: BM25 and beyond[M]. Now Publishers Inc, 2009.
- [45] Reimers N, Gurevych I. Sentence-bert: Sentence embeddings using siamese bert-networks[C]//Proceedings of the 2019 conference on empirical methods in natural language processing and the 9th international joint conference on natural language processing (EMNLP-IJCNLP). 2019: 3982-3992.
- [46] Xiong L, Xiong C, Li Y, et al. Approximate nearest neighbor negative contrastive learning for dense text retrieval[J]. arXiv preprint arXiv:2007.00808, 2020.
- [47] Gao L, Callan J. Unsupervised corpus aware language model pre-training for dense passage retrieval[C]//Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2022: 2843-2853.
- [48] Gao S, Shi Z, Zhu M, et al. Confucius: Iterative tool learning from introspection feedback by easy-to-difficult curriculum[C]//Proceedings of the AAAI conference on artificial intelligence. 2024, 38(16): 18030-18038.
- [49] Kong Y, Ruan J, Chen Y, et al. Tptu-v2: Boosting task planning and tool usage of large language model-based agents in real-world industry systems[C]//Proceedings of the 2024 conference on empirical methods in natural language processing: industry track. 2024: 371-385.
- [50] Minsky M. Society of Mind, Simon and Schuster[J]. 心の社会, 1990.
- [51] Frith C, Frith U. Theory of mind[J]. Current biology, 2005, 15(17): R644-R645.
- [52] Qian C, Liu W, Liu H, et al. Chatdev: Communicative agents for software development[C]//Proceedings of the 62nd annual meeting of the association for computational linguistics (volume 1: Long papers). 2024: 15174-15186.
- [53] Hong S, Zhuge M, Chen J, et al. MetaGPT: Meta programming for a multi-agent collaborative framework[C]//The twelfth international conference on learning representations. 2023.
- [54] Vichentijevikj I, Mishev K, Simjanoska Misheva M. Prompt-to-pill: Multi-Agent drug discovery and clinical simulation pipeline[J]. Bioinformatics Advances, 2026, 6(1): vbaf323.
- [55] Xiao Y, Sun E, Luo D, et al. Tradingagents: Multi-agents llm financial trading framework[J]. arXiv preprint arXiv:2412.20138, 2024.
- [56] Yu Y, Yao Z, Li H, et al. Fincon: A synthesized llm multi-agent system with conceptual verbal reinforcement for enhanced financial decision making[J]. Advances in Neural Information Processing Systems, 2024, 37: 137010-137045.
- [57] Kim H, Jang Y, Ahn S. Mt-mol: Multi agent system with tool-based reasoning for molecular

- optimization[J]. Artificial Intelligence Repository, 2025.
- [58] Wenger M, Ochsenbein F, Egret D, et al. The SIMBAD astronomical database-The CDS reference database for astronomical objects[J]. Astronomy and Astrophysics Supplement Series, 2000, 143(1): 9-22.
- [59] Ochsenbein F, Bauer P, Marcout J. The VizieR database of astronomical catalogues[J]. Astronomy and Astrophysics Supplement Series, 2000, 143(1): 23-32.
- [60] Kurtz M J, Eichhorn G, Accomazzi A, et al. The NASA astrophysics data system: Overview[J]. Astronomy and astrophysics supplement series, 2000, 143(1): 41-59.
- [61] 柯大荣,赵永恒.一种图象传输系统及其 FITS 数据基本格式[J].数据分析与知识发现, 1994, 10(002):22-27.
- [62] Pence W D, Chiappetti L, Page C G, et al. Definition of the flexible image transport system (fits), version 3.0[J]. Astronomy & Astrophysics, 2010, 524: A42.
- [63] Zotti G, Hoffmann S M, Wolf A, et al. The simulated sky: Stellarium for cultural astronomy research[J]. arXiv preprint arXiv:2104.01019, 2021.
- [64] Baines D, Giordano F, Racero E, et al. Visualization of multi-mission astronomical data with ESASky[J]. Publications of the Astronomical Society of the Pacific, 2017, 129(972): 028001.
- [65] American Astronomical Society. WorldWide Telescope WebGL Engine Reference [EB/OL]. [2026-03-25]. <https://docs.worldwidetelescope.org/webgl-reference>.
- [66] Kojima T, Gu S S, Reid M, Matsuo Y, Iwasawa Y. Large language models are zero-shot reasoners[J]. Advances in neural information processing systems, 2022, 35: 22199-22213.
- [67] Brown T, Mann B, Ryder N, Subbiah M, Kaplan JD, Dhariwal P, Neelakantan A, Shyam P, Sastry G, Askell A, Agarwal S, Herbert-Voss A, Krueger G, Henighan T, Child R, Ramesh A, Ziegler D, Wu J, Winter C, Hesse C, Chen M, Sigler E, Litwin M, Gray S, Chess B, Clark J, Berner C, McCandlish S, Radford A, Sutskever I, Amodei D. Language models are few-shot learners[J]. Advances in neural information processing systems, 2020, 33: 1877-1901.
- [68] Yao S, Yu D, Zhao J, Shafran I, Griffiths T, Cao Y, Narasimhan K. Tree of thoughts: Deliberate problem solving with large language models[J]. Advances in neural information processing systems, 2023, 36: 11809-11822.
- [69] Wootten A. The Atacama large millimeter array (ALMA)[C]//Large ground-based Telescopes. SPIE, 2003, 4837: 110-118.
- [70] Woodsworth A W. Database Services at the Canadian Astronomy Data Centre[M]//Databases & On-line Data in Astronomy. Dordrecht: Springer Netherlands, 1991: 193-198.
- [71] Chapman J, Dempsey J, Miller D, et al. CASDA: The CSIRO ASKAP Science Data Archive[J]. IAU General Assembly, 2015, 22: 2232458.
- [72] European Southern Observatory. ESO Publication Acknowledgment[EB/OL]. (2022-08-18)[2026-04-11]. <https://archive.eso.org/cms/publication-acknowledgment.html>.

研究生期间参加的科研项目及取得的成果

作者在攻读硕士学位期间参与项目及成果：

（一）科研项目

1. 参与国家自然科学基金项目一项

（二）科研竞赛

1. “华为杯”第二十一届中国研究生数学建模竞赛，国二
2. “华为杯”第二十二届中国研究生数学建模竞赛，国三
3. “华为杯”第六届中国研究生人工智能创新大赛，国三

图版

图 1-1 传统手动方式完成基于 WWT 的天文数据分析任务	1
图 1-2 工具调用相关研究 ^[13]	4
图 1-3 研究内容概览图	8
图 2-1 基于 WWT 的天文数据获取与查询	12
图 2-2 基于 WWT 的可视化标注与结构构建	13
图 2-3 基于 WWT 的精准定位与快速跳转	14
图 2-4 基于 WWT 的天文事件模拟与复现	14
图 2-5 基于 WWT 的 FITS 图像渲染与闭环处理	15
图 2-6 工具调用示意图	16
图 2-7 RAG 示意图	17
图 3-1 天文数据查询中按照查询的类型划分的任务数量统计	22
图 3-2 仙女座的图像数据	23
图 3-3 光谱和光变曲线图	23
图 3-4 天文数据查询中按照工具的调用个数划分的任务数量统计	24
图 3-5 基于动态 RAG 的天文数据查询工具调用方法设计图	26
图 3-6 不同 LLM 对本章 RAG 工具调用方法的性能影响	34
图 4-1 WWT 智能交互系统中的自然语言星体检测交互示例	40
图 4-2 WWT 及数据分析工具类别分布统计	42
图 4-3 天文数据分析任务中按照任务类型进行划分	43
图 4-4 基于 WWT 的天文图像分析应用示例图	43
图 4-5 基于 WWT 的天文事件分析应用示例图	44
图 4-6 基于 WWT 的天文数据查询应用示例图	44
图 4-7 天文数据分析任务中按照智能体调用数量划分的统计结果	45
图 4-8 天文数据分析中按照任务所需的调用工具个数进行划分统计	46
图 4-9 基于反向递归多智能体编排的天文数据分析任务执行方法图	49
图 4-10 不同大语言模型在多智能体系统中的性能对比	57
图 4-11 WWT 中金星凌日可视化结果展示	58
图 5-1 WWT 智能交互系统原型图	62
图 5-2 WWT 智能交互系统用户用例图	63
图 5-3 系统总体设计图	64
图 5-4 空间交互与状态感知功能展示图	67
图 5-5 多智能体决策过程透明化展示图	68
图 5-6 多模态结果输出与 FITS 渲染展示图	69

表版

表 3-1 天文数据查询工具收集表	21
表 3-2 天文星表主要字段介绍	22
表 3-3 天文数据查询工具描述表	27
表 3-4 不同查询任务类型下的方法性能对比（%，加粗为最优）	30
表 3-5 不同工具调用数量下的方法性能对比（%，加粗为最优）	31
表 3-6 不同查询任务类型下的消融实验结果（%）	33
表 3-7 不同工具调用数量下的消融实验结果（%）	33
表 3-8 本章方法执行过程	36
表 3-9 Craft 的执行过程	36
表 3-10 Re-invoke 的执行过程	37
表 3-11 Toolshed 的执行过程	37
表 4-1 天文数据分析中按照任务所需的调用工具个数按难易进行划分	46
表 4-2 不同天文任务类型下的多智能体性能对比（%）	54
表 4-3 不同智能体调用数量下的多智能体性能对比（%）	55
表 4-4 不同工具调用数量下的多智能体性能对比（%）	56
表 4-5 金星凌日分析任务的正确执行流程与工具依赖	58
表 4-6 本章方法的执行步骤	59
表 4-7 AgentVerse 方法的执行步骤	59
表 4-8 AutoAgent 方法的执行步骤	60
表 4-9 AutoGen 方法的执行步骤	60
表 4-10 OWL 方法的执行步骤	61
表 5-1 系统环境配置表	66
表 5-2 系统功能测试用例表	70
表 5-3 系统非功能测试用例表	70

原创性声明

本人郑重声明：所呈交的学位论文，是本人在导师的指导下，独立进行研究所取得的成果。除文中已经注明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的科研成果。对本文的研究在做出重要贡献的个人和集体，均已在文中以明确方式标明。本人在导师指导下所完成的学位论文及相关的职务作品，知识产权归属贵州大学。本人完全意识到本声明的法律责任由本人承担。

论文作者签名：谢家福 日期：2026年6月5日

关于学位论文使用授权的声明

本人完全了解贵州大学有关保留、使用学位论文的规定，同意学校保留或向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅；本人授权贵州大学可以将本学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或其他复制手段保存论文和汇编本学位论文。

本学位论文属于：

保 密（ ），在_____年解密后适用授权。

不保密（☒）

（请在以上相应方框内打“√”）

论文作者签名：谢家福 导师签名：
日 期：2026年6月5日